

面向无人机遥感异构网络的注意力 LSTM 增强型风险感知垂直切换算法

多滨^[1], 刘同^[1], 郑宇翔^[1], 苏文^[1]

(1. 成都理工大学, 四川省成都市 610000)

摘 要: 无人机遥感监测系统在灾害评估、环境监测等大范围对地观测场景中广泛应用。无人机巡航时需持续穿越 5G、LTE 和 WiFi 三种异构网络的覆盖边界, 构成典型的候选网络垂直切换场景, 面临决策滞后、乒乓切换频繁以及固定属性权重难以适应动态飞行阶段的挑战。提出一种基于长短期记忆网络与注意力机制的自适应垂直切换方法 (LAAVHA, Long Short-Term Memory-Attention based Adaptive Vertical Handover Algorithm), 并在其基础上引入自适应滞后 (ADH, Adaptive Dynamic Hysteresis) 与风险敏感 TOPSIS (RS-TOPSIS, Risk-Sensitive TOPSIS) 两项增强机制, 形成增强型风险感知垂直切换算法 (ALERA, Attention-LSTM Enhanced Risk-aware Vertical Handoff Algorithm)。该方法利用堆叠 LSTM 预测候选网络短期状态变化, 通过注意力机制根据飞行阶段和移动状态动态生成属性权重, 融合当前与预测状态构建改进 TOPSIS 决策矩阵, 结合双重滞后机制抑制不必要切换; 增强机制进一步引入上下文感知的自适应滞后参数 (ADH) 和风险敏感 TOPSIS (RS-TOPSIS) 机制对候选网络评分进行波动风险惩罚, 提升算法在信道剧烈波动场景下的决策鲁棒性。基于 ns-3 网络仿真平台及其 AI 扩展模块 ns3-ai 搭建决策级实验平台—ns-3 负责异构网络物理仿真与指标采集, ns3-ai 通过共享内存实现仿真与 Python AI 推理的双向实时交互。50 组随机种子实验表明, LAAVHA 在代理异构网络场景下切换次数集中分布在 0–2 次区间。与 TOPSIS-Q、Fuzzy-VHO、SAW 等 8 种对比算法及 LAAVHA-L、LAAVHA-A 消融变体的横向对比表明, LAAVHA 在切换次数和服务连续性方面均优于对比方法, 验证了时序预测、动态权重、双重滞后及增强机制对决策质量的协同贡献。

关键词: 无人机遥感; 异构网络; 垂直切换; LSTM; 注意力机制; 自适应滞后; 风险敏感 TOPSIS

Attention-LSTM Enhanced Risk-aware Vertical Handoff Algorithm for UAV Remote Sensing Heterogeneous Networks

DUO Bin^[1], LIU Tong^[1], ZHENG Yuxiang^[1], SU Wen^[1]

1. Chengdu University of Technology, Chengdu 610000, China

Abstract: Unmanned aerial vehicle (UAV) remote sensing systems are widely deployed in large-scale earth observation missions including disaster assessment, agricultural survey, and environmental monitoring. During cruise missions, UAVs must traverse coverage boundaries of heterogeneous wireless networks (5G, LTE, WiFi), where

vertical handover faces challenges of decision latency, frequent ping-pong handovers, and poor adaptability of fixed attribute weights. An adaptive vertical handover method based on long short-term memory (LSTM) and attention mechanism (LAAVHA) is proposed, and two enhanced mechanisms—adaptive hysteresis and risk-sensitive TOPSIS—are further introduced to form ALERA. A stacked LSTM predicts short-term candidate-network state changes; an attention mechanism (embed_dim=5, num_heads=1) generates dynamic attribute weights according to flight phase and mobility conditions; an improved TOPSIS decision matrix fuses current and predicted states; and a dual hysteresis mechanism suppresses unnecessary handovers. The enhanced mechanisms further introduce context-aware adaptive hysteresis parameters (threshold auto-adjusted by SINR volatility, confirmation window adapted to flight speed) and a lower-confidence-bound penalty on historical score volatility, improving decision robustness under severe channel fluctuations. A decision-level experimental platform is built with ns-3 and its AI extension ns3-ai: ns-3 handles heterogeneous network simulation and metric collection, while ns3-ai enables bidirectional real-time Python interaction via shared memory. Fifty randomized-seed experiments show that LAAVHA keeps handover counts within the 0–2 range in the proxy heterogeneous network scenario. Comparison with eight baseline algorithms (TOPSIS-Q, Fuzzy-VHO, SAW, etc.) and two ablation variants (LAAVHA-L, LAAVHA-A) confirms that LAAVHA outperforms all counterparts in handover count and service continuity, verifying the synergistic contribution of temporal prediction, dynamic weighting, dual hysteresis, and the enhanced decision mechanisms.

Key words: UAV remote sensing, heterogeneous network, vertical handover, LSTM, attention mechanism, adaptive hysteresis, risk-sensitive TOPSIS

0 引言

无人机遥感系统在灾害评估、农业普查、环境监测等领域广泛应用, 无人机搭载的高分辨率光学/多光谱载荷在巡航过程中产生大量遥感图像数据, 需通过 5G、LTE 和 WiFi 等异构无线网络实时回传至地面站^[1-3]。然而, 无人机的高机动性导致其频繁穿越不同网络的覆盖边界, 触发垂直切换^[4]。传统垂直切换研究主要围绕多属性决策方法展开, 如 TOPSIS^[7-8]、VIKOR^[22]、GRA^[22]、COPRAS^[22]、SPOTIS^[22]、Fuzzy-VHO^[4]和 SAW 等, 通过构建信噪比、时延、吞吐量等网络属性的评价矩阵进行候选排序。这些方法存在两个共性问题: 一是权重通常由熵权法或层次分析法一次性确定^[10-11], 无法随飞行阶段和信道环境动态调整; 二是仅依据当前时刻的网络指标做决策, 缺乏对未来状态变化的前瞻性判断, 当无人机高速飞向 WiFi 覆盖边缘时, 可能在链路实际中断后才触发切换^[12-13]。此外, 近年深度强化学习 (DRL) 方法被引入切换决策^[12-14], 但其黑箱性质和训练不稳定性在安全攸关的遥感巡航场景中带来可解释性和可靠性方面的顾虑。

长短期记忆网络 (LSTM) 通过门控结构有效缓解梯度消失问题^[15], 具有捕获长时间序列依赖关系的能力, 已被应用于 5G 异构网络的切换判决和网络状态预测^[16-17]。然而, 单一 LSTM 网络存在两方面局限: 其一, LSTM 将候选网络的 5 维状态指标视为独立的时间序列分别建模, 无法显式捕获指标之间的耦合关系—例如吞吐量与丢包率的负相关性、SINR 与时延的关联性等; 其二, LSTM 输出的预测状态仍需配合固定或人工设定的属性权重才能完成多属性决策, 无法根据飞行阶段和移动状态自适应调整各指标的重要性。

综上所述, 当前无人机遥感异构网络中的垂直切换面临两个层面的挑战: 在算法层面, 传统多属性决

策方法 (Multiple Attribute Decision Making, MADM) 权重固定、缺乏时序预测能力, 单一 LSTM 即使引入预测机制仍无法自适应调节属性权重以适应飞行阶段变化; 在场景层面, 无人机巡航过程中信道环境动态变化—平稳飞行时信号波动小, 跨越覆盖边界或遭遇遮挡时信号剧烈振荡, 固定的切换阈值和确认窗口难以在两者之间取得平衡。两个层面的问题相互关联: 算法适应性的不足加剧了场景波动带来的切换不稳定, 而场景的动态变化又要求算法具备更强的环境感知能力。

针对上述两个层面相互关联的挑战, 本文提出分层次的解决方案。在算法层面, 构建基于长短期记忆神经网络和注意力机制的自适应垂直切换算法 (LAAVHA), 以引入注意力机制弥补传统 MADM 方法在动态权重与时序预测方面的不足。LAAVHA 采用“预测-权重-决策”三阶段架构: 堆叠 LSTM 预测候选网络短期状态变化; 注意力机制以当前网络状态矩阵为自注意力输入, 融合飞行速度与高度等移动特征, 输出随飞行阶段自适应变化的动态属性权重; 融合当前与预测状态构建改进 TOPSIS 决策矩阵, 结合双重滞后机制完成候选排序。LAAVHA 通过动态权重与前瞻预测, 克服了传统 MADM 方法权重固定和被动响应的问题, 实现了无人机遥感巡航场景下的稳定候选网络评价。在场景层面, 于 LAAVHA 决策框架之上进一步引入自适应滞后 (ADH) 与风险敏感 TOPSIS (RS-TOPSIS) 两项增强机制, 形成注意力 LSTM 增强型风险感知垂直切换算法 (ALERA)。ADH 将固定的切换阈值与确认窗口替换为上下文感知的可变参数—以服务网络近 5 个周期的 SINR 标准差度量信道波动, 阈值随波动从 0.03 线性增长至 0.08, 确认窗口随飞行速度在 [2, 4] 范围内自适应缩短。RS-TOPSIS 引入置信下界罚分, 以 $C_i^{\text{robust}} = C_i - 0.5\sigma_i^C$ 作为排序依据, 对评分波动较大的候选网络施加惩罚, 使排序偏好倾向历史表现更稳定的网络。两项增强机制均作用于决策层, 不改变 LAAVHA 模型结构, 协同实现了信道波动感知与风险规避决策, 从而解决了遥感巡航场景下固定参数切换策略的适应性不足问题。

1 系统模型与网络状态参数

考虑无人机遥感巡航场景: 无人机在 $2000 \text{ m} \times 2000 \text{ m}$ 的任务区域内沿预定航线飞行, 飞行高度为 $50 \sim 150 \text{ m}$, 巡航速度为 $5 \sim 30 \text{ m/s}$ 。任务区域内存在 5G、LTE 和 WiFi 三种候选接入网络, 其覆盖范围与部署密度各不相同—WiFi 热点覆盖半径约 200 m , 部署于地面站和关键拍摄点周边; LTE 基站覆盖半径约 $1 \sim 2 \text{ km}$, 沿航线稀疏分布; 5G 基站提供高速率但覆盖尚不连续。无人机在飞行过程中周期性采集各候选网络的状态信息, 用于切换决策^[21]。对于第 i 个候选网络, 其在时刻 t 的状态向量定义为

$$S_i(t) = [\text{SINR}_i(t), \text{RSRP}_i(t), D_i(t), T_i(t), \text{PLR}_i(t)]. \quad (1)$$

在遥感飞行场景中, 上述五个指标从不同维度刻画了候选网络服务遥感任务的能力: 当无人机从 WiFi 热点上空飞向任务区域边缘时, SINR 从数十 dB 单调下降至接近噪声底限, 直接反映了信号质量随距离和遮挡的衰减过程, 是判断是否触发切换的最直观依据; RSRP 表示参考信号接收功率, 与 SINR 共同决定链路预算是否满足解调门限—若 RSRP 低于接收灵敏度, 即使 SINR 尚可, 物理层也无法建立可靠连接; 端到端时延定义为数据包从地面站到达无人机应用层的往返时间, 在高速巡航阶段直接决定了飞控指令的响应速度与飞行安全裕度; 吞吐量衡量候选网络单位时间内可交付的有效载荷比特数, 对单张可达数 MB 的高分辨率遥感图像而言, 吞吐量不足将导致单次过顶时间内无法完成图像下传; 丢包率反映网络传输的可靠性, 即使在信号较强、吞吐量充裕的位置, 高丢包率也会使接收端重建的遥感图像出现条带缺失或块状模

糊。上述指标中，SINR、RSRP 和吞吐量属于效益型指标（数值越大越优），时延和丢包率属于成本型指标（数值越小越优）。为消除各指标量纲差异，采用 min-max 归一化方法将所有指标映射至 $[0, 1]$ 区间，并使归一化后的值越大表示候选网络在该维度上越优^[22]。

因此，式(1)不是单独用于描述网络状态的静态定义，而是后续算法链路的统一输入接口。对同一时刻 3 个候选网络的 $S_i(t)$ 按网络维度堆叠，可得到当前状态矩阵 $S_{\text{cur}} \in \mathbf{R}^{3 \times 5}$ ，该矩阵直接输入第 2.2 节的注意力权重生成模块；对单个候选网络连续 10 个决策周期的状态向量按时间维度堆叠，可得到历史状态张量 $X_k \in \mathbf{R}^{10 \times 5}$ ，该张量输入第 2.1 节的堆叠 LSTM 预测模块。也就是说，第 1 章给出的网络状态参数同时承担两类作用：横向上刻画同一时刻不同候选网络的优劣差异，纵向上刻画同一网络随无人机运动产生的短期演化趋势。

无人节点移动会引起候选网络信号质量和传输性能持续变化。在遥感巡航场景中，若仅依据当前时刻指标进行切换决策，无人机可能在高速接近 WiFi 覆盖边缘时未能提前切换，导致正在回传的图像数据因链路突然中断而丢失^[23]。因此，算法将过去若干个决策周期的网络状态组织为时序输入，用于预测短期未来状态，并将预测结果与当前状态共同用于最终决策。实验平台采用 ns-3 网络仿真器^[19]与其 AI 扩展模块 ns3-ai^[20]协同构建：ns-3 负责部署 5G/LTE/WiFi 异构网络拓扑、模拟无人机移动模型和采集物理层/传输层指标；ns3-ai 通过共享内存机制在 C++ 侧与 Python AI 推理侧之间建立双向通信通道—仿真侧每个决策周期将 3 个候选网络各 10 步历史 $\times 5$ 维指标（共 150 维）及移动状态写入共享内存，Python 侧加载预训练的 LAAVHA 模型读取状态数据并返回目标网络编号和候选网络评分，使深度学习推理与网络仿真同步执行，避免离线批处理时延。

2 LAAVHA 自适应垂直切换算法

基于第 1 章定义的系统模型与网络状态参数，本章提出基于长短期记忆神经网络和注意力机制的自适应垂直切换算法（LAAVHA），旨在解决传统 MADM 方法在无人机遥感巡航场景中权重固定和缺乏时序预测能力的不足。LAAVHA 以第 1 章所述的 5 维网络状态向量和滑动窗口机制为输入，依次通过堆叠 LSTM 预测、注意力动态权重生成和融合预测状态的改进 TOPSIS 决策三个模块完成候选网络评估与切换判决，最后引入自适应滞后（ADH）与风险敏感 TOPSIS（RS-TOPSIS）两项增强机制形成 ALERA。

图 1 LAAVHA 与 ALERA 算法框架




图 1 中的各模块并非并列孤立运行，而是围绕同一组网络状态形成端到端变量流：第 1 章采集并归一化后的历史序列 X_k 首先进入堆叠 LSTM，得到下一时刻预测状态 S_{pred} ；同一决策周期的当前状态矩阵 S_{cur} 进入注意力模块，与速度、高度等移动特征共同生成动态权重 w ；随后 S_{cur} 、 S_{pred} 和 w 在改进 TOPSIS 模块中汇合，输出候选网络贴近度 C_i ；最后， C_i 与当前接入网络 N_{cur} 共同进入滞后判决和 ALERA 增强机制，形成最终切换决策。按照这一链路，2.1 节解决“未来状态是什么”，2.2 节解决“当前任务更重视哪些指标”，2.3 节解决“综合当前与未来后哪个网络更优”，2.4 节进一步解决“在波动环境下是否应该执行这次切换”。

2.1 基于堆叠 LSTM 的网络状态预测

设时间窗口长度 $T = 10$ （即 1.0 s 历史，决策周期 $\tau = 0.1$ s），候选网络 $k \in \{1, 2, 3\}$ （分别对应 5G、LTE、WiFi）的历史输入张量为 $X_k \in \mathbb{R}^{10 \times 5}$ —10 个连续决策周期的 5 维归一化状态向量按行堆叠。预测目标是下一时刻的状态向量 $\hat{s}_k(t + \tau) \in \mathbb{R}^5$ 。

$$h_{1,k} = \text{LSTM}_1(X_k; \theta_1), \quad h_{1,k} \in \mathbb{R}^{10 \times 128}, \quad (2)$$

$$h_{2,k} = \text{LSTM}_2(h_{1,k}; \theta_2), \quad h_{2,k} \in \mathbb{R}^{10 \times 64}, \quad (3)$$

$$\hat{s}_k(t + \Delta t) = W_{pred} h_{2,k}[-1] + b_{pred}, \quad \hat{s}_k \in \mathbb{R}^5. \quad (4)$$

式中 θ_1 、 θ_2 分别为两层 LSTM 的可训练参数（含输入门、遗忘门、输出门及细胞状态的权重与偏置）， $W_{pred} \in \mathbb{R}^{5 \times 64}$ 与 $b_{pred} \in \mathbb{R}^5$ 为预测头的全连接权重与偏置， $h_{2,k}[-1]$ 表示取 LSTM2 最后时刻的输出向量。式(2)–(4)完整刻画了预测分支的维度变换：10 步 $\times 5$ 维指标 $\rightarrow \text{LSTM}_1(5 \rightarrow 128) \rightarrow \text{LSTM}_2(128 \rightarrow 64) \rightarrow \text{fc_pred}(64 \rightarrow 5)$ 。三个候选网络共享同一组 LSTM 参数（即对 5G、LTE、WiFi 使用相同的 θ_1 、 θ_2 、 W_{pred} 、 b_{pred} ），各自独立输入历史序列 X_k ，预测结果堆叠为 $S_{pred} \in \mathbb{R}^{3 \times 5}$ —即三个网络各自下一时刻的五项指标预测值。

需要强调的是， S_{pred} 并不是直接决定切换目标的最终评分，而是把历史序列 X_k 压缩为下一决策周期可比较的预测状态。其作用是在第 2.3 节式(11)中与当前状态 S_{cur} 共同构成融合决策矩阵，使 TOPSIS 排序同时具有当前实测依据和短期前瞻信息。若没有这一输出，后续决策只能退化为对 S_{cur} 的被动排序，这正是消融变体 LAAVHA-L 用于检验的部分。

2.2 面向飞行阶段的动态权重生成

在垂直切换决策中，不同网络属性的重要性会随场景变化而变化。例如，无人机处于巡航飞行阶段时，链路稳定性和控制指令时延对飞行安全更加关键；当抵达拍摄点进入图像回传阶段时，吞吐量和丢包率的权重应显著提升，以确保高分辨率遥感图像在有限时间窗口内完整送达地面站^[24]。固定权重难以刻画这种动态变化。

为解决固定权重无法匹配遥感飞行中不同阶段需求差异的问题，LAAVHA 引入自注意力机制（Self-Attention）^[18]。将当前 3 个候选网络的 5 维状态向量按行堆叠为矩阵 $S_{\text{cur}} \in \mathbf{R}^{3 \times 5}$ ，令自注意力的查询(Query)、键(Key)、值(Value)均等于 S_{cur} （即 $Q = K = V = S_{\text{cur}}$ ， $\text{embed_dim}=5$ ， $\text{num_heads}=1$ ）。其中， embed_dim 表示注意力模块中每个输入向量的特征维度；本文每个候选网络由 SINR、RSRP、时延、吞吐量和丢包率 5 个归一化指标描述，因此 embed_dim 取 5，与 S_{cur} 的列数一致。 num_heads 表示并行注意力头的数量；由于本文属性维度仅为 5，若采用多头注意力会使每个头分到的特征维度过小，不利于解释各指标权重，因此采用单头注意力（ $\text{num_heads}=1$ ）直接学习 5 个属性之间的相关性。随后通过缩放点积注意力计算属性间的交互权重—注意力矩阵 A 的每个元素 a_{ij} 表示属性 j 对属性 i 的重要性。再经跨网络均值池化提取属性级上下文 $c \in \mathbf{R}^5$ ，并联合飞行速度 v 与高度 h 经 $W_{\text{mob}} \in \mathbf{R}^{2 \times 16}$ 映射为移动特征 $m \in \mathbf{R}^{16}$ ，拼接后经全连接层投影与 softmax 归一化输出 5 维动态权重 w ：

$$Q = K = V = S_{\text{cur}} \in \mathbf{R}^{3 \times 5}, \quad (5)$$

$$A = \text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{5}}\right)V, \quad A \in \mathbf{R}^{3 \times 5}, \quad (6)$$

$$c = \text{mean}(A, \text{dim} = 0) \in \mathbf{R}^5, \quad (7)$$

$$m = \text{ReLU}(W_{\text{mob}}[v, h]^T), \quad W_{\text{mob}} : \mathbf{R}^2 \rightarrow \mathbf{R}^{16}, \quad m \in \mathbf{R}^{16}, \quad (8)$$

$$w = \text{softmax}(W_{\text{weight}}[c \parallel m]), \quad W_{\text{weight}} : \mathbf{R}^{21} \rightarrow \mathbf{R}^5, \quad w \in \mathbf{R}^5, \quad \sum_j w_j = 1. \quad (9)$$

式(5)–(9)描述了动态权重的完整生成过程：以当前时刻网络状态 $S_{\text{cur}} \in \mathbf{R}^{3 \times 5}$ 为自注意力输入，缩放点积注意力获得 3×5 注意力矩阵 A ；跨网络均值池化得到 5 维属性级上下文 c ； $W_{\text{mob}} : 2 \rightarrow 16$ 将速度和高度映射为 16 维移动特征 m 引入飞行状态；最后拼接为 21 维经 W_{weight} 投影和 softmax 归一化输出 5 维动态权重 w 。

因此，注意力模块的输出 w 也不是单独评价网络优劣的结果，而是第 2.3 节 TOPSIS 加权步骤的输入。具体而言，式(14)中的 $v_{ij} = w_j r_{ij}$ 将 w_j 作用到融合矩阵 D 的第 j 个属性维度，使 SINR、RSRP、时延、吞吐量和丢包率的相对重要性能随当前网络状态和飞行状态变化。这样，LSTM 分支提供“预测到哪里去”，Attention 分支提供“当前该重视什么”，二者在 TOPSIS 排序阶段共同影响最终贴适度 C_i 。

2.3 融合预测状态的改进 TOPSIS 决策

本节是前述两个学习模块的汇合点：第 2.1 节输出的 S_{pred} 提供短期未来状态，第 2.2 节输出的 w 提供当前飞行阶段下的属性重要性，第 1 章定义并实时采集的 S_{cur} 提供当前观测状态。在遥感巡航场景中，候选网络的优劣需要综合权衡信号强度、传输能力与可靠性三个维度—不存在单一指标最优的“完美网络”。TOPSIS 的基本思想是将各候选网络在多维属性空间中的位置与虚拟的“最优网络”和“最劣网络”进行比

较^[7-8]。为避免传统 TOPSIS 仅依赖当前状态导致的被动决策，LAAVHA 首先将当前状态与 LSTM 预测状态进行融合，构建决策矩阵：

$$s_{\text{norm}} = \frac{s - s_{\min}}{s_{\max} - s_{\min}}, \quad \text{for each indicator } j, \quad (10)$$

$$d_{ij} = \alpha s_{\text{cur}}(i, j) + (1 - \alpha) s_{\text{pred}}(i, j), \quad \alpha = 0.6, \quad (11)$$

$$d_{ij} \leftarrow 1 - d_{ij}, \quad j \in \{\text{delay, PLR}\}. \quad (12)$$

式(10)–(12)中, i 表示候选网络编号, $i = 1, 2, 3$ 分别对应 5G、LTE 和 WiFi; j 表示属性指标编号, 本文共有 5 个属性, 即 SINR、RSRP、时延、吞吐量和丢包率。 s 表示某一候选网络在第 j 个属性上的原始或待归一化指标值, $s_{\min}$ 和 $s_{\max}$ 分别表示当前决策周期内该属性在全部候选网络中的最小值和最大值, s_{norm} 为映射到 $[0, 1]$ 区间后的归一化值。 $s_{\text{cur}}(i, j)$ 表示候选网络 i 在当前时刻第 j 个属性上的归一化状态值, $s_{\text{pred}}(i, j)$ 表示 LSTM 预测得到的下一时刻对应属性值, d_{ij} 表示二者融合后写入决策矩阵 D 的元素。 α 为当前状态与预测状态的融合系数 (本文取 $\alpha = 0.6$), $\alpha = 0.6$ 使当前实测状态占主导、预测信息提供前瞻引导, 在遥感巡航中实现平滑过渡。由于时延和丢包率属于成本型指标, 数值越小越优, 因此式(12)对其归一化值执行取反, 使所有属性在进入 TOPSIS 前统一为“数值越大越优”。将成本型指标取反后得到融合决策矩阵 $D \in \mathbf{R}^{3 \times 5}$, 进入标准化 TOPSIS 流程:

$$r_{ij} = \frac{d_{ij}}{\sqrt{\sum_{k=1}^3 d_{kj}^2}}, \quad (13)$$

$$v_{ij} = w_j r_{ij}, \quad (14)$$

$$v_j^+ = \max_i v_{ij}, \quad v_j^- = \min_i v_{ij}, \quad (15)$$

$$D_i^+ = \sqrt{\sum_{j=1}^5 (v_{ij} - v_j^+)^2}, \quad D_i^- = \sqrt{\sum_{j=1}^5 (v_{ij} - v_j^-)^2}, \quad (16)$$

$$C_i = \frac{D_i^-}{D_i^+ + D_i^-}, \quad C_i \in [0, 1]. \quad (17)$$

式(13)–(17)中, r_{ij} 表示融合决策矩阵 D 经向量归一化后的元素, 分母 $\sqrt{\sum_{k=1}^3 d_{kj}^2}$ 为第 j 个属性在 3 个候选网络上的欧氏范数; 此处 k 仅为求和索引, 表示候选网络编号, 不再表示第 2.1 节中的历史输入序列编号。 w_j 为第 2.2 节 Attention 模块输出的第 j 个属性动态权重, v_{ij} 为归一化元素 r_{ij} 经权重 w_j 加权后的结果。 v_j^+ 和 v_j^- 分别表示第 j 个属性上的正理想解和负理想解, 即所有候选网络加权归一化值中的最大值和最小值。 D_i^+ 表示候选网络 i 到正理想解的欧氏距离, D_i^- 表示其到负理想解的欧氏距离; C_i 为候选网络 i 的相对贴近度, 取值范围为 $[0, 1]$ 。因此, 式(13)–(17)将 3×5 的融合决策矩阵 D 转换为三个候选网络的相对贴近度排序: 向量归一化消除指标量纲 $\rightarrow$ 动态权重加权 $\rightarrow$ 确定正/负理想解 $\rightarrow$ 欧氏距离计算 $\rightarrow$ 输出 $C_i \in [0, 1]$ 。 C_i 越接近 1, 表示该网络对遥感任务中图像回传、飞控响应和链路可靠性三者的综合保障能力

越强。

$$N^* = \arg \max_i C_i, \quad (18)$$

$$\text{Decision} = \begin{cases} \text{switch to } N^*, & C(N^*) - C(N_{\text{cur}}) > \Delta_{\text{th}} \text{ and lasts } T \text{ consecutive cycles,} \\ \text{keep } N_{\text{cur}}, & \text{otherwise,} \end{cases} \quad (19)$$

式(18)–(19)中, N^* 表示当前决策周期内贴近期 C_i 最大的候选网络, N_{cur} 表示无人机当前正在接入的服务网络, $C(N^*)$ 和 $C(N_{\text{cur}})$ 分别表示目标候选网络和当前服务网络的 TOPSIS 贴近期。 Δ_{th} 为切换触发阈值, 用于要求目标网络相对当前网络具有足够明显的评分优势; T 为连续确认窗口, 用于要求该优势连续保持若干个决策周期。本文设置 $\Delta_{\text{th}} = 0.05$, $T = 3$ 。为降低网络状态瞬时波动引发的乒乓切换, 算法设置双重滞后机制。式(18)–(19)描述了切换的最终裁定逻辑: 仅当得分最高的候选网络 N^* 的贴近期超过当前服务网络 N_{cur} 达 $\Delta_{\text{th}} = 0.05$ 以上, 且该条件在连续 $T = 3$ 个决策周期内持续满足时, 才正式执行切换。在遥感任务中, 一次乒乓切换可能导致正在传输的图像数据包丢失–滞后机制通过阈值过滤小幅评分波动, 通过时间窗口消除瞬时信道异常触发的虚假切换, 两者协同保障遥感数据传输的连续性。表 1 是整个 LAAVHA 算法的总体流程, 对上述预测、权重生成、TOPSIS 排序和滞后裁定步骤进行汇总。

表 1 LAAVHA 垂直切换算法总体流程

步骤	说明
1	采集 5G、LTE 和 WiFi 候选网络的 SINR、RSRP、时延、吞吐量和丢包率
2	对效益型和成本型指标进行归一化处理, 构建历史状态序列
3	利用堆叠 LSTM 预测各候选网络短期未来状态
4	基于注意力机制生成动态属性权重
5	融合当前状态与预测状态, 构建改进 TOPSIS 决策矩阵
6	计算候选网络相对贴近期, 选取得分最高的目标网络
7	结合贴近期阈值和时间窗口滞后机制输出最终切换决策

需要指出的是, 上述 TOPSIS 决策流程和双重滞后机制在训练阶段用于生成监督标签: 对每条历史网络状态记录, 执行完整的融合决策矩阵构建、加权 TOPSIS 排序和滞后条件检查, 将最终选定的最优网络编号作为该记录的训练目标。部署阶段, 训练好的 LAAVHA_Net 仅输出 $S_{\text{pred}} \in \mathbf{R}^{3 \times 5}$ 和 $w \in \mathbf{R}^5$ –神经网络不直接输出切换决策, 而是作为“状态感知器”提供时序预测与动态权重; 推理侧随后依次执行式(11)的融合矩阵构建、式(13)–(17)的 TOPSIS 排序和式(18)–(19)的滞后裁定, 最终输出目标网络编号。由此可见, X_k 、 S_{cur} 、 S_{pred} 、 w 、 D 、 C_i 和 Decision 构成一条连续的数据链, 而不是多个互不相关的公式集合。这一“神经网络预测 + 规则化决策”的混合架构, 使算法的每一步变换均可由式(1)–(19)完整追踪, 兼顾了深度学习的时序建模能力和传统多属性决策的透明性与可解释性。

上述 LAAVHA 框架中的双重滞后机制采用固定参数 ($\Delta_{\text{th}} = 0.05, T = 3$), 在信道平稳场景下获得良好效果。但在无人机遥感巡航场景中, 信道状态随飞行位置和周围环境持续变化–平稳飞行时信号波动小, 跨越覆盖边界或遭遇遮挡时信号剧烈振荡。固定的滞后参数无法感知这种环境变化, 因此本节引入自适应

滞后 (ADH) 与风险敏感 TOPSIS (RS-TOPSIS) 两项决策层增强机制, 在不改变 LSTM-Attention 模型的前提下使切换参数随信道波动和飞行状态自适应调节, 形成 ALERA。

2.4 ALERA 增强型风险感知垂直切换算法

上述 LAAVHA 决策流程中的双重滞后机制采用固定参数 ($\Delta_{th} = 0.05, T = 3$), 在信道平稳场景下表现良好, 但缺乏对场景变化的适应能力—当网络波动加剧时, 固定阈值可能无法有效过滤瞬时异常; 当飞行速度显著变化时, 固定确认窗口可能无法及时响应。此外, 原始 TOPSIS 排序仅考虑候选网络的期望贴近度, 未对评分序列的波动性进行风险建模。为此, 在不重新训练模型的条件下, 提出以下两项增强机制。二者沿用前文的决策输出而非另起一套评价体系: ADH 读取当前服务网络的 SINR 历史和飞行速度, 更新式(19)中的 Δ_{th} 与 T ; RS-TOPSIS 读取第 2.3 节输出的贴近度序列 C_i , 将其修正为风险惩罚后的 C_i^{robust} 再参与排序。

2.4.1 自适应滞后参数

将固定阈值 Δ_{th} 和窗口 T 替换为上下文感知的可变参数。定义近期 SINR 波动度 σ 为当前服务网络近 5 个决策周期 SINR 的标准差, 飞行速度 v 由仿真侧实时传入。这里的 σ 来自式(1)中 SINR 维度的历史观测, v 来自第 2.2 节已用于动态权重生成的移动状态输入, 因此 ADH 复用已有状态信息, 只改变最终滞后判决的门槛和确认长度。自适应阈值和窗口计算公式为:

$$\Delta_{th} = 0.03 + 0.05 \left(\frac{\sigma}{10} \right), \quad \sigma \in [0, 10], \quad (20)$$

$$T = \max \left(2, \left\lfloor 4 - \frac{2v}{30} \right\rfloor \right), \quad v \in [0, 30] \text{ m/s}. \quad (21)$$

式(20)在信道稳定 ($\sigma \approx 0$) 时给出基础阈值 0.03, 低于原始固定值 0.05, 为快速响应真实退化预留空间; 波动修正项使阈值随 SINR 波动线性增长至最高 0.08, 在信道振荡时抬高切换门槛以抑制乒乓。式(21)在低速飞行 ($v \approx 5 \text{ m/s}$) 时给出窗口 4, 提供充分的确认周期; 窗口随速度增加而缩短至最低 2, 使高速无人机飞越覆盖边界时能及时切换。参数范围 ($\Delta_{th} \in [0.03, 0.08], T \in [2, 4]$) 确保了极端条件下的基本防抖能力。窗口随速度增加而缩短的设计依据在于: 高速飞行时网络覆盖边界转瞬即逝—以 30 m/s 飞行时, 单个决策周期 (0.1 s) 内无人机已移动 3 m, 若维持长窗口 $T = 4$ (0.4 s) 则确认期间位移达 12 m, 可能已从 WiFi 覆盖中心飞至边缘, 初始判断在确认完成时已失效; 缩短至 $T = 2$ (0.2 s, 位移 6 m) 使算法在覆盖边界附近能更快锁定真正需要切换的时刻, 以少量防抖冗余换取切换时效。反之低速 5 m/s 时 $T = 4$ 期间仅位移 2 m, 网络条件几乎不变, 长窗口可充分过滤偶然抖动而不增加失效风险。

2.4.2 风险敏感 TOPSIS

原始 TOPSIS 以当前贴近度 C_i 作为排序依据。该 C_i 正是式(17)在融合 S_{cur} 、 S_{pred} 和 w 之后得到的排序输出; RS-TOPSIS 并不替换前面的预测和加权过程, 而是在已有 C_i 序列之上加入风险约束。增强版引入置信下界 (Lower Confidence Bound, LCB) 思想, 对候选网络评分减去其历史波动惩罚项:

$$C_i^{robust} = C_i - \lambda \sigma_i^C, \quad \lambda = 0.5. \quad (22)$$

其中 σ_i^C 为网络 i 近 5 轮评分的标准差, $\lambda = 0.5$ 为风险厌恶系数。该机制的核心思想是—在多个候选网络贴近度接近时, 优先选择评分稳定的网络而非均值略高但波动剧烈的网络。在遥感巡航场景中, 若 LTE 在近 5 个周期内贴近度持续上升、方差较小, 而 WiFi 贴近度在高低之间大幅跳动, 即使 WiFi 的当前贴近度

略高于 LTE, C^{robust} 排序仍将偏好 LTE, 保障遥感数据传输的连续性。

两项增强机制的关键优势在于: 无需重新训练 LSTM-Attention 模型, 仅修改决策层的参数和排序逻辑, 即可为算法增加环境感知能力。从计算复杂度看, 设候选网络数为 R , 状态属性维度为 d , LSTM 输入窗口长度为 K , 增强机制使用的近期历史长度为 $K_c = 5$ 。ADH 仅对当前服务网络近 K_c 个 SINR 值计算标准差, 并执行阈值和窗口的线性更新, 复杂度为 $O(K_c) = O(1)$; RS-TOPSIS 对 R 个候选网络分别计算近 K_c 轮贴近度标准差并完成 LCB 罚分, 复杂度为 $O(R \cdot K_c)$ 。在本文实验设置中 $R = 3$ 、 $K_c = 5$, 两项增强机制每个决策周期不增加可训练参数, 也不改变 LSTM 和 Attention 的前向推理结构。相比堆叠 LSTM 预测和注意力权重生成的主要计算开销, ADH 与 RS-TOPSIS 的额外负担可以忽略, 因此能够以很低代价获得信道波动感知和风险规避能力。在信道平稳时, 自适应参数退化为接近原始固定值, 与原版表现一致; 在信道剧烈波动时, 自适应阈值、缩短窗口和风险罚分协同作用, 抑制乒乓切换。

2.5 算法复杂度与总结

表 2 汇总了 LAAVHA 及 ALERA 各算法模块的输入/输出、核心流程与计算复杂度, 表中顺序也对应算法的实际数据流。堆叠 LSTM 预测模块 (2.1 节) 以滑动窗口内的历史状态张量 $X_k \in \mathbf{R}^{10 \times 5}$ 为输入, 通过两层 LSTM 提取时序特征后经全连接头输出下一时刻的预测状态 $S_{\text{pred}} \in \mathbf{R}^{3 \times 5}$, 其计算瓶颈在于 LSTM 的门控矩阵运算, 复杂度为 $O(R \cdot K \cdot d \cdot h^2)$ 。注意力动态权重模块 (2.2 节) 以当前状态矩阵 $S_{\text{cur}} \in \mathbf{R}^{3 \times 5}$ 为自注意力输入, 融合移动特征后输出 5 维动态权重 $w \in \mathbf{R}^5$, 自注意力计算复杂度为 $O(R^2 \cdot d)$ 。改进 TOPSIS 决策模块 (2.3 节) 将 S_{cur} 与 S_{pred} 以融合系数 $\alpha = 0.6$ 加权组合, 经归一化后以动态权重 w 执行加权 TOPSIS 排序, 输出候选网络贴近度 C_i , 整体复杂度为 $O(R \cdot d)$ 。ADH 自适应滞后 (2.4.1 节) 和 RS-TOPSIS 风险敏感排序 (2.4.2 节) 属于决策层增强, 分别把 SINR 历史、飞行速度和 C_i 历史反馈到最终判决环节, 计算量分别为 $O(1)$ 和 $O(R \cdot K_c)$, 其中 $K_c = 5$ 为增强机制使用的固定历史长度, 不增加模型推理负担。整体算法的端到端推理复杂度由 LSTM 预测和注意力权重生成主导, 增强机制只引入常数级或线性于候选网络数的轻量统计计算, 远低于单个决策周期 0.1 s 的时间预算, 满足无人机遥感巡航场景下的实时切换决策需求。

表 2 算法总结

算法模块	输入/输出	核心流程	复杂度
堆叠 LSTM 预测	输入: $3 \times 10 \times 5$ 状态张量; 输出: 预测状态	LSTM1(5128)→LSTM2(12864)→fc(64→5)	$\rightarrow O(R \cdot K \cdot d \cdot h^2)$
注意力动态权重	输入: 3×5 状态矩阵 + 移动特征; 输出: 5 维动态权重	Self-Attn→均值池化→拼接移动特征→softmax	$O(R^2 \cdot d)$
改进 TOPSIS 决策	输入: 当前 + 预测状态 + 动态权重; 输出: 候选网络贴近度 C_i	融合矩阵→加权归一化→正负理想解→贴近度	$O(R \cdot d)$
ADH 自适应滞后	输入: SINR 历史 + 飞行速度; 输出: 自适应 Δ_{th}, T	SINR 波动度计算→阈值线性调节→窗口自适应	$O(1)$
RS-TOPSIS	输入: 近 5 轮贴近度历史; 输出: LCB 调整后排序	历史标准差→罚分计算→ C_{robust} 排序	$O(R \cdot K_c)$

3 仿真实验与结果分析

3.1 实验平台与参数设置

为验证 LAAVHA 决策流程的有效性, 基于 ns-3.45^[19]和 ns3-ai^[20]搭建了网络仿真与 Python 模型推理协同平台。仿真侧周期性采集候选网络指标并写入共享内存, Python 侧加载训练好的 LAAVHA 模型, 读取网络状态、速度、高度和当前网络编号, 输出目标网络编号及候选网络评分。(网络编号约定: 0=5G, 1=LTE, 2=WiFi) 模型输入为 3 个候选网络各自 5 维指标的历史序列 (3 网络 $\times$ 10 时间步 $\times$ 5 指标 = 150 维总输入), 每个网络独立经堆叠 LSTM 处理; 移动状态输入为 2 维 (速度、高度); 输出为 5 维预测状态向量及 5 维动态权重向量, 经改进 TOPSIS 后得到候选网络评分。实验采用 50 组随机种子 (200~249), 模拟无人机在不同初始位置和高度条件下执行遥感巡航任务。仿真时长为 10 s, 决策周期为 0.1 s, 每组实验产生 100 次决策。为模拟实际飞行中的位置偏差和高度波动, 启用位置扰动 (30 m) 和高度扰动 (10 m)。

表 3 给出了本节实验的主要平台、网络场景、模型结构和训练/推理参数。先列出实验参数的原因在于, 后续对比算法、指标来源和结果分析均建立在同一组仿真设置之上; 明确这些基础条件后, 再说明对比算法范围和候选网络指标来源, 能够避免读者将算法差异与实验环境差异混淆。

表 3 实验参数设置

参数	取值
仿真平台	ns-3.45, ns3-ai, Python/PyTorch
候选网络	5G、LTE、WiFi
算法范围	LAHVHA、8 种对比算法和 2 种消融变体
运行次数	每种算法 50 组随机场景
仿真时长	10 s
决策周期	0.1 s
每次运行决策数	100
随机种子	200~249
FlowMonitor 模式	feed
指标维度	SINR、RSRP、时延、吞吐量、丢包率
位置扰动	30 m
高度扰动	10 m
时间窗口 T	10
LSTM 隐藏单元	第一层 128, 第二层 64
注意力头数 (num_heads)	1 (embed_dim=5 约束)
融合系数 α	0.6
双重滞后参数	$\Delta_{th} = 0.05$, 确认窗口 $T_h = 3$
增强机制参数	ADH 历史长度 $K_c = 5$, RS-TOPSIS 风险系数 $\lambda = 0.5$
数据集划分	训练/验证 = 80%/20%
优化器	Adam
早停策略	验证集损失连续 10 个 epoch 不下降

实验除 LAHVHA 外, 还运行了 TOPSIS-Q、Fuzzy-VHO、SAW、VIKOR、GRA、COPRAS、SPOTIS 和最强信号法等 8 种对比算法以及 LAHVHA-L、LAHVHA-A 两种消融变体。这 8 种对比算法覆盖了模糊逻辑式 (Fuzzy-VHO)、简单加权式 (SAW)、补偿式 (VIKOR)、距离式 (TOPSIS-Q)、关联度式 (GRA)、比例式 (COPRAS) 和参考点式 (SPOTIS) 七种主流决策范式, 为全面评估 LAHVHA 的决策性能提供了多维参照。对比算法来源与设置如下: TOPSIS-Q 基于 TOPSIS 网络选择思想及熵权改进 TOPSIS 方法^[7-8,30]; Fuzzy-VHO 参考无人机 5G 网络中的模糊切换机制^[4]; SAW 作为经典加权和 MADM 基线, VIKOR、GRA、COPRAS 和 SPOTIS 选自主流 MADM 决策范式及其网络选择综述^[11,22,30]; 最强信号法为本文设置的单因素启发式基线, 仅依据 SINR 最大原则选择候选网络。LAHVHA-L 表示去除 LSTM 预测分支的消融变体, 直接以当前状态替代预测状态, 保留 Attention 权重与双重滞后; LAHVHA-A 表示去除 Attention 动态权重分支的消融变体, 保留 LSTM 预测和双重滞后, 并以熵权法生成 TOPSIS 权重。

5G 候选网络由代理链路表示, 其 SINR 和 RSRP 由基于位置的传播模型计算, 传输类指标来自点到点代理流的 FlowMonitor 统计; 切换事件表示 LAHVHA 输出的网络编号变化, 并未执行真实 WiFi 解除关联、LTE 分离或 5G 新空口 (NR, new radio) 协议栈切换。各候选网络指标来源见表 4。

表 4 候选网络指标来源


网络	SINR/RSRP	时延	吞吐量	丢包率
WiFi	基于 MobilityModel 位置的传播代理值	FlowMonitor	PacketSink 区间接收字节	FlowMonitor
LTE	基于 MobilityModel 位置的传播代理值	FlowMonitor	FlowMonitor	FlowMonitor
5G	到假设下一代节点 B (gNB, next generation NodeB) 的传播代理值	点到点代理流 Flow-Monitor	点到点代理流 Flow-Monitor	点到点代理流 FlowMonitor

表 4 用于说明第 3 章实验中五类网络状态指标的采集来源。SINR 和 RSRP 主要反映物理层链路质量，实验中依据无人机与接入点或基站的相对位置及传播代理模型计算得到；时延、吞吐量和丢包率主要反映传输层服务质量，其中 WiFi 吞吐量由 PacketSink 在相邻决策周期内的接收字节数换算，LTE 和 5G 的传输类指标由 FlowMonitor 统计得到。需要强调的是，该表刻画的是决策级仿真平台中的指标来源映射，而非完整协议栈实网测量流程：各候选网络在同一决策周期内提供同维度指标，随后由 LAHVHA 及对比算法统一归一化并输入多属性决策模块。这样设置可以保证不同算法面对完全一致的候选网络状态，避免因采集口径差异影响横向比较。

3.2 对比算法横向比较

为系统评估 LAHVHA 在不同决策范式下的性能优势，选择 8 种具有代表性的对比算法在同一实验条件下进行横向比较。Fuzzy-VHO 基于 Mamdani 模糊推理系统，将 SINR 和 RSRP 模糊化后通过规则库推理输出切换决策，无需精确数学模型；SAW 以固定权重对所有归一化属性进行简单加权求和，代表最基本的 MADM 方法；TOPSIS-Q 采用熵权法确定属性权重并执行标准 TOPSIS 排序，不涉及时序预测；GRA 通过计算各候选网络与理想参考序列的灰色关联度进行排序，对不确定性信息具有较好的处理能力；VIKOR 基于折中规划思想在群体效用与个体遗憾之间寻求平衡；COPRAS 对效益型和成本型指标分别评估后计算综合效用度；SPOTIS 以参考点距离最小化为目标进行排序。最强信号法直接选择 SINR 最大的候选网络，作为单因素基线。上述 11 种算法对比见图 2。


图2 11种算法平均切换次数对比 (mean $\pm$ std, n=50)



3.3 代表性算法决策过程对比

图3以2行 $\times$ 3列布局对比了LAAVHA、TOPSIS-Q和Fuzzy-VHO三种算法在同一随机种子(seed=200)下的决策过程。该组时序对比的目的不是单纯选择横向统计中切换次数最少的两个算法，而是选择最能解释LAAVHA改进来源的参照对象。TOPSIS-Q与LAAVHA同属TOPSIS排序框架，差异主要在于是否引入LSTM预测、Attention动态权重和双重滞后，因此二者可以形成较清晰的控制变量对比，用来观察预测状态和动态权重加入后，候选网络贴进度曲线是否更稳定、切换触发是否更克制。Fuzzy-VHO则代表另一类规则驱动方法，其决策依赖模糊隶属函数和规则库，对SINR、RSRP等局部波动更敏感；将其与LAAVHA并列，可以从不同决策范式角度展示动态多属性融合方法相对于规则式切换方法的鲁棒性。相较之下，最强信号法和SAW虽然在平均切换次数上可能较低，但前者只依据单一SINR，后者采用固定加权求和，缺少可与LAAVHA内部评分机制对应的时序解释维度，因此更适合作为总体统计基线，而不适合作为图3中的机制分析对象。上排三幅子图的纵轴为贴进度(Closeness Score)，展示5G、LTE和WiFi三个候选网络在TOPSIS排序中的综合得分变化—贴进度越接近1，表示该网络对遥感任务的综合保障能力越强；下排三幅子图的纵轴为SINR(dB)，展示同一仿真中三个网络的物理层信号质量变化。红色竖虚线标记切换发生时刻。可以观察到，LAAVHA的5G贴进度在全过程中保持稳定高水平(0.99~1.00)，LTE和WiFi评分均远低于5G，结合双重滞后机制($\Delta_{th} = 0.05, T = 3$)全程未触发任何切换—尽管下排SINR子图显示5G信号并非始终最高，但注意力机制生成的动态权重综合了时延、吞吐量和丢包率等多维指标后仍然选择5G，体现了多属性融合决策的优势。相比之下，TOPSIS-Q在5G与WiFi贴进度接近时发生了数次切换，Fuzzy-VHO因模糊规则对SINR波动敏感而产生多次切换—这直观展示了时序预测和动态权重对决策稳定性的关键贡献。


图3 LAAVHA/TOPSIS-Q/Fuzzy-VHO 候选网络评分与 SINR 时序对比 (seed=200, 竖线 = 切换时刻)



3.4 消融实验验证

为量化 LSTM 预测模块和注意力动态权重模块对 LAAVHA 决策质量的贡献, 设计消融实验。LAAVHA-L 为移除 LSTM 预测分支的版本, 直接令预测状态等于当前状态, 仅保留 Attention 权重生成、改进 TOPSIS 和双重滞后逻辑, 用于检验短期状态预测的作用; LAAVHA-A 为移除 Attention 动态权重分支的版本, 保留 LSTM 预测、改进 TOPSIS 和双重滞后逻辑, 但采用熵权法替代 Attention 输出权重, 用于检验动态权重学习的作用。两组消融变体与完整 LAAVHA 在相同的 50 组随机种子 (200~249) 和仿真参数下运行。图 4 以散点叠加柱状图的形式展示了三种方案的切换次数对比—每个散点代表一次独立运行的结果, 柱高为均值, 误差线为 ± 1 标准差。完整 LAAVHA 平均切换仅 0.24 次 (std=0.43), 50 次运行中 38 次保持零切换、12 次出现 1 次切换, 体现了 LSTM 预测与注意力动态权重协同工作的决策稳定性; LAAVHA-L (去 LSTM) 平均切换 1.08 次 (std=1.01), 失去时序预测后算法退化为被动反应式决策, 切换次数显著升高且方差增大; LAAVHA-A (去 Attention) 平均切换 2.00 次 (std=0.00), 全部 50 次运行均产生 2 次切换, 说明仅依靠熵权难以根据飞行阶段自适应调整评价标准, 在 WiFi 覆盖边缘必然触发乒乓。

图 4 LAAVHA 消融实验切换次数对比 (mean $\pm$ std, n=50)



上述消融结果表明，LSTM 预测模块和注意力动态权重模块对 LAAVHA 决策质量的贡献具有显著的协同效应—单独保留任一模块均无法维持低切换水平。Attention 模块的缺失影响最为严重（平均切换从 0.24 次增至 2.00 次，增幅达 8 倍，且 50 次运行无一例外），说明在遥感巡航场景下，基于飞行状态和候选网络状态生成的动态权重比静态统计权重更能区分不同飞行阶段的网络需求；LSTM 模块的缺失导致切换次数上升至 1.08 次且方差增大 ($\text{std}=1.01$)，说明时序预测能力对维持决策稳定性同样关键。两个模块的消融结果从正反两面共同验证了 LAAVHA 架构设计的合理性。

3.5 增强机制验证

为验证自适应滞后机制对信道波动的响应能力，构造网络 A（类比 5G）与网络 B（类比 WiFi）贴近度在 0.50 附近拉锯的竞争场景，初始状态设为接入网络 A。图 5 给出了同一时间轴下的四个子图，横坐标统一对应最下方的时间轴，因而图 5-a 到图 5-d 中 $t = 5 \sim 8 \text{ s}$ 和 $t = 12 \sim 15 \text{ s}$ 表示同一段仿真时间。浅蓝色区域 Zone 1 表示真实退化区间：网络 A 贴近度持续下降，网络 B 贴近度稳步上升，因此从 A 切换到 B 属于正确切换；浅红色区域 Zone 2 表示瞬时波动区间：网络 B 被注入正弦振荡和高斯噪声，虽然会出现短时峰值，但其均值并未形成稳定优势，因此不应触发切换。

图 5-a 展示两个网络的原始贴近度（Closeness）曲线，纵坐标表示未进行风险惩罚前的候选网络综合评分，数值越大表示该网络越接近理想候选网络。可以看到，Zone 1 中网络 B 的优势是连续形成的，而 Zone 2 中网络 B 只是高频振荡造成的瞬时抬升。图 5-b 展示固定低阈值方案 ($\Delta_{th} = 0.03$) 的切换结果，纵坐标仍为原始贴近度，红色虚线表示实际执行的切换时刻，图中已标明切换方向。该方案在 $t = 6.6 \text{ s}$ 执行 A $\rightarrow$ B、在 $t = 11.9 \text{ s}$ 执行 B $\rightarrow$ A，这两次分别对应 Zone 1 中的真实退化和退化结束后的恢复，属于正确切换；但在 Zone 2 内又于 $t = 14.8 \text{ s}$ 执行 A $\rightarrow$ B、 $t = 15.1 \text{ s}$ 执行 B $\rightarrow$ A，这两次仅由网络 B 的瞬时峰值触发，未对应真实链路质量改善，因而属于误切换和随后的乒乓切换。

图 5-c 展示 ALERA 增强机制下的 LCB 调整后评分，纵坐标为 $C_i^{\text{robust}} = C_i - \lambda \sigma_i^C$ ，即在原始贴近度基础

上扣除了历史波动风险罚分后的排序分数；绿色虚线表示增强机制实际执行的切换时刻。可以看到，ALERA 仍然保留了 Zone 1 中的 A→B 正确切换和退化结束后的 B→A 恢复切换，说明增强机制并未因为提高鲁棒性而阻塞必要切换；同时，Zone 2 内网络 B 的高频振荡被风险罚分压低，未触发任何切换。图 5-d 展示自适应阈值 Δ_{th} 随时间变化，纵坐标表示当前切换判决所需的最小贴近度优势。Zone 2 波动期间，阈值由基线 0.03 自动抬升至约 0.09，显著高于固定低阈值方案；波动消退后阈值逐步回落，说明 ADH 只在波动场景下提高切换门槛。

从网络切换正确性看，增强机制的优势体现在两个方面：一是面对真实退化时仍能完成必要切换，保证无人机从劣化网络 A 迁移到更优网络 B，避免因过度保守导致服务质量下降；二是面对瞬时波动时能够拒绝短时峰值诱导的误切换，避免 A→B→A 的乒乓过程。RS-TOPSIS 负责在“切向谁”的问题上压低高波动候选网络的排序优势，ADH 负责在“何时切换”的问题上提高波动阶段的触发门槛，两者共同使算法既保持正确切换能力，又减少错误切换和由此带来的链路重建开销。

图 5 自适应滞后机制验证：固定低阈值 ($\Delta_{th} = 0.03$) 与 ALERA 在真实退化和瞬时波动竞争场景下的对比



表 5 增强前后切换次数对比

方案	平均切换次数	标准差	最终接入网络
LAHVHA	0.24	0.43	5G (50/50)
ALERA	0.22	0.42	5G (50/50)

4 结束语

面向无人机遥感监测中广域飞行、异构覆盖和链路状态快速变化带来的垂直切换问题，本文提出了基于 LSTM-Attention 的 LAAVHA 自适应垂直切换方法，并在其决策层进一步构建增强型风险感知垂直切换算法 ALERA。LAAVHA 以 5G、LTE 和 WiFi 候选网络的 SINR、RSRP、时延、吞吐量和丢包率作为统一状态输入，将历史状态序列 X_k 输入堆叠 LSTM 得到短期预测状态 S_{pred} ，将当前状态矩阵 S_{cur} 和移动状态输入注意力模块得到动态权重 w ，再通过融合当前与预测状态的改进 TOPSIS 计算候选网络贴近度 C_i ，最后结合双重滞后机制输出切换决策。ALERA 在不改变 LSTM-Attention 模型结构和不重新训练参数的前提下，进一步引入自适应滞后（ADH）和风险敏感 TOPSIS（RS-TOPSIS）：前者根据当前服务网络近期 SINR 波动度和飞行速度动态调整切换阈值 Δ_{th} 与确认窗口 T ，后者基于贴近度历史波动对候选网络评分施加置信下界风险惩罚。由此，全文形成了“状态采集-时序预测-动态加权-融合排序-滞后裁定-风险增强”的连续决策链路，使每个模块的输出都成为后续模块的输入，同时兼顾了深度学习的前瞻建模能力和 TOPSIS 决策过程的可解释性。

基于 ns-3.45 与 ns3-ai 搭建的决策级协同仿真平台，本文在 50 组随机种子、每组 100 个决策周期的设置下，对 LAAVHA、8 种对比算法和 2 种消融变体进行了横向比较。实验结果表明，LAAVHA 平均切换次数为 0.24 次（std=0.43），明显低于 TOPSIS-Q 的 4.04 次、Fuzzy-VHO 的 8.64 次、SAW 的 2.00 次、VIKOR 的 13.52 次、GRA 的 19.24 次、COPRAS 的 25.88 次、SPOTIS 的 23.88 次和最强信号法的 1.58 次，说明时序预测、动态权重和双重滞后能够有效降低不必要切换。消融实验进一步表明，去除 LSTM 预测分支的 LAAVHA-L 平均切换次数上升至 1.08 次，去除 Attention 动态权重分支的 LAAVHA-A 上升至 2.00 次，验证了短期预测与动态属性权重之间的协同作用。增强机制实验显示，ALERA 平均切换次数为 0.22 次（std=0.42），在保持最终接入 5G 稳定性的同时，能够在真实退化区间保留必要切换，在瞬时波动区间抑制由短时峰值诱发的误切换和乒乓切换，体现了 ADH 与 RS-TOPSIS 在“何时切换”和“切向谁”两个层面的互补作用。需要指出的是，本文实验仍属于决策级验证，5G 链路和切换事件采用代理建模方式表示；后续工作将进一步结合更完整的协议栈切换过程和真实飞行轨迹数据，验证 LAAVHA/ALERA 在实网异构接入场景中的时延开销、链路重建代价和遥感数据传输完整性。

参考文献

- [1] YANG K, WANG Y, GAO X, et al. Communications in space-air-ground integrated networks: an overview[J]. Space: Science & Technology, 2025, 5: 0199.
- [2] MOZAFFARI M, SAAD W, BENNIS M, et al. A tutorial on UAVs for wireless networks: applications, challenges, and open problems[J]. IEEE Communications Surveys & Tutorials, 2019, 21(3): 2334-2360.
- [3] RIBEIRO L M B, MÜLLER I, BECKER L B. Communication interface manager for improving performance of heterogeneous UAV networks[J]. Sensors, 2021, 21(13): 4255.
- [4] AYASS T, COQUEIRO T, CARVALHO T, et al. Unmanned aerial vehicle with handover management fuzzy system for 5G networks: challenges and perspectives[J]. Intelligence & Robotics, 2022, 2(1): 20-36.

- [5] WANG Z, LV Z, XU X, et al. Vertical switching algorithm for unmanned aerial vehicle in power grid heterogeneous communication networks[J]. *Electronics*, 2024, 13(13): 2612.
- [6] ALAM S, SULISTYO S, MUSTIKA I W, et al. Handover decision for V2V communication in VANET based on moving average slope of RSS[J]. *Journal of Communications*, 2021, 16(7): 284-293.
- [7] GOUTAM S, UNNIKRISHNAN S, KARANDIKAR A. Algorithm for handover decision based on TOPSIS[C]//2020 International Conference on UK-China Emerging Technologies. Piscataway: IEEE Press, 2020: 1-4.
- [8] XIAO K Y, LI C G. Vertical handoff decision algorithm for heterogeneous wireless networks based on entropy and improved TOPSIS[C]//2018 IEEE 18th International Conference on Communication Technology. Piscataway: IEEE Press, 2018: 706-710.
- [9] AHMED I I O, IPAYE A A, MITROPOULOS D N G, et al. Vertical handover E-TOPSIS algorithm mathematical model using AHP and standard deviation weighing method[C]//2019 International Conference on Computer, Control, Electrical, and Electronics Engineering. Piscataway: IEEE Press, 2019: 1-5.
- [10] SATAPATHY P, MAHAPATRO J. An efficient multicriteria-based vertical handover decision-making algorithm for heterogeneous networks[J]. *Transactions on Emerging Telecommunications Technologies*, 2022, 33(4): e4409.
- [11] DANTAS SILVA F S, LIMA M P S, CORUJO D, et al. A comprehensive step-wise survey of multiple attribute decision-making mobility approaches[J]. *IEEE Access*, 2024, 12: 108616-108656.
- [12] TAN K, BREMNER D, LE KERNEC J, et al. Intelligent handover algorithm for vehicle-to-network communications with double-deep Q-learning[J]. *IEEE Transactions on Vehicular Technology*, 2022, 71(7): 7848-7862.
- [13] JANG Y, RAZA S M, KIM M, et al. Proactive handover decision for UAVs with deep reinforcement learning[J]. *Sensors*, 2022, 22(3): 1200.
- [14] ZAID M, KADIR M K A, SHAYEA I, et al. Machine learning-based approaches for handover decision of cellular-connected drones in future networks: a comprehensive review[J]. *Engineering Science and Technology, an International Journal*, 2024, 55: 101732.
- [15] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. *Neural Computation*, 1997, 9(8): 1735-1780.
- [16] KAUR G, GOYAL R K, MEHTA R. An efficient handover mechanism for 5G networks using hybridization of LSTM and SVM[J]. *Multimedia Tools and Applications*, 2022, 81(26): 37057-37085.
- [17] MOLLEL M S, ABUBAKAR A I, OZTURK M, et al. A survey of machine learning applications to handover management in 5G and beyond[J]. *IEEE Access*, 2021, 9: 45770-45802.

- [18] SOYDANER D. Attention mechanism in neural networks: where it comes and where it goes[J]. *Neural Computing and Applications*, 2022, 34(16): 13371-13385.
- [19] MANZOOR S, MANZOOR M, MANZOOR H, et al. Which simulator to choose for next generation wireless network simulations? ns-3 or OMNeT++[J]. *Engineering Proceedings*, 2023, 46(1): 36.
- [20] YIN H, LIU P, LIU K, et al. ns3-ai: fostering artificial intelligence algorithms for networking research[C]//*Proceedings of the 2020 Workshop on ns-3*. New York: ACM, 2020: 57-64.
- [21] AL- HOURANI A, KANDEEPAN S, LARDNER S. Optimal LAP altitude for maximum coverage[J]. *IEEE Wireless Communications Letters*, 2014, 3(6): 569-572.
- [22] ZOLFANI S, YAZDANI M, PAMUCAR D, et al. A VIKOR and TOPSIS focused reanalysis of the MADM methods based on logarithmic normalization[J]. *Facta Universitatis, Series: Mechanical Engineering*, 2020, 18(3): 341-355.
- [23] 赵雪圻, 崔玉波. 乒乓切换问题的区域用户预测研究 [J]. *山东通信技术*, 2022, 42(4): 40-42.
ZHAO X Q, CUI Y B. Research on regional user prediction for ping-pong handover problem[J]. *Shandong Communication Technology*, 2022, 42(4): 40-42.
- [24] YU H, MA Y, YU J. Network selection algorithm for multiservice multimode terminals in heterogeneous wireless networks[J]. *IEEE Access*, 2019, 7: 46240-46260.
- [25] TAN X, CHEN G, SUN H. Vertical handover algorithm based on multi-attribute and neural network in heterogeneous integrated network[J]. *EURASIP Journal on Wireless Communications and Networking*, 2020, 2020(1): 202.
- [26] PANAITOPOL D, JIN Y, TANG R, et al. Requirements on satellite access node and user equipment for non-terrestrial networks in 5G new radio of 3GPP Release-17[J]. *International Journal of Satellite Communications and Networking*, 2023, 41(3): 289-301.
- [27] PATRICIELLO N, LAGEN S, BOJOVIC B, et al. An E2E simulator for 5G NR networks[J]. *Simulation Modelling Practice and Theory*, 2019, 96: 101933.
- [28] RAPPAPORT T S. *Wireless communications: principles and practice*[M]. 2nd ed. Upper Saddle River: Prentice Hall, 2002.
- [29] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//*Advances in Neural Information Processing Systems 30*. Red Hook: Curran Associates, 2017: 5998-6008.
- [30] HWANG C L, YOON K. *Multiple attribute decision making: methods and applications*[M]. Berlin: Springer-Verlag, 1981.

作者简介

苏文（2006- ），男，成都理工大学本科生，主要研究方向：无人异构网络、智能垂直切换、网络仿真等。