

面向无人机遥感异构网络的注意力 LSTM 增强型风险感知垂直切换算法

孙汉明^[1], 刘同^[1], 苏文^[1], 林杰^[1], 罗俊松^[1], 多滨^[1]

(1. 成都理工大学, 四川省成都市 610000)

摘 要: 无人机遥感监测系统在灾害评估、环境监测等大范围对地观测场景中广泛应用。无人机巡航时需持续穿越 5G、LTE 和 WiFi 三种异构网络的覆盖边界, 构成典型的候选网络垂直切换场景, 面临决策滞后、乒乓切换频繁以及固定属性权重难以适应动态飞行阶段的挑战。该研究提出了一种基于长短期记忆网络与注意力机制的自适应垂直切换方法 (Long Short-Term Memory-Attention based Adaptive Vertical Handover Algorithm, LAAVHA), 并在其基础上引入自适应滞后 (Adaptive Dynamic Hysteresis, ADH) 与风险敏感 TOPSIS (Risk-Sensitive TOPSIS, RS-TOPSIS) 两项增强机制, 形成增强型风险感知垂直切换算法 (Attention-LSTM Enhanced Risk-aware Vertical Handoff Algorithm, ALERA)。LAAVHA 由预测、动态加权、候选排序和切换判决构成的基础决策链包括: 堆叠 LSTM 预测候选网络短期状态, 注意力机制结合当前网络状态与移动特征生成动态属性权重, 当前状态与预测状态经改进的逼近理想解排序法 (Technique for Order Preference by Similarity to Ideal Solution, TOPSIS) 融合排序, 随后以贴强度评分优势阈值和连续确认窗口实施双重滞后判决, 抑制不必要切换。在此基础上, ADH 依据飞行速度和服务网络信道波动自适应调节切换阈值与确认窗口, RS-TOPSIS 依据候选网络近期贴强度评分的波动程度施加风险罚分, 并以鲁棒评分完成候选排序。两项增强机制在基础评分生成后、最终切换判决前提高了算法对信道波动的适应性和决策鲁棒性。大量仿真实验表明, 所提算法可减少无效切换、提高切换决策效率并保障遥感数据回传连续性, 在信道突变条件下具有更强的抗扰能力。

关键词: 无人机遥感; 异构网络; 垂直切换; LSTM; 注意力机制; 自适应滞后; 风险敏感 TOPSIS

Attention-LSTM Enhanced Risk-aware Vertical Handoff Algorithm for UAV Remote Sensing Heterogeneous Networks

SUN Hanming^[1], LIU Tong^[1], SU Wen^[1], LIN Jie^[1], LUO Junsong^[1], DUO Bin^[1]

1. Chengdu University of Technology, Chengdu 610000, China

Abstract: Unmanned aerial vehicle (UAV) remote sensing systems are widely used in large-area earth observation scenarios such as disaster assessment and environmental monitoring. During cruise missions, UAVs continuously traverse the coverage boundaries of three heterogeneous networks—5G, LTE, and WiFi—forming a typical

candidate-network vertical handover scenario that faces decision delay, frequent ping-pong handovers, and the inability of fixed attribute weights to adapt to dynamic flight phases. This study proposes an adaptive vertical handover method based on long short-term memory and an attention mechanism (Long Short-Term Memory-Attention based Adaptive Vertical Handover Algorithm, LAAVHA). On this basis, two enhancement mechanisms, adaptive dynamic hysteresis (Adaptive Dynamic Hysteresis, ADH) and risk-sensitive TOPSIS (Risk-Sensitive TOPSIS, RS-TOPSIS), are introduced to form an enhanced risk-aware vertical handoff algorithm (Attention-LSTM Enhanced Risk-aware Vertical Handoff Algorithm, ALERA). LAAVHA comprises a basic decision chain of prediction, dynamic weighting, candidate ranking, and handover decision. A stacked LSTM predicts short-term candidate-network states; an attention mechanism combines current network states with mobility features to generate dynamic attribute weights; and current and predicted states are fused and ranked using an improved Technique for Order Preference by Similarity to Ideal Solution (TOPSIS). A dual hysteresis decision based on a closeness-score advantage threshold and a consecutive-confirmation window then suppresses unnecessary handovers. On this basis, ADH adapts the handover threshold and confirmation window according to flight speed and serving-network channel fluctuations, whereas RS-TOPSIS applies a risk penalty according to recent fluctuations in candidate-network closeness scores and ranks candidates using robust scores. The two enhancement mechanisms leave the LSTM and attention-network structures and training processes unchanged, and improve adaptation to channel fluctuations and decision robustness after base scores are generated and before the final handover decision. Extensive simulations show that the proposed algorithm reduces unnecessary handovers, improves handover-decision efficiency, maintains the continuity of remote sensing data transmission, and provides stronger resistance to abrupt channel changes.

Key words: UAV remote sensing, heterogeneous network, vertical handover, LSTM, attention mechanism, adaptive hysteresis, risk-sensitive TOPSIS

0 引言

无人机遥感系统在灾害评估、农业普查、环境监测等领域广泛应用, 无人机搭载的高分辨率光学/多光谱载荷在巡航过程中产生大量遥感图像数据, 需通过 5G、LTE 和 WiFi 等异构无线网络实时回传至地面站^[1-3]。然而, 无人机的高机动性导致其频繁穿越不同网络的覆盖边界, 触发垂直切换^[4]。传统垂直切换研究主要围绕多属性决策方法 (Multiple Attribute Decision Making, MADM) 展开, 如 TOPSIS^[6-7]、VIKOR^[20]、GRA^[20]、COPRAS^[20]、SPOTIS^[20]、Fuzzy-VHO^[4]和 SAW 等^[5], 通过构建信噪比、时延、吞吐量等网络属性的评价矩阵进行候选排序。这些方法存在两个共性问题: 一是权重通常由熵权法或层次分析法一次性确定^[8-9], 无法随飞行阶段和信道环境动态调整; 二是仅依据当前时刻的网络指标做决策, 缺乏对未来状态变化的前瞻性判断, 例如, 当无人机高速飞向 WiFi 覆盖边缘时, 可能在链路实际中断后才触发切换^[10-11]。此外, 近年深度强化学习 (DRL) 方法被引入切换决策^[10-12], 但其黑箱性质和训练不稳定性在安全攸关的遥感巡航场景中带来可解释性和可靠性方面的顾虑。

长短期记忆网络 (LSTM) 通过门控结构有效缓解梯度消失问题^[13], 具有捕获长时间序列依赖关系的能力, 已被应用于 5G 异构网络的切换判决和网络状态预测^[14-15]。然而, 单一 LSTM 网络存在两方面局限:

其一，LSTM 将候选网络的 5 维状态指标视为独立的时间序列分别建模，无法显式捕获指标之间的耦合关系，例如吞吐量与丢包率的负相关性、SINR 与时延的关联性等；其二，LSTM 输出的预测状态仍需配合固定或人工设定的属性权重才能完成多属性决策，无法根据飞行阶段和移动状态自适应调整各指标的重要性。

综上所述，当前无人机遥感异构网络中的垂直切换面临两个层面的挑战：在算法层面，传统多属性决策方法权重固定、缺乏时序预测能力，单一 LSTM 即使引入预测机制仍无法自适应调节属性权重以适应飞行阶段变化；在场景层面，平稳飞行时信号波动小，而跨越覆盖边界或遭遇遮挡时信号会剧烈振荡，固定的切换阈值和确认窗口难以同时适应两类环境。两个层面的问题相互关联：算法适应性的不足加剧了场景波动带来的切换不稳定，而场景的动态变化又要求算法具备更强的环境感知能力。

针对上述两个层面相互关联的挑战，本文提出分层次的解决方案。在算法层面，构建基于长短期记忆神经网络和注意力机制的自适应垂直切换算法（LAAVHA），以引入注意力机制弥补传统 MADM 方法在动态权重与时序预测方面的不足。LAAVHA 采用预测、权重与决策三阶段架构：堆叠 LSTM 预测候选网络短期状态变化；注意力机制以当前网络状态矩阵为自注意力输入，融合飞行速度与高度等移动特征，输出随飞行阶段自适应变化的动态属性权重；融合当前与预测状态构建改进 TOPSIS 决策矩阵，并以 TOPSIS 贴近度评分优势阈值和连续确认窗口组成的双重滞后机制完成候选排序与切换裁定。LAAVHA 通过动态权重与前瞻预测，克服了传统 MADM 方法权重固定和被动响应的问题，实现了无人机遥感巡航场景下的稳定候选网络评价。在场景层面，无人机遥感探测任务具有广域巡航、高速跨越 5G/LTE/WiFi 覆盖边界以及跨越边界或遭遇遮挡时信道突变等特点；同时，高分辨率遥感图像需要在飞行过程中持续、可靠地回传。为满足这一场景需求，在 LAAVHA 决策框架之上进一步引入自适应滞后（Adaptive Dynamic Hysteresis, ADH）与风险敏感 TOPSIS（Risk-Sensitive TOPSIS, RS-TOPSIS）两项增强机制，形成注意力 LSTM 增强型风险感知垂直切换算法（ALERA）。

ADH 针对固定阈值和固定确认窗口难以兼顾稳定性与时效性的问题，依据当前服务网络近 5 个决策周期的 SINR 标准差刻画信道波动，并结合飞行速度动态更新切换条件。信道波动增大时，ADH 提高评分优势阈值以过滤短时扰动；飞行速度增大时，ADH 缩短连续确认窗口，使无人机能够在覆盖边界快速变化时及时完成必要切换。由此，ADH 在信道平稳时保持较低的切换门槛，在信道剧烈波动时提高防抖能力。

RS-TOPSIS 针对候选网络当前评分偏高但近期表现不稳定的问题，维护候选网络近 5 轮 TOPSIS 贴近度历史，计算各候选网络评分的标准差，并从当前贴近度中扣除与波动程度成正比的风险罚分。经惩罚后的鲁棒评分同时反映候选网络的即时性能和历史稳定性，使均值略高但波动剧烈的网络不再因短时峰值获得优先级，从而降低高波动信道诱发的误切换风险。

仿真结果表明，LAAVHA 的平均切换次数为 0.24 次，在 11 种算法中最低，较 8 种对比算法降低 84.8% ~ 99.1%，50 次运行中有 38 次实现零切换。去除 LSTM 预测分支或注意力动态权重分支后，该值分别增至 1.08 次和 2.00 次，表明两模块的协同作用是切换稳定性的主要来源。ALERA 在持续性链路劣化区间完成全部必要切换，在瞬时波动区间保持零误切换，而固定低阈值方案额外触发两次乒乓切换，表明 ADH 与 RS-TOPSIS 能够在保证必要切换的同时增强波动环境下的抗扰能力。

1 网络场景与网络状态参数

考虑无人机遥感巡航场景，无人机在 $2000\text{ m} \times 2000\text{ m}$ 的任务区域内沿预定航线飞行，飞行高度为 $50 \sim 150\text{ m}$ ，巡航速度为 $5 \sim 30\text{ m/s}$ 。任务区域内存在 WiFi、LTE 和 5G 三种候选接入网络，其覆盖范围与部署密度各不相同：WiFi 热点覆盖半径约 200 m ，部署于地面站和关键拍摄点周边；LTE 基站覆盖半径约 $1 \sim 2\text{ km}$ ，沿航线稀疏分布；5G 基站覆盖半径约 500 m ，部署于任务区域东侧的遥感数据汇聚位置，提供高速率接入但覆盖尚不连续。无人机在飞行过程中周期性采集各候选网络的状态信息，用于切换决策^[19]。




图 1 无人机遥感任务区域中的异构网络覆盖与移动轨迹示意

如图 1 所示，任务区域内三类网络形成尺度不同且相互重叠的覆盖空间：WiFi 热点覆盖范围较小，主要服务地面站和关键拍摄点附近的数据接入；LTE 基站覆盖范围较广，为无人机广域巡航提供连续性较强的基础连接；5G 基站部署于任务区域东侧的数据汇聚位置，在有限覆盖范围内提供高速率传输。图中的 5G gNB (next generation NodeB) 表示 5G 无线接入基站，负责为无人机提供 5G 信号覆盖、无线资源调度和高速数据传输服务。无人机沿预定轨迹飞行时依次进入、离开并穿越不同网络的重叠覆盖区域，当当前服务网络质量下降而其他候选网络的综合性能上升时，需要执行垂直切换。图中各覆盖圆的相对尺度与前述覆盖半径设置一致，为后续网络状态采集和候选网络评价提供场景基础。

对于第 i 个候选网络，其在时刻 t 的状态向量定义为

$$S_i(t) = [\text{SINR}_i(t), \text{RSRP}_i(t), D_i(t), T_i(t), \text{PLR}_i(t)]. \quad (1)$$


在遥感飞行场景中，上述五个指标从不同维度刻画了候选网络服务遥感任务的能力：当无人机从 WiFi 热点上空飞向任务区域边缘时，信噪比 $\text{SINR}_i(t)$ 从数十 dB 单调下降至接近噪声底限，直接反映了信号质量随距离和遮挡的衰减过程，是判断是否触发切换的最直观依据；参考信号接收功率 $\text{RSRP}_i(t)$ 与 $\text{SINR}_i(t)$ 共同决定链路预算是否满足解调门限；若 $\text{RSRP}_i(t)$ 低于接收灵敏度，即使 $\text{SINR}_i(t)$ 尚可，物理层也无法建立可靠连接；端到端时延 $D_i(t)$ 定义为数据包从地面站到达无人机应用层的往返时间，在高速巡航阶段直接决定飞控指令的响应速度与飞行安全冗余度；吞吐量 $T_i(t)$ 衡量候选网络单位时间内可交付的有效载荷比特数，对单张可达数 MB 的高分辨率遥感图像而言， $T_i(t)$ 不足将导致单次过顶时间内无法完成图像下传；丢包率 $\text{PLR}_i(t)$ 反映网络传输的可靠性，即使在信号较强、吞吐量充裕的位置，较高的 $\text{PLR}_i(t)$ 也会使接收端重建的遥感图像出现条带缺失或块状模糊。上述指标中， $\text{SINR}_i(t)$ 、 $\text{RSRP}_i(t)$ 和 $T_i(t)$ 属于效益型指标（数值越大越优）， $D_i(t)$ 和 $\text{PLR}_i(t)$ 属于成本型指标（数值越小越优）。为消除各指标量纲差异，采用 min-max 归一化方法将所有指标映射至 $[0, 1]$ 区间，并使归一化后的值越大表示候选网络在该维度上越优^[20]。

因此，式(1)不是单独用于描述网络状态的静态定义，而是后续算法链路的统一输入接口。对同一时刻 3 个候选网络的 $S_i(t)$ 按网络维度堆叠，可得到当前状态矩阵 $S_{\text{cur}} \in \mathbf{R}^{3 \times 5}$ ，该矩阵直接输入第 2.2 节的注意力权重生成模块；对单个候选网络连续 10 个决策周期的状态向量按时间维度堆叠，可得到历史状态张量 $X_k \in \mathbf{R}^{10 \times 5}$ ，该张量输入第 2.1 节的堆叠 LSTM 预测模块。也就是说，第 1 章给出的网络状态参数同时承担两类作用：横向上刻画同一时刻不同候选网络的优劣差异，纵向上刻画同一网络随无人机运动产生的短期演化趋势。


无人节点移动会引起候选网络信号质量和传输性能持续变化。在遥感巡航场景中，若仅依据当前时刻指标进行切换决策，无人机可能在高速接近 WiFi 覆盖边缘时未能提前切换，导致正在回传的图像数据因链路突然中断而丢失^[21]。因此，算法将过去若干个决策周期的网络状态组织为时序输入，用于预测短期未来状态，并将预测结果与当前状态共同用于最终决策。

2 LAHVHA 自适应垂直切换算法

基于第 1 章定义的网络场景与网络状态参数，本章提出基于长短期记忆神经网络和注意力机制的自适应垂直切换算法（LAHVHA），旨在解决传统 MADM 方法在无人机遥感巡航场景中权重固定和缺乏时序预测能力的不足。LAHVHA 以第 1 章所述的 5 维网络状态向量和滑动窗口机制为输入，依次通过堆叠 LSTM 预测、注意力动态权重生成和融合预测状态的改进 TOPSIS 决策三个模块完成候选网络评估与切换判决，最后引入自适应滞后（ADH）与风险敏感 TOPSIS（RS-TOPSIS）两项增强机制形成 ALERA。



(a) LAAVHA 算法框架



(b) ALERA 算法框架

图 2 LAAVHA 与 ALERA 算法框架

如图 2 所示, 该图展示了 LAAVHA 从网络状态预测、动态权重生成、候选网络排序到双重滞后判决的基础算法框架, 以及 ADH 与 RS-TOPSIS 两项机制对基础决策链的增强过程。图中的各模块并非并列孤立运行, 而是围绕同一组网络状态形成端到端变量流: 由第 1 章采集并归一化后的历史序列 X_k 首先进入堆叠 LSTM, 得到下一时刻预测状态 S_{pred} ; 同一决策周期的当前状态矩阵 S_{cur} 进入注意力模块, 与速度、高度等移动特征共同生成动态权重 w ; 随后 S_{cur} 、 S_{pred} 和 w 在改进 TOPSIS 模块中汇合, 输出候选网络贴进度 C_i ; 最后, C_i 与当前接入网络 N_{cur} 共同进入滞后判决和 ALERA 增强机制, 形成最终切换决策。按照这一链路, 2.1 节解决“未来状态是什么”, 2.2 节解决“当前任务更重视哪些指标”, 2.3 节解决“综合当前与未来后哪个网络更优”, 2.4 节进一步解决“在波动环境下是否应该执行这次切换”。

图中预测分支的 θ_1 、 θ_2 表示两层 LSTM 参数, W_{pred} 和 b_{pred} 表示预测头的权重与偏置。注意力分支中, Q 、 K 、 V 为查询、键和值, A 为注意力输出, c 为均值池化后的上下文向量, v 和 h 分别为飞行速度与高度, W_{mob} 将二者映射为移动特征 m , W_{weight} 再将 c 与 m 的拼接结果投影为动态权重 w 。TOPSIS 分支中, D 为融合决策矩阵, α 为融合系数, d_{ij} 、 r_{ij} 和 v_{ij} 分别表示融合、归一化和加权后的矩阵元素, v_j^+ 与 v_j^- 为正、负理想解, D_i^+ 与 D_i^- 为候选网络 i 到两类理想解的欧氏距离, C_i 为贴近度, N^* 为排序得到的目标网络, Δ_{th} 和 T_h 分别为切换阈值与连续确认窗口。增强分支中, K_c 为贴近度历史长度, σ_i^C 为候选网络 i 的评分标准差, λ 为风险系数, C_i^{robust} 为风险罚分后的鲁棒评分, σ 为当前服务网络近 5 个周期的 SINR 标准差。

2.1 基于堆叠 LSTM 的网络状态预测

设时间窗口长度 $T_s = 10$ (即覆盖 1.0 s 内的 10 个连续决策周期, 决策周期 $\tau = 0.1$ s), 候选网络 $k \in \{1, 2, 3\}$ (分别对应 5G、LTE、WiFi) 的历史输入张量为 $X_k \in \mathbf{R}^{10 \times 5}$, 其中 10 个连续决策周期的 5 维归一化状态向量按行堆叠。预测目标是下一时刻的状态向量 $\hat{s}_k(t + \tau) \in \mathbf{R}^5$ 。

$$h_{1,k} = \text{LSTM}_1(X_k; \theta_1), \quad h_{1,k} \in \mathbf{R}^{10 \times 128}, \quad (2)$$

$$h_{2,k} = \text{LSTM}_2(h_{1,k}; \theta_2), \quad h_{2,k} \in \mathbf{R}^{10 \times 64}, \quad (3)$$

$$\hat{s}_k(t + \tau) = W_{\text{pred}} h_{2,k}[-1] + b_{\text{pred}}, \quad \hat{s}_k \in \mathbf{R}^5. \quad (4)$$

式中 θ_1 、 θ_2 分别为两层 LSTM 的可训练参数 (含输入门、遗忘门、输出门及细胞状态的权重与偏置), $W_{\text{pred}} \in \mathbf{R}^{5 \times 64}$ 与 $b_{\text{pred}} \in \mathbf{R}^5$ 为预测头的全连接权重与偏置, $h_{2,k}[-1]$ 表示取 LSTM₂ 最后时刻的输出向量。式(2)至式(4)完整刻画了预测分支的维度变换: 10 步 $\times$ 5 维指标 $\rightarrow$ LSTM₁ (5 $\rightarrow$ 128) $\rightarrow$ LSTM₂ (128 $\rightarrow$ 64) $\rightarrow$ fc_pred (64 $\rightarrow$ 5)。三个候选网络共享同一组 LSTM 参数 (即对 5G、LTE、WiFi 使用相同的 θ_1 、 θ_2 、 W_{pred} 、 b_{pred}), 各自独立输入历史序列 X_k , 预测结果堆叠为 $S_{\text{pred}} \in \mathbf{R}^{3 \times 5}$, 即三个网络各自下一时刻的五项指标预测值。

需要强调的是, S_{pred} 并不是直接决定切换目标的最终评分, 而是把历史序列 X_k 压缩为下一决策周期可比较的预测状态。其作用是在第 2.3 节式(11)中与当前状态 S_{cur} 共同构成融合决策矩阵, 使 TOPSIS 排序同时具有当前实测依据和短期前瞻信息。若没有这一输出, 后续决策只能退化为对 S_{cur} 的被动排序, 这正是消融变体 LAAVHA-L 用于检验的部分。

2.2 面向飞行阶段的动态权重生成

在垂直切换决策中, 不同网络属性的重要性会随场景变化而变化。例如, 无人机处于巡航飞行阶段时, 链路稳定性和控制指令时延对飞行安全更加关键; 当抵达拍摄点进入图像回传阶段时, 吞吐量和丢包率的权重应显著提升, 以确保高分辨率遥感图像在有限时间窗口内完整送达地面站^[22]。固定权重难以刻画这种动态变化。

为解决固定权重无法匹配遥感飞行中不同阶段需求差异的问题, LAAVHA 引入自注意力机制 (Self-Attention) ^[16,24]。将当前 3 个候选网络的 5 维状态向量按行堆叠为矩阵 $S_{\text{cur}} \in \mathbf{R}^{3 \times 5}$, 令自注意力的查询 (Query)、键 (Key)、值 (Value) 均等于 S_{cur} (即 $Q = K = V = S_{\text{cur}}$, embed_dim=5, num_heads=1)。其中, embed_dim 表示注意力模块中每个输入向量的特征维度; 本文每个候选网络由 SINR、RSRP、时延、吞吐

量和丢包率 5 个归一化指标描述, 因此 embed_dim 取 5, 与 S_{cur} 的列数一致。 num_heads 表示并行注意力头的数量; 由于本文属性维度仅为 5, 若采用多头注意力会使每个头分到的特征维度过小, 不利于解释各指标权重, 因此采用单头注意力 ($\text{num_heads}=1$) 直接学习 5 个属性之间的相关性。 随后通过缩放点积注意力计算属性间的交互权重, 其中注意力矩阵 A 的每个元素 a_{ij} 表示属性 j 对属性 i 的重要性。 再经跨网络均值池化提取属性级上下文 $c \in \mathbf{R}^5$, 并联合飞行速度 v 与高度 h 经 $W_{\text{mob}} \in \mathbf{R}^{16 \times 2}$ 映射为移动特征 $m \in \mathbf{R}^{16}$, 拼接后经全连接层投影与 softmax 归一化输出 5 维动态权重 w :

$$Q = K = V = S_{\text{cur}} \in \mathbf{R}^{3 \times 5}, \quad (5)$$

$$A = \text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{5}}\right) V, \quad A \in \mathbf{R}^{3 \times 5}, \quad (6)$$

$$c = \text{mean}(A, \text{dim} = 0) \in \mathbf{R}^5, \quad (7)$$

$$m = \text{ReLU}(W_{\text{mob}}[v, h]^\top), \quad W_{\text{mob}}: \mathbf{R}^2 \rightarrow \mathbf{R}^{16}, \quad m \in \mathbf{R}^{16}, \quad (8)$$

$$w = \text{softmax}(W_{\text{weight}}[c \parallel m]), \quad W_{\text{weight}}: \mathbf{R}^{21} \rightarrow \mathbf{R}^5, \quad w \in \mathbf{R}^5, \quad \sum_j w_j = 1. \quad (9)$$

式(5)至式(9)描述了动态权重的完整生成过程: 以当前时刻网络状态 $S_{\text{cur}} \in \mathbf{R}^{3 \times 5}$ 为自注意力输入, 缩放点积注意力获得 3×5 注意力矩阵 A ; 跨网络均值池化得到 5 维属性级上下文 c ; $W_{\text{mob}}: 2 \rightarrow 16$ 将速度和高度映射为 16 维移动特征 m 引入飞行状态; 最后拼接为 21 维经 W_{weight} 投影和 softmax 归一化输出 5 维动态权重 w 。

因此, 注意力模块的输出 w 也不是单独评价网络优劣的结果, 而是第 2.3 节 TOPSIS 加权步骤的输入。 具体而言, 式(14)中的 $v_{ij} = w_j r_{ij}$ 将 w_j 作用到融合矩阵 D 的第 j 个属性维度, 使 SINR、RSRP、时延、吞吐量和丢包率的相对重要性能随当前网络状态和飞行状态变化。 这样, LSTM 分支提供“预测到哪里去”, Attention 分支提供“当前该重视什么”, 二者在 TOPSIS 排序阶段共同影响最终贴近期 C_i 。

2.3 融合预测状态的改进 TOPSIS 决策

本节是前述两个学习模块的汇合点。 第 2.1 节输出的 S_{pred} 提供短期未来状态, 第 2.2 节输出的 w 提供当前飞行阶段下的属性重要性, 第 1 章定义并实时采集的 S_{cur} 提供当前观测状态。 在遥感巡航场景中, 候选网络的优劣需要综合权衡信号强度、传输能力与可靠性三个维度, 不存在单一指标最优的“完美网络”。 TOPSIS 的基本思想是将各候选网络在多维属性空间中的位置与虚拟的“最优网络”和“最劣网络”进行比较^[6-7]。 为避免传统 TOPSIS 仅依赖当前状态导致的被动决策, LAHVHA 首先将当前状态与 LSTM 预测状态进行融合, 构建决策矩阵:

$$s_{\text{norm}} = \frac{s - s_{\min}}{s_{\max} - s_{\min}}, \quad \text{for each indicator } j, \quad (10)$$

$$d_{ij} = \alpha s_{\text{cur}}(i, j) + (1 - \alpha) s_{\text{pred}}(i, j), \quad \alpha = 0.6, \quad (11)$$

$$d_{ij} \leftarrow 1 - d_{ij}, \quad j \in \{\text{delay}, \text{PLR}\}. \quad (12)$$

式(10)至式(12)中, i 表示候选网络编号, $i = 1, 2, 3$ 分别对应 5G、LTE 和 WiFi; j 表示属性指标编号, 本文共有 5 个属性, 即 SINR、RSRP、时延、吞吐量和丢包率。 s 表示某一候选网络在第 j 个属性上的原始或待归一化指标值, $s_{\min}$ 和 $s_{\max}$ 分别表示当前决策周期内该属性在全部候选网络中的最小值和最大值, s_{norm} 为映

射到 $[0, 1]$ 区间后的归一化值。 $s_{\text{cur}}(i, j)$ 表示候选网络 i 在当前时刻第 j 个属性上的归一化状态值, $s_{\text{pred}}(i, j)$ 表示 LSTM 预测得到的下一时刻对应属性值, d_{ij} 表示二者融合后写入决策矩阵 D 的元素。 α 为当前状态与预测状态的融合系数, 本文取 $\alpha = 0.6$, 该取值使当前实测状态占主导, 同时保留预测信息的前瞻引导作用 (此参数取值依据会在后续实验进行说明)。由于时延和丢包率属于成本型指标, 数值越小越优, 因此式(12)对其归一化值执行取反, 使所有属性在进入 TOPSIS 前统一为“数值越大越优”。将成本型指标取反后得到融合决策矩阵 $D \in \mathbf{R}^{3 \times 5}$, 进入标准化 TOPSIS 流程:

$$r_{ij} = \frac{d_{ij}}{\sqrt{\sum_{k=1}^3 d_{kj}^2}}, \quad (13)$$

$$v_{ij} = w_j r_{ij}, \quad (14)$$

$$v_j^+ = \max_i v_{ij}, \quad v_j^- = \min_i v_{ij}, \quad (15)$$

$$D_i^+ = \sqrt{\sum_{j=1}^5 (v_{ij} - v_j^+)^2}, \quad D_i^- = \sqrt{\sum_{j=1}^5 (v_{ij} - v_j^-)^2}, \quad (16)$$

$$C_i = \frac{D_i^-}{D_i^+ + D_i^-}, \quad C_i \in [0, 1]. \quad (17)$$

式(13)至式(17)中, r_{ij} 表示融合决策矩阵 D 经向量归一化后的元素, 分母 $\sqrt{\sum_{k=1}^3 d_{kj}^2}$ 为第 j 个属性在 3 个候选网络上的欧氏范数; 此处 k 仅为求和索引, 表示候选网络编号, 不再表示第 2.1 节中的历史输入序列编号。 w_j 为第 2.2 节 Attention 模块输出的第 j 个属性动态权重, v_{ij} 为归一化元素 r_{ij} 经权重 w_j 加权后的结果。 v_j^+ 和 v_j^- 分别表示第 j 个属性上的正理想解和负理想解, 即所有候选网络加权归一化值中的最大值和最小值。 D_i^+ 表示候选网络 i 到正理想解的欧氏距离, D_i^- 表示其到负理想解的欧氏距离; C_i 为候选网络 i 的相对贴近度, 取值范围为 $[0, 1]$ 。因此, 式(13)至式(17)将 3×5 的融合决策矩阵 D 转换为三个候选网络的相对贴近度排序: 向量归一化消除指标量纲 $\rightarrow$ 动态权重加权 $\rightarrow$ 确定正/负理想解 $\rightarrow$ 欧氏距离计算 $\rightarrow$ 输出 $C_i \in [0, 1]$ 。 C_i 越接近 1, 表示该网络对遥感任务中图像回传、飞控响应和链路可靠性三者的综合保障能力越强。

$$N^* = \arg \max_i C_i, \quad (18)$$

$$\text{Decision} = \begin{cases} \text{switch to } N^*, & C(N^*) - C(N_{\text{cur}}) > \Delta_{\text{th}} \text{ and lasts } T_h \text{ consecutive cycles,} \\ \text{keep } N_{\text{cur}}, & \text{otherwise,} \end{cases} \quad (19)$$

式(18)至式(19)中, N^* 表示当前决策周期内贴近度 C_i 最大的候选网络, N_{cur} 表示无人机当前正在接入的服务网络, $C(N^*)$ 和 $C(N_{\text{cur}})$ 分别表示目标候选网络和当前服务网络的 TOPSIS 贴近度。 Δ_{th} 为切换触发阈值, 用于要求目标网络相对当前网络具有足够明显的评分优势; T_h 为连续确认窗口, 用于要求该优势连续保持若干个决策周期。本文设置 $\Delta_{\text{th}} = 0.05$, $T_h = 3$ (此参数取值依据会在后续实验进行说明)。为降低网络状态瞬时波动引发的乒乓切换, 算法设置双重滞后机制。仅当得分最高的候选网络 N^* 的贴近度超过当前服务网络 N_{cur} 达 $\Delta_{\text{th}} = 0.05$ 以上, 且该条件在连续 $T_h = 3$ 个决策周期内持续满足时, 才正式执行切换。算法 1 将上述预测、权重生成、TOPSIS 排序和滞后裁定串联为一次完整的 LAHVHA 决策流程。

算法 1 LAAVHA 垂直切换决策流程

Require: 历史状态 $\{X_k\}_{k=1}^3$, 当前状态 S_{cur} , 移动状态 $[v, h]$, 当前服务网络 N_{cur} , 上周期确认候选 N_{cand} 及其连续计数 q

Ensure: 切换决策 Decision 与更新后的 N_{cur} 、 N_{cand} 和 q

- 1: **阶段 0: 初始化**
- 2: 读取当前决策周期的状态与上周期滞后状态 N_{cand} 、 q
- 3: **阶段 1: 状态预测与动态权重生成**
- 4: **for** $k \leftarrow 1$ **to** 3 **do**
- 5: $h_{1,k} \leftarrow \text{LSTM}_1(X_k; \theta_1)$, $h_{2,k} \leftarrow \text{LSTM}_2(h_{1,k}; \theta_2)$
- 6: $s_{\text{pred},k} \leftarrow W_{\text{pred}} h_{2,k}[-1] + b_{\text{pred}}$
- 7: **end for**
- 8: 将 $\{s_{\text{pred},k}\}_{k=1}^3$ 堆叠为 S_{pred}
- 9: $A \leftarrow \text{Attention}(S_{\text{cur}}, S_{\text{cur}}, S_{\text{cur}})$, $c \leftarrow \text{mean}(A, \text{dim} = 0)$
- 10: $m \leftarrow \text{ReLU}(W_{\text{mob}}[v, h]^T)$, $w \leftarrow \text{softmax}(W_{\text{weight}}[c \parallel m])$
- 11: **阶段 2: 融合 TOPSIS 候选排序**
- 12: **for** $i \leftarrow 1$ **to** 3 **do**
- 13: **for** $j \leftarrow 1$ **to** 5 **do**
- 14: $d_{ij} \leftarrow 0.6s_{\text{cur}}(i, j) + 0.4s_{\text{pred}}(i, j)$
- 15: **if** $j \in \{\text{delay}, \text{PLR}\}$ **then** $d_{ij} \leftarrow 1 - d_{ij}$
- 16: **end if**
- 17: **end for**
- 18: **end for**
- 19: 按式(13)至式(17)计算 r_{ij} 、 v_{ij} 、 v_j^+ 、 v_j^- 、 D_i^+ 、 D_i^- 和 C_i
- 20: $N^* \leftarrow \arg \max_i C_i$
- 21: **阶段 3: 双重滞后切换判决**
- 22: **if** $N^* \neq N_{\text{cand}}$ **then**
- 23: $N_{\text{cand}} \leftarrow N^*$, $q \leftarrow 0$
- 24: **end if**
- 25: **if** $C(N^*) - C(N_{\text{cur}}) > \Delta_{\text{th}}$ **then**
- 26: $q \leftarrow q + 1$
- 27: **else**
- 28: $q \leftarrow 0$
- 29: **end if**
- 30: **if** $q \geq T_h$ **then**
- 31: Decision $\leftarrow$ 切换至 N^* , $N_{\text{cur}} \leftarrow N^*$
- 32: **else**
- 33: Decision $\leftarrow$ 保持 N_{cur}
- 34: **end if**
- 35: **return** Decision, N_{cur} , N_{cand} , q

算法 1 表明, 堆叠 LSTM 只提供预测状态 S_{pred} , 注意力模块只提供动态权重 w ; 两者与 S_{cur} 共同进入 TOPSIS 计算贴近度 C_i , 最终由双重滞后规则给出切换结果。各变量的计算顺序与式(2)至式(19)一致。

2.4 ALERA 增强型风险感知垂直切换算法

第 2.3 节完成了从状态预测、动态加权到候选排序和切换裁定的基础决策链路, 但其中的双重滞后仍采用前述固定参数。该设置在信道平稳时表现良好, 当无人机跨越覆盖边界、遭遇遮挡或飞行速度显著变化时, 固定阈值与确认窗口却难以同时兼顾抗波动能力和切换时效; 与此同时, 原始 TOPSIS 仅依据当前贴近度排序, 尚未对评分序列的波动风险进行约束。为承接前述基础决策并增强其遥感场景适应性, 本节

在不重新训练 LSTM-Attention 模型的条件下引入两项机制：ADH 读取当前服务网络的 SINR 历史和飞行速度，动态更新式(19)中的 Δ_{th} 与 T_h ；RS-TOPSIS 读取第 2.3 节输出的贴适度序列 C_i ，将其修正为风险惩罚后的 C_i^{robust} 再参与排序，从而形成 ALERA。

2.4.1 自适应滞后参数

将固定阈值 Δ_{th} 和窗口 T_h 替换为上下文感知的可变参数。定义近期 SINR 波动度 σ 为当前服务网络近 5 个决策周期 SINR 的标准差，飞行速度 v 由仿真侧实时传入。这里的 σ 来自式(1)中 SINR 维度的历史观测， v 来自第 2.2 节已用于动态权重生成的移动状态输入，因此 ADH 复用已有状态信息，只改变最终滞后判决的门槛和确认长度。自适应阈值和窗口计算公式为：

$$\Delta_{th} = 0.03 + 0.05 \left(\frac{\sigma}{10} \right), \quad \sigma \in [0, 10], \quad (20)$$

$$T_h = \max \left(2, \left\lfloor 4 - \frac{2v}{30} \right\rfloor \right), \quad v \in [0, 30] \text{ m/s}. \quad (21)$$

式(20)在信道稳定 ($\sigma \approx 0$) 时给出基础阈值 0.03，低于原始固定值 0.05，为快速响应持续性链路劣化预留空间；在信道波动较为剧烈 ($\sigma \approx 10$) 时，波动修正项使阈值线性增长至最高 0.08，抬高切换门槛以抑制切换 (σ 的历史长度取值依据会在后续实验进行说明)。式(21)在低速飞行 ($v \approx 5 \text{ m/s}$) 时给出窗口 4，提供充分的确认周期；窗口随速度增加而缩短至最低 2，使高速无人机飞越覆盖边界时能及时切换。参数范围 ($\Delta_{th} \in [0.03, 0.08]$, $T_h \in [2, 4]$) 确保了极端条件下的基本防抖能力（此参数取值依据会在后续实验进行说明）。窗口随速度增加而缩短的设计依据在于，无人机在高速飞行时跨越网络覆盖边界所经历的时间极短。以 30 m/s 飞行时，单个决策周期 (0.1 s) 内无人机已移动 3 m，若维持长窗口 $T_h = 4$ (0.4 s) 则确认期间位移达 12 m，可能已从 WiFi 覆盖中心飞至边缘，初始判断在确认完成时已失效；缩短至 $T_h = 2$ (0.2 s，位移 6 m) 使算法在覆盖边界附近能更快锁定真正需要切换的时刻，以少量防抖冗余换取切换时效。反之低速 5 m/s 时 $T_h = 4$ 期间仅位移 2 m，网络条件几乎不变，长窗口可充分过滤偶然抖动而不增加失效风险。

2.4.2 风险敏感 TOPSIS

原始 TOPSIS 以当前贴适度 C_i 作为排序依据。该 C_i 正是式(17)在融合 S_{cur} 、 S_{pred} 和 w 之后得到的排序输出；RS-TOPSIS 并不替换前面的预测和加权过程，而是在已有 C_i 序列之上加入风险约束，通过引入置信下界 (Lower Confidence Bound, LCB) 思想，对候选网络评分减去其历史波动惩罚项：

$$C_i^{robust} = C_i - \lambda \sigma_i^C, \quad \lambda = 0.5. \quad (22)$$

其中 σ_i^C 为网络 i 近 5 轮评分的标准差， $\lambda = 0.5$ 为风险厌恶系数（此参数取值依据会在后续实验进行说明）。该机制的核心思想是：在多个候选网络贴适度接近时，优先选择评分稳定的网络而非均值略高但波动剧烈的网络。例如，在遥感巡航场景中，若 LTE 在近 5 个周期内贴适度持续上升、方差较小，而 WiFi 贴适度在高低之间大幅跳动，即使 WiFi 的当前贴适度略高于 LTE， C_i^{robust} 排序仍将偏好 LTE，保障遥感数据传输的连续性。

两项增强机制无需重新训练 LSTM-Attention 模型，也不改变其前向推理结构，仅在已有状态与评分序列上进行轻量统计和规则更新，因此新增计算开销相对于堆叠 LSTM 预测与注意力权重生成较小。ADH 负责根据信道波动和飞行速度调整切换门槛，RS-TOPSIS 负责抑制高波动候选网络的排序优势：信道平稳时，

两者对原有决策的影响较弱；信道波动加剧时，自适应阈值、确认窗口和风险罚分协同作用，以较低额外开销增强环境感知与乒乓切换抑制能力。

算法 2 给出 ALERA 在每个决策周期对基础贴近度的增强过程。其输入 C_i 来自算法 1 的 TOPSIS 步骤；RS-TOPSIS 先修正排序分数，ADH 再更新双重滞后的触发参数，最后仍依据评分优势的连续性决定是否切换。

算法 2 ALERA 风险感知垂直切换增强流程

Require: 基础贴近度 $\{C_i\}_{i=1}^3$ 及其近 $K_c = 5$ 轮历史，当前服务网络 SINR 近 5 轮历史，飞行速度 v ，当前服务网络 N_{cur} ，上周期确认候选 N_{cand} 及其连续计数 q

Ensure: 增强切换决策 Decision 与更新后的 N_{cur} 、 N_{cand} 和 q

```

1: 阶段 0：状态与历史缓存初始化
2: 读取基础贴近度、SINR 历史、飞行速度及上周期滞后状态  $N_{\text{cand}}$ 、 $q$ 
3: 阶段 1：RS-TOPSIS 风险敏感排序
4: for  $i \leftarrow 1$  to 3 do
5:   将  $C_i$  写入贴近度历史缓存并保留最近  $K_c$  轮
6:    $\sigma_i^C \leftarrow \text{std}(C_i \text{ 的近 } K_c \text{ 轮历史})$ 
7:    $C_i^{\text{robust}} \leftarrow C_i - 0.5\sigma_i^C$ 
8: end for
9:  $N^* \leftarrow \arg \max_i C_i^{\text{robust}}$ 
10: 阶段 2：ADH 自适应滞后参数更新
11:  $\sigma \leftarrow \text{std}(N_{\text{cur}} \text{ 的近 5 轮 SINR})$ 
12:  $\Delta_{\text{th}} \leftarrow 0.03 + 0.05(\sigma/10)$ ,  $T_h \leftarrow \max(2, \lfloor 4 - 2v/30 \rfloor)$ 
13: 阶段 3：鲁棒评分双重滞后判决
14: if  $N^* \neq N_{\text{cand}}$  then
15:    $N_{\text{cand}} \leftarrow N^*$ ,  $q \leftarrow 0$ 
16: end if
17: if  $C^{\text{robust}}(N^*) - C^{\text{robust}}(N_{\text{cur}}) > \Delta_{\text{th}}$  then
18:    $q \leftarrow q + 1$ 
19: else
20:    $q \leftarrow 0$ 
21: end if
22: if  $q \geq T_h$  then
23:   Decision  $\leftarrow$  切换至  $N^*$ ,  $N_{\text{cur}} \leftarrow N^*$ 
24: else
25:   Decision  $\leftarrow$  保持  $N_{\text{cur}}$ 
26: end if
27: return Decision,  $N_{\text{cur}}$ ,  $N_{\text{cand}}$ ,  $q$ 

```

2.5 复杂度分析与算法总结

表 1 汇总了 LAAVHA 及 ALERA 各算法模块的输入/输出、核心流程与计算复杂度，表中顺序也对算法的实际数据流。堆叠 LSTM 预测模块（2.1 节）以滑动窗口内的历史状态张量 $X_k \in \mathbf{R}^{10 \times 5}$ 为输入，通过两层 LSTM 提取时序特征后经全连接头输出下一时刻的预测状态 $S_{\text{pred}} \in \mathbf{R}^{3 \times 5}$ ，其计算瓶颈在于 LSTM 的门控矩阵运算，复杂度为 $O(R \cdot K \cdot d \cdot h^2)$ 。注意力动态权重模块（2.2 节）以当前状态矩阵 $S_{\text{cur}} \in \mathbf{R}^{3 \times 5}$ 为自注意力输入，融合移动特征后输出 5 维动态权重 $w \in \mathbf{R}^5$ ，自注意力计算复杂度为 $O(R^2 \cdot d)$ 。改进 TOPSIS 决策模块（2.3 节）将 S_{cur} 与 S_{pred} 按融合系数加权组合，经归一化后以动态权重 w 执行加权 TOPSIS 排序，

输出候选网络贴近度 C_i ，整体复杂度为 $O(R \cdot d)$ 。ADH 自适应滞后（2.4.1 节）和 RS-TOPSIS 风险敏感排序（2.4.2 节）分别把 SINR 历史、飞行速度和 C_i 历史反馈到最终判决环节，只增加轻量统计计算而不增加模型推理负担。整体算法的端到端推理复杂度由 LSTM 预测和注意力权重生成主导，能够满足无人机遥感巡航场景下的实时切换决策需求。

表 1 算法总结

算法模块	输入/输出	核心流程	复杂度
堆叠 LSTM 预测	输入: $3 \times 10 \times 5$ 状态张量; 输出: 预测状态	$LSTM_1(5 \rightarrow 128) \rightarrow LSTM_2(128 \rightarrow 64) \rightarrow fc(64 \rightarrow 5)$	$O(R \cdot K \cdot d \cdot h^2)$
注意力动态权重	输入: 3×5 状态矩阵 + 移动特征; 输出: 5 维动态权重	Self-Attn $\rightarrow$ 均值池化 $\rightarrow$ 拼接移动特征 $\rightarrow$ softmax	$O(R^2 \cdot d)$
改进 TOPSIS 决策	输入: 当前 + 预测状态 + 动态权重; 输出: 候选网络贴近度 C_i	融合矩阵 $\rightarrow$ 加权归一化 $\rightarrow$ 正负理想解 $\rightarrow$ 贴近度	$O(R \cdot d)$
ADH 自适应滞后	输入: SINR 历史 + 飞行速度; 输出: 自适应 Δ_{th}, T_h	SINR 波动度计算 $\rightarrow$ 阈值线性调节 $\rightarrow$ 窗口自适应	$O(1)$
RS-TOPSIS	输入: 近期贴近度历史; 输出: LCB 调整后排序	历史标准差 $\rightarrow$ 罚分计算 $\rightarrow C_i^{robust}$ 排序	$O(R \cdot K_c)$

3 仿真实验与结果分析

3.1 实验平台与参数设置

为验证 LAAVHA/ALERA 在无人机遥感探测异构网络场景中的决策效果，基于 ns-3.45^[17]和其 AI 扩展模块 ns3-ai^[18]搭建网络仿真与模型推理协同平台。ns-3 负责部署 5G/LTE/WiFi 异构网络拓扑、模拟无人机移动模型并采集物理层和传输层指标；ns3-ai 通过共享内存存在仿真侧与推理侧之间建立双向通信。每个决策周期内，仿真侧将 3 个候选网络各 10 步历史 $\times 5$ 维指标（共 150 维）以及移动状态写入共享内存，推理侧加载训练好的 LAAVHA 模型，读取网络状态、速度、高度和当前网络编号后返回目标网络编号及候选网络评分（网络编号约定：0=5G, 1=LTE, 2=WiFi）。模型输入为 3 个候选网络各自 5 维指标的历史序列（3 网络 $\times 10$ 时间步 $\times 5$ 指标 = 150 维总输入），每个网络独立经堆叠 LSTM 处理；移动状态输入为 2 维（速度、高度）；输出为 5 维预测状态向量及 5 维动态权重向量，经改进 TOPSIS 后得到候选网络评分。实验采用 50 组随机种子（200~249），模拟无人机在不同初始位置和高度条件下执行遥感巡航任务。仿真时长为 10 s，决策周期为 0.1 s，每组实验产生 100 次决策。为模拟实际飞行中的位置偏差和高度波动，启用位置扰动（30 m）和高度扰动（10 m）。

为说明第 2 章关键参数的取值依据，在总体实验参数之前先进行三组灵敏度实验，结果如图 3 所示。融合系数 α 实验在 50 组包含持续性链路劣化和瞬时波动的压力时序上进行重放，当前观测状态包含信道测

量波动，预测状态则包含突变条件下的短期预测滞后，分别取 $\alpha = 0.2, 0.4, 0.6, 0.8$ 进行对比。四种取值的平均误切换次数依次为 1.20、0.90、0.08 和 1.00 次： α 偏小时算法对预测滞后较为敏感， α 偏大时又更容易受到当前测量波动影响； $\alpha = 0.6$ 能够更好地平衡两类误差，误切换次数最低。因此本文取 $\alpha = 0.6$ ，使当前实测状态占 60%，同时保留 40% 的短期预测信息。

双重滞后与增强机制参数采用与后文场景适配性实验一致的两类竞争区间进行 50 次随机重复：一类为候选网络综合质量持续下降、必须执行必要切换的持续性链路劣化区间；另一类为候选评分短时振荡、不应触发切换的瞬时波动区间。对 $\Delta_{th} \in \{0.03, 0.05, 0.07\}$ 与 $T_h \in \{2, 3, 4\}$ 进行组合扫描后，各组合对必要切换的识别率均为 100%。其中， $\Delta_{th} = 0.05, T_h = 3$ 的平均误切换次数为 0.64 次，必要切换平均检测时延为 1.55 s；更激进的 0.03, 2 组合虽然响应更快，但平均误切换达到 9.10 次；更保守的 0.07, 4 组合可完全抑制误切换，但平均检测时延增至 2.00 s。因此本文采用 0.05, 3 作为稳定性与响应速度之间的折中。

进一步对增强机制的贴近期历史长度 $K_c \in \{3, 5, 7\}$ 和风险系数 $\lambda \in \{0.2, 0.5, 0.8\}$ 进行组合扫描。各组合仍能识别全部必要切换；在 $K_c = 5$ 时， λ 由 0.2 增至 0.8 可将平均误切换次数由 1.90 次降至 0.58 次，但平均检测时延由 1.13 s 增至 1.22 s。取 $\lambda = 0.5$ 时， $K_c = 5$ 的平均误切换次数为 1.08 次，低于 $K_c = 3$ 和 $K_c = 7$ 对应的 1.48 次与 1.14 次，且平均检测时延保持在 1.17 s。综合风险抑制、历史统计稳定性和必要切换时效，最终取 $K_c = 5, \lambda = 0.5$ 。




图3 融合系数、双重滞后参数与增强机制参数的灵敏度实验
(图 b、图 c 单元格上行为平均误切换次数，下行为平均检测时延)

在上述参数取值实验基础上，表 2 汇总本节采用的平台、网络场景、模型结构和训练/推理参数。后续对比算法、指标来源和结果分析均基于同一组仿真设置，以避免算法差异与实验环境差异相互混淆。

表 2 实验参数设置

参数	取值
仿真平台	ns-3.45, ns3-ai, Python/PyTorch
候选网络	5G、LTE、WiFi
算法范围	LAHVHA、8 种对比算法和 2 种消融变体
运行次数	每种算法 50 组随机场景
仿真时长	10 s
决策周期	0.1 s
每次运行决策数	100
随机种子	200~249
FlowMonitor 模式	feed
指标维度	SINR、RSRP、时延、吞吐量、丢包率
位置扰动	30 m
高度扰动	10 m
时间窗口 T_s	10
LSTM 隐藏单元	第一层 128, 第二层 64
注意力头数 (num_heads)	1 (embed_dim=5, 采用单头注意力)
融合系数 α	0.6
双重滞后参数	$\Delta_{th} = 0.05$, 确认窗口 $T_h = 3$
增强机制参数	RS-TOPSIS 贴进度历史长度 $K_c = 5$, RS-TOPSIS 风险系数 $\lambda = 0.5$
数据集划分	训练/验证 = 80%/20%
优化器	Adam
早停策略	验证集损失连续 10 个 epoch 不下降

实验除 LAHVHA 外, 还运行了 TOPSIS-Q、Fuzzy-VHO、SAW、VIKOR、GRA、COPRAS、SPOTIS 和最强信号法等 8 种对比算法以及 LAHVHA-L、LAHVHA-A 两种消融变体。这 8 种对比算法覆盖了模糊逻辑式 (Fuzzy-VHO)、简单加权式 (SAW)、补偿式 (VIKOR)、距离式 (TOPSIS-Q)、关联度式 (GRA)、比例式 (COPRAS) 和参考点式 (SPOTIS) 七种主流决策范式, 为全面评估 LAHVHA 的决策性能提供了多维参照。对比算法来源与设置如下: TOPSIS-Q 基于 TOPSIS 网络选择思想及熵权改进 TOPSIS 方法^[6-7,25]; Fuzzy-VHO 参考无人机 5G 网络中的模糊切换机制^[4]; SAW 作为经典加权和 MADM 基线, VIKOR、GRA、COPRAS 和 SPOTIS 选自主流 MADM 决策范式及其网络选择综述^[9,20,25]; 最强信号法为本文设置的单因素启发式基线, 仅依据 SINR 最大原则选择候选网络。LAHVHA-L 表示去除 LSTM 预测分支的消融变体, 直接以当前状态替代预测状态, 保留 Attention 权重与双重滞后; LAHVHA-A 表示去除 Attention 动态权重分支的消融变体, 保留 LSTM 预测和双重滞后, 并以熵权法生成 TOPSIS 权重。

5G 候选网络由代理链路表示, 其 SINR 和 RSRP 由基于位置的传播模型计算^[23], 传输类指标来自点到点代理流的 FlowMonitor 统计; 切换事件表示 LAHVHA 输出的网络编号变化, 并未执行真实 WiFi 解除关

联、LTE 分离或 5G 新空口（NR, new radio）协议栈切换。各候选网络指标来源见表 3。

表 3 候选网络指标来源

网络	SINR/RSRP	时延	吞吐量	丢包率
WiFi	基于 MobilityModel 位置的传播代理值	FlowMonitor	PacketSink 区间接收字节	FlowMonitor
LTE	基于 MobilityModel 位置的传播代理值	FlowMonitor	FlowMonitor	FlowMonitor
5G	到假设下一代节点 B（gNB, next generation NodeB）的传播代理值	点到点代理流 Flow-Monitor	点到点代理流 Flow-Monitor	点到点代理流 FlowMonitor

表 3 用于说明第 3 章实验中五类网络状态指标的采集来源。SINR 和 RSRP 主要反映物理层链路质量，实验中依据无人机与接入点或基站的相对位置及传播代理模型计算得到；时延、吞吐量和丢包率主要反映传输层服务质量，其中 WiFi 吞吐量由 PacketSink 在相邻决策周期内的接收字节数换算，LTE 和 5G 的传输类指标由 FlowMonitor 统计得到。需要强调的是，该表刻画的是决策级仿真平台中的指标来源映射，而非完整协议栈实网测量流程。各候选网络在同一决策周期内提供同维度指标，随后由 LAHVHA 及对比算法统一归一化并输入多属性决策模块。这样设置可以保证不同算法面对完全一致的候选网络状态，避免因采集口径差异影响横向比较。

3.2 对比算法横向比较

为与引言提出的算法层面和遥感探测场景层面两类挑战相对应，本节结果分析也分为两个层面。第一层面验证基础算法改进的有效性：通过 11 种算法横向比较、代表性决策过程对比和消融实验，考察 LSTM 预测、注意力动态权重和双重滞后是否能够改善候选网络选择与切换稳定性。第二层面验证面向遥感探测场景的适配性：针对无人机高速跨越覆盖边界时可能出现的持续性链路劣化和信道突变，检验 ALERA 的 ADH 与 RS-TOPSIS 能否在保留必要切换的同时抑制误切换与乒乓切换。现有实验分别对这两个层面给出验证，不额外引入未经测量的性能指标。

为系统评估 LAHVHA 在不同决策范式下的性能优势，选择 8 种具有代表性的对比算法在同一实验条件下进行横向比较。Fuzzy-VHO 基于 Mamdani 模糊推理系统，将 SINR 和 RSRP 模糊化后通过规则库推理输出切换决策，无需精确数学模型；SAW 以固定权重对所有归一化属性进行简单加权求和，代表最基本的 MADM 方法；TOPSIS-Q 采用熵权法确定属性权重并执行标准 TOPSIS 排序，不涉及时序预测；GRA 通过计算各候选网络与理想参考序列的灰色关联度进行排序，对不确定性信息具有较好的处理能力；VIKOR 基于折中规划思想在群体效用与个体遗憾之间寻求平衡；COPRAS 对效益型和成本型指标分别评估后计算综合效用度；SPOTIS 以参考点距离最小化为目标进行排序。最强信号法直接选择 SINR 最大的候选网络，作为单因素基线。上述 11 种算法对比见图 4。




图 4 11 种算法平均切换次数对比 (mean ± std, n=50)

如图 4 所示, LAAVHA 的平均切换次数为 0.24 次 (std=0.43), 在 11 种算法中最低; 8 种对比算法中, 最强信号法的平均切换次数最低, 为 1.58 次。7 种 MADM 方法中, SAW、TOPSIS-Q、Fuzzy-VHO、VIKOR、GRA、SPOTIS 和 COPRAS 的平均切换次数分别为 2.00、4.04、8.64、13.52、19.24、23.88 和 25.88 次, 均高于 LAAVHA 且数值分布跨度较大。这 7 种 MADM 方法未同时引入时序预测与动态权重机制, 属性权重一次性确定且仅依据当前时刻指标决策, 容易在覆盖边界处因候选网络评分交替领先而反复切换; 最强信号法则仅依据 SINR 单因素进行选择, 未综合考虑时延、吞吐量和丢包率等其他网络状态指标。总体而言, 在切换次数这一决策级指标上, LAAVHA 较 8 种对比算法降低 84.8% ~ 99.1%, 且 50 次运行中有 38 次实现零切换, 体现出所提方法在降低切换频度和提升切换稳定性方面的整体优势。

3.3 代表性算法决策过程对比

图 5 以 2 行 × 3 列布局对比了 LAAVHA、TOPSIS-Q 和 Fuzzy-VHO 三种算法在同一随机种子 (seed=200) 下的决策过程。该组时序对比的目的不是单纯选择横向统计中切换次数最少的两个算法, 而是选择最能解释 LAAVHA 改进来源的参照对象。TOPSIS-Q 与 LAAVHA 同属 TOPSIS 排序框架, 差异主要在于是否引入 LSTM 预测、Attention 动态权重和双重滞后, 因此二者可以形成较清晰的控制变量对比, 用来观察预测状态和动态权重加入后, 候选网络贴近度曲线是否更稳定、切换触发是否更克制。Fuzzy-VHO 则代表另一类规则驱动方法, 其决策依赖模糊隶属函数和规则库, 对 SINR、RSRP 等局部波动更敏感; 将其与 LAAVHA 并列, 可以从不同决策范式角度展示动态多属性融合方法相对于规则式切换方法的鲁棒性。相较之下, 最强信号法和 SAW 虽然在平均切换次数上可能较低, 但前者只依据单一 SINR, 后者采用固定加权求和, 缺少可与 LAAVHA 内部评分机制对应的时序解释维度, 因此更适合作为总体统计基线, 而不适合作为图 5 中的机制分析对象。上排三幅子图的纵轴为贴近度 (Closeness Score), 展示 5G、LTE 和 WiFi 三个候选网络在 TOPSIS 排序中的综合得分变化; 贴近度越接近 1, 表示该网络对遥感任务的综合保障能力越强。下排三幅子图的纵轴为 SINR (dB), 展示同一仿真中三个网络的物理层信号质量变化。红色竖虚线标记切换发生时刻。可以观察到, LAAVHA 的 5G 贴近度在全过程中保持稳定高水平 (0.99~1.00), LTE 和 WiFi 评分均远低

于 5G，结合双重滞后机制 ($\Delta_{th} = 0.05, T_h = 3$) 全程未触发任何切换。尽管下排 SINR 子图显示 5G 信号并非始终最高，但注意力机制生成的动态权重综合了时延、吞吐量和丢包率等多维指标后仍然选择 5G，体现了多属性融合决策的优势。相比之下，TOPSIS-Q 在 5G 与 WiFi 贴近度接近时发生了数次切换，Fuzzy-VHO 因模糊规则对 SINR 波动敏感而产生多次切换；这一结果直观展示了时序预测和动态权重对决策稳定性的关键贡献。




图5 LAAVHA/TOPSIS-Q/Fuzzy-VHO 候选网络评分与 SINR 时序对比 (seed=200, 竖线 = 切换时刻)

3.4 消融实验验证

为量化 LSTM 预测模块和注意力动态权重模块对 LAAVHA 决策质量的贡献，设计消融实验。LAAVHA-L 为移除 LSTM 预测分支的版本，直接令预测状态等于当前状态，仅保留 Attention 权重生成、改进 TOPSIS 和双重滞后逻辑，用于检验短期状态预测的作用；LAAVHA-A 为移除 Attention 动态权重分支的版本，保留 LSTM 预测、改进 TOPSIS 和双重滞后逻辑，但采用熵权法替代 Attention 输出权重，用于检验动态权重学习的作用。两组消融变体与完整 LAAVHA 在相同的 50 组随机种子 (200~249) 和仿真参数下运行。图 6 以散点叠加柱状图的形式展示了三种方案的切换次数对比，其中每个散点代表一次独立运行的结果，柱高为均值，误差线为 ± 1 标准差。完整 LAAVHA 平均切换仅 0.24 次 (std=0.43)，50 次运行中 38 次保持零切换、12 次出现 1 次切换，体现了 LSTM 预测与注意力动态权重协同工作的决策稳定性；LAAVHA-L (去 LSTM) 平均切换 1.08 次 (std=1.01)，失去时序预测后算法退化为被动反应式决策，切换次数显著升高且方差增大；LAAVHA-A (去 Attention) 平均切换 2.00 次 (std=0.00)，全部 50 次运行均产生 2 次切换，说明仅依靠熵权难以根据飞行阶段自适应调整评价标准，在 WiFi 覆盖边缘必然触发乒乓切换。




图 6 LAAVHA 消融实验切换次数对比 (mean $\pm$ std, n=50)

上述消融结果表明, LSTM 预测模块和注意力动态权重模块对 LAAVHA 决策质量的贡献具有显著的协同效应: 单独保留任一模块均无法维持低切换水平。Attention 模块的缺失影响最为严重 (平均切换从 0.24 次增至 2.00 次, 增幅达 8 倍, 且 50 次运行无一例外), 说明在遥感巡航场景下, 基于飞行状态和候选网络状态生成的动态权重比静态统计权重更能区分不同飞行阶段的网络需求; LSTM 模块的缺失导致切换次数上升至 1.08 次且方差增大 ($\text{std}=1.01$), 说明时序预测能力对维持决策稳定性同样关键。两个模块的消融结果从正反两面共同验证了 LAAVHA 架构设计的合理性。

3.5 遥感探测场景适配性与增强机制验证

为验证 ALERA 对遥感探测场景中快速跨越覆盖边界和信道突变的适配能力, 构造网络 A (类比 5G) 与网络 B (类比 WiFi) 贴近度在 0.50 附近拉锯的竞争场景, 初始状态设为接入网络 A。该场景抽象了无人机持续回传遥感图像时所面临的两类典型情况: 覆盖条件持续恶化时必须及时迁移, 以及短时遮挡或多径扰动引起瞬时波动时应避免无效切换。图 7 给出了同一时间轴下的四个子图, 横坐标统一对应最下方的时间轴, 因而图 7-a 到图 7-d 中 $t = 5 \sim 8$ s 和 $t = 12 \sim 15$ s 表示同一段仿真时间。浅蓝色区域 Zone 1 表示持续性链路劣化区间, 即网络 A 的综合服务质量在一段时间内持续下降、网络 B 持续改善, 因此从 A 切换到 B 属于必要且正确的切换; 浅红色区域 Zone 2 表示瞬时波动区间: 网络 B 被注入正弦振荡和高斯噪声, 虽然会出现短时峰值, 但其均值并未形成稳定优势, 因此不应触发切换。

图 7-a 展示两个网络的原始贴近度 (Closeness) 曲线, 纵坐标表示未进行风险惩罚前的候选网络综合评分, 数值越大表示该网络越接近理想候选网络。可以看到, Zone 1 中网络 B 的优势是连续形成的, 而 Zone 2 中网络 B 只是高频振荡造成的瞬时抬升。

图 7-b 展示固定低阈值方案 ($\Delta_{th} = 0.03$) 的切换结果, 纵坐标仍为原始贴近度, 红色虚线表示实际执行的切换时刻, 图中已标明切换方向。该方案在 $t = 6.6$ s 执行 A $\rightarrow$ B、在 $t = 11.9$ s 执行 B $\rightarrow$ A, 这两次分别对应 Zone 1 中的持续性链路劣化和劣化结束后的恢复, 属于正确切换; 但在 Zone 2 内又于 $t = 14.8$ s 执

行 $A \rightarrow B$ 、 $t = 15.1$ s 执行 $B \rightarrow A$ ，这两次仅由网络 B 的瞬时峰值触发，未对应链路质量的持续改善，因而属于误切换和随后的乒乓切换。

图 7-c 展示 ALERA 增强机制下的 LCB 调整后评分，纵坐标为 $C_i^{\text{robust}} = C_i - \lambda \sigma_i^C$ ，即在原始贴近度基础上扣除了历史波动风险罚分后的排序分数；绿色虚线表示增强机制实际执行的切换时刻。可以看到，ALERA 仍然保留了 Zone 1 中的 $A \rightarrow B$ 正确切换和劣化结束后的 $B \rightarrow A$ 恢复切换，说明增强机制并未因为提高鲁棒性而阻塞必要切换；同时，Zone 2 内网络 B 的高频振荡被风险罚分压低，未触发任何切换。

图 7-d 展示自适应阈值 Δ_{th} 随时间变化，纵坐标表示当前切换判决所需的最小贴近度优势。Zone 2 波动期间，阈值由基线 0.03 自动抬升至约 0.09，显著高于固定低阈值方案；波动消退后阈值逐步回落，说明 ADH 只在波动场景下提高切换门槛。

从网络切换正确性看，增强机制的优势体现在两个方面：一是面对持续性链路劣化时仍能完成必要切换，保证无人机从劣化网络 A 迁移到更优网络 B，避免因过度保守导致服务质量下降；二是面对瞬时波动时能够拒绝短时峰值诱导的误切换，避免 $A \rightarrow B \rightarrow A$ 的乒乓过程。RS-TOPSIS 负责在“切向谁”的问题上压低高波动候选网络的排序优势，ADH 负责在“何时切换”的问题上提高波动阶段的触发门槛，两者共同使算法既保持正确切换能力，又减少错误切换和由此带来的链路重建开销。




图 7 自适应滞后机制验证：固定低阈值 ($\Delta_{th} = 0.03$) 与 ALERA 在持续性链路劣化和瞬时波动竞争场景下的对比

4 结束语

面向无人机遥感监测中广域飞行、异构覆盖和链路状态快速变化带来的垂直切换问题, 本文提出了基于 LSTM-Attention 的 LAAVHA 自适应垂直切换方法, 并在此基础上进一步提出增强型风险感知垂直切换算法 ALERA。LAAVHA 的创新在于将堆叠 LSTM 的短期状态预测、注意力机制的动态属性加权、融合当前与预测状态的改进 TOPSIS 排序及双重滞后判决有机结合, 使网络选择能够同时利用时序演化、飞行状态和多属性服务需求, 降低覆盖边界处由瞬时波动引起的频繁切换。ALERA 在保持 LSTM-Attention 结构与训练参数不变的基础上, 以 ADH 根据服务网络 SINR 波动和飞行速度自适应调节切换阈值与确认窗口, 并以 RS-TOPSIS 对贴中度历史波动施加风险罚分, 从“何时切换”和“切向谁”两个环节进一步增强了基础方法对复杂信道变化的适应能力。50 组随机种子的仿真结果表明, LAAVHA 的平均切换次数为 0.24 次, 在 11 种算法中最低, 较 8 种对比算法降低 84.8% ~ 99.1%, 且 50 次运行中有 38 次实现零切换; 去除 LSTM 预测分支或注意力动态权重分支后, 平均切换次数分别增至 1.08 次和 2.00 次。ALERA 在持续性链路劣化时完成全部必要切换, 在瞬时波动时保持零误切换, 说明所提方法能够为无人机遥感探测中的高效稳定数据回传提供可靠的切换保障。

参考文献

- [1] YANG K, WANG Y, GAO X, et al. Communications in space-air-ground integrated networks: an overview[J]. Space: Science & Technology, 2025, 5: 0199.
- [2] GERACI G, GARCIA-RODRIGUEZ A, AZARI M M, et al. What will the future of UAV cellular communications be? A flight from 5G to 6G[J]. IEEE Communications Surveys & Tutorials, 2022, 24(3): 1304–1335.
- [3] RIBEIRO L M B, MÜLLER I, BECKER L B. Communication interface manager for improving performance of heterogeneous UAV networks[J]. Sensors, 2021, 21(13): 4255.
- [4] AYASS T, COQUEIRO T, CARVALHO T, et al. Unmanned aerial vehicle with handover management fuzzy system for 5G networks: challenges and perspectives[J]. Intelligence & Robotics, 2022, 2(1): 20–36.
- [5] WANG Z, LV Z, XU X, et al. Vertical switching algorithm for unmanned aerial vehicle in power grid heterogeneous communication networks[J]. Electronics, 2024, 13(13): 2612.
- [6] ZHONG J, ZHANG L, ALHABO M, et al. A hybrid scheme using TOPSIS and Q-learning for handover decision making in UAV assisted heterogeneous network[J]. IEEE Access, 2024, 12: 31422–31430.
- [7] GOH M I, MBULWA A I, YEW H T, et al. Handover decision-making algorithm for 5G heterogeneous networks[J]. Electronics, 2023, 12(11): 2384.
- [8] SATAPATHY P, MAHAPATRO J. An efficient multicriteria-based vertical handover decision-making algorithm for heterogeneous networks[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4409.

- [9] DANTAS SILVA F S, LIMA M P S, CORUJO D, et al. A comprehensive step-wise survey of multiple attribute decision-making mobility approaches[J]. IEEE Access, 2024, 12: 108616–108656.
- [10] TAN K, BREMNER D, LE KERNEC J, et al. Intelligent handover algorithm for vehicle-to-network communications with double-deep Q-learning[J]. IEEE Transactions on Vehicular Technology, 2022, 71(7): 7848–7862.
- [11] JANG Y, RAZA S M, KIM M, et al. Proactive handover decision for UAVs with deep reinforcement learning[J]. Sensors, 2022, 22(3): 1200.
- [12] ZAID M, KADIR M K A, SHAYEA I, et al. Machine learning-based approaches for handover decision of cellular-connected drones in future networks: a comprehensive review[J]. Engineering Science and Technology, an International Journal, 2024, 55: 101732.
- [13] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735–1780.
- [14] KAUR G, GOYAL R K, MEHTA R. An efficient handover mechanism for 5G networks using hybridization of LSTM and SVM[J]. Multimedia Tools and Applications, 2022, 81(26): 37057–37085.
- [15] ALRAIH S, NORDIN R, ABU-SAMAH A, et al. A survey on handover optimization in beyond 5G mobile networks: challenges and solutions[J]. IEEE Access, 2023, 11: 59317–59345.
- [16] SOYDANER D. Attention mechanism in neural networks: where it comes and where it goes[J]. Neural Computing and Applications, 2022, 34(16): 13371–13385.
- [17] MANZOOR S, MANZOOR M, MANZOOR H, et al. Which simulator to choose for next generation wireless network simulations? ns-3 or OMNeT++[J]. Engineering Proceedings, 2023, 46(1): 36.
- [18] YIN H, LIU P, LIU K, et al. ns3-ai: fostering artificial intelligence algorithms for networking research[C]//Proceedings of the 2020 Workshop on ns-3. New York: ACM, 2020: 57–64.
- [19] ZHOU S, LIU X, TANG B, et al. Handover and coverage analysis in 3-D mobile UAV cellular networks[J]. IEEE Internet of Things Journal, 2024, 11(18): 29911–29925.
- [20] ZOLFANI S, YAZDANI M, PAMUCAR D, et al. A VIKOR and TOPSIS focused reanalysis of the MADM methods based on logarithmic normalization[J]. Facta Universitatis, Series: Mechanical Engineering, 2020, 18(3): 341–355.
- [21] TASHAN W, SHAYEA I, ALDIRMAZ-COLAK S, et al. Voronoi-based handover self-optimization technique for handover ping-pong reduction in 5G networks[C]//2023 10th International Conference on Wireless Networks and Mobile Communications (WINCOM). Piscataway: IEEE Press, 2023: 1–6.

- [22] NDEGWA S, NYACHIONJEKA K, MHARAKURWA E T. User preference-based heterogeneous network management system for vertical handover[J]. Journal of Electrical and Computer Engineering, 2023: 1–20.
- [23] RAPPAPORT T S. Wireless communications: principles and practice[M]. 2nd ed. Upper Saddle River: Prentice Hall, 2002.
- [24] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems 30. Red Hook: Curran Associates, 2017: 5998–6008.
- [25] HWANG C L, YOON K. Multiple attribute decision making: methods and applications[M]. Berlin: Springer-Verlag, 1981.

作者简介

苏文（2006- ），男，成都理工大学本科生，主要研究方向：无人异构网络、智能垂直切换、网络仿真等。