

分类号_____

密 级_____

UDC_____

编 号_____

成都理工大学

硕 士 学 位 论 文

题名和副题名 无人异构网络垂直切换与路由协议自适应切换算法
研究

作 者 姓 名 郑宇翔

指导教师姓名及职称 罗俊松 教授

申请学位级别 学术学位硕士 类别（领域） 计算机科学与技术

论文提交日期 2026.04 论文答辩日期 2026.06

学位授予单位和日期 成 都 理 工 大 学（2026 年 06 月）

答辩委员会主席_____

2026 年 4 月

分类号_____

学校代码：10616

UDC _____

密级_____ 学号：2023020952

学术学位硕士学位论文

无人异构网络垂直切换与路由协议自适应 切换算法研究

郑宇翔

指导教师姓名及职称 _____ 罗俊松 教授

申请学位级别 _____ 学术学位硕士 类别（领域） _____ 计算机科学与技术

论文提交日期 _____ 2026.04 论文答辩日期 _____ 2026.06

学位授予单位和日期 _____ 成 都 理 工 大 学（2026 年 06 月）

答辩委员会主席 _____

2026 年 04 月

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得成都理工大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的人员对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：

年 月 日

学位论文版权使用授权书

本学位论文作者完全了解成都理工大学有关保留、使用学位论文的规定，有权保留并向国家有关部门或机构送交论文的复印件和磁盘，允许论文被查阅和借阅。本人授权成都理工大学可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

（保密的学位论文在解密后适用本授权书）

学位论文作者签名：

学位论文作者导师签名：

年 月 日

无人异构网络垂直切换与路由协议自适应切换算法研究

摘 要

随着无人设备应用场景的不断扩展,无人异构网络在军事、应急救援、智慧城市等领域获得广泛应用。在复杂多变的网络环境下,网络切换技术已成为保障通信质量和系统稳定性的研究热点,垂直网络切换和路由协议的切换问题更是该研究领域中的核心内容。在网络垂直切换过程中,由于网络接入技术和覆盖范围的差异出现乒乓效应,导致网络连接的稳定性受到影响。此外,网络中传统固定单一路由协议难以应对节点高速移动、网络密度动态变化等特性,势必导致网络中路由性能下降。针对上述问题,本文分别从无人异构网络垂直切换和路由协议自适应切换两个方面展开研究,主要工作内容如下:

(1) 针对无人异构网络中垂直切换面临的乒乓切换频繁、决策滞后及固定权重难以适应动态环境等问题,提出了基于长短期记忆神经网络和注意力机制的自适应垂直切换算法(Long Short-Term Memory-Attention based Adaptive Vertical Handover Algorithm, LAAVHA)。该算法利用堆叠 LSTM 网络对信干噪比、参考信号接收功率、传输时延、吞吐量和丢包率等网络状态参数进行时序预测,实现主动式切换决策;通过多头注意力机制根据网络状态与无人节点移动特征动态生成各属性权重;最后结合逼近理想解排序法(Technique for Order Preference by Similarity to an Ideal Solution, TOPSIS)构建融合当前状态与预测状态的决策矩阵进行最优网络选择,并引入双重滞后机制有效抑制乒乓切换。NS-3 仿真结果和消融实验共同表明, LAAVHA 算法在平均切换次数、平均吞吐量、丢包率和平均端到端时延等指标上均显著优于对比算法,有效提升了通信可靠性与网络稳定性。

(2) 针对传统最优链路状态路由(Optimized Link State Routing, OLSR)和按需距离矢量路由(Ad hoc On-Demand Distance Vector, AODV)在无人异构网络高动态环境下的场景适配局限性,提出控制消息发送策略改进 OLSR 路由协议(OLSR Control, OLSR-C)和多因素权重 AODV 路由协议(AODV Multi-Factor Weighted, AODV-MFW)。OLSR-C 协议通过融合节点移动特征与邻居密度等因素,动态调整 HELLO/TC 消息发送间隔,解决了固定时隙导致的拓扑感知滞后与控制消息泛滥问题;AODV-MFW 协议结合传播区域约束、相对移动速度预判、剩余能量与网络密度等多因素优化转发节点选择,有效抑制了广播风暴与链路频繁失效。在此基础上,针对单一协议难以适应全场景需求的问题,进一步提出基于 Q-Learning 的自适应路由协议切换算法(Q-Learning based Adaptive Routing

Protocol Switching Algorithm, QAS), 该算法以节点移动性、链路质量、网络密度和网络拥塞度为状态空间, 通过强化学习实时感知网络状态并智能选择最优协议, 实现 OLSR-C 与 AODV-MFW 的动态互补。NS-3 仿真结果表明, 改进协议在不同节点规模下的平均吞吐量、平均端到端时延及丢包率方面均显著优于传统协议且 QAS 算法也进一步提升了网络长时间的整体性能。

关键词: 垂直切换; 路由协议; 自适应切换; 无人异构网络; NS-3 仿真

Research on Vertical Handover and Adaptive Handover Algorithm for Routing Protocols in Unmanned Heterogeneous Networks

Abstract

With the continuous expansion of application scenarios for unmanned devices, unmanned heterogeneous networks have been widely deployed in military operations, emergency rescue, smart cities, and other fields. In complex and dynamic network environments, network handover technology has become a key research focus for ensuring communication quality and system stability. Among them, vertical network handover and routing protocol switching are the core contents in this research field. During vertical network handover, the ping-pong effect occurs due to differences in network access technologies and coverage ranges, which affects the stability of network connections. In addition, the traditional fixed single routing protocol in the network is difficult to cope with the characteristics of high-speed node movement and dynamic changes in network density, which will inevitably lead to the degradation of routing performance in the network. Aiming at the above problems, this thesis conducts research from two aspects: vertical handover of unmanned heterogeneous networks and adaptive switching of routing protocols. The main work contents are as follows:

(1) To address the problems of frequent ping-pong handover, decision-making lag, and fixed weights being difficult to adapt to dynamic environments in vertical handover of unmanned heterogeneous networks, a Long Short-Term Memory Neural Network-Attention based Adaptive Vertical Handover Algorithm (LAAVHA) is proposed. The algorithm utilizes a stacked LSTM network to conduct time-series prediction of network state parameters, such as signal-to-interference-plus-noise ratio, received signal strength of reference signal, transmission delay, throughput, and packet loss rate, thereby achieving proactive handover decision-making. Attribute weights are dynamically generated according to network states and mobility characteristics of unmanned nodes through a multi-head attention mechanism. Finally, combined with the Technique for Order Preference by Similarity to an Ideal Solution (TOPSIS), a decision matrix integrating current and predicted states is constructed for

optimal network selection, and a dual hysteresis mechanism is introduced to effectively suppress ping-pong handover. Both NS-3 simulation results and ablation experiments demonstrate that the LAAVHA algorithm outperforms comparison algorithms in terms of metrics such as average number of handovers, average throughput, packet loss rate, and average end-to-end delay, effectively improving communication reliability and network stability.

(2) To address the scenario adaptation limitations of traditional Optimized Link State Routing (OLSR) and Ad hoc On-Demand Distance Vector (AODV) protocols in highly dynamic unmanned heterogeneous networks, an improved OLSR protocol based on a control message sending strategy (OLSR-C) and a multi-factor weighted AODV protocol (AODV-MFW) are proposed. The OLSR-C protocol dynamically adjusts the sending intervals of HELLO/TC messages by integrating node mobility characteristics and neighbor density, thereby resolving the problems of topology perception lag and control message flooding caused by fixed intervals. The AODV-MFW protocol optimizes the selection of forwarding nodes by combining multiple factors such as propagation area constraints, relative movement speed prediction, residual energy, and network density, effectively suppressing broadcast storms and frequent link failures. On this basis, to solve the problem that a single protocol struggles to adapt to all-scenario requirements, a Q-Learning based Adaptive Routing Protocol Switching Algorithm (QAS) is further proposed. Taking node mobility, link quality, network density, and network congestion degree as the state space, the algorithm perceives the network state in real time and intelligently selects the optimal protocol through reinforcement learning, achieving dynamic complementarity between OLSR-C and AODV-MFW. NS-3 simulation results demonstrate that the improved protocols significantly outperform traditional protocols in terms of average throughput, average end-to-end delay, and packet loss rate under different node scales, and the QAS algorithm further enhances the overall long-term performance of the network.

Keywords: Vertical Handover; Routing Protocol; Adaptive Handover; Unmanned Heterogeneous Networks; NS-3 Simulation

目 录

第 1 章 绪论.....	3
1.1 研究背景及意义.....	3
1.2 研究现状.....	5
1.2.1 无人异构网络研究现状.....	5
1.2.2 无人异构网络垂直切换算法研究现状.....	6
1.2.3 无人异构网络路由协议研究现状.....	8
1.3 论文研究内容.....	10
1.4 论文章节安排.....	11
第 2 章 相关理论基础.....	13
2.1 协议原理.....	13
2.1.1 垂直切换阶段介绍.....	13
2.1.2 路由协议工作原理.....	14
2.2 强化学习.....	15
2.2.1 强化学习框架.....	15
2.2.2 马尔可夫决策模型.....	16
2.3 LSTM 神经网络.....	17
2.4 NS-3 网络仿真器与网络性能评价指标.....	19
2.4.1 NS-3 离散事件网络仿真器.....	19
2.4.2 性能评价指标.....	20
2.5 本章小结.....	21
第 3 章 基于 LSTM-Attention 的自适应垂直切换算法研究.....	22
3.1 传统垂直切换算法局限性分析.....	23
3.2 基于堆叠 LSTM 的网络状态预测.....	23
3.2.1 网络系统模型.....	24
3.2.2 网络状态参数建模.....	25
3.2.3 数据预处理与预输入构建.....	26
3.2.4 堆叠 LSTM 网络结构设计.....	26
3.3 基于 Multi-Head Attention 的动态权重生成.....	27
3.3.1 注意力机制原理.....	28
3.3.2 动态权重生成网络.....	28
3.4 基于改进 TOPSIS 的垂直切换决策方法.....	30
3.4.1 融合决策矩阵构建.....	30

3.4.2 TOPSIS 网络选择流程	30
3.4.3 切换决策与滞后机制.....	31
3.4.4 LAAVHA 算法流程	32
3.5 仿真验证与分析.....	33
3.5.1 仿真平台与环境配置.....	33
3.5.2 仿真结果分析.....	34
3.5.3 消融实验分析.....	41
3.6 本章小结.....	44
第 4 章 基于 Q-Learning 的自适应路由协议切换算法研究	45
4.1 OLSR、AODV 路由协议局限性分析	46
4.2 基于控制消息发送策略改进的 OLSR 协议研究	47
4.2.1 OLSR 协议控制消息机制分析	47
4.2.2 自适应 HELLO 消息发送机制	48
4.2.3 自适应 TC 消息发送机制	49
4.3 基于多因素改进的 AODV-MFW 协议研究	51
4.3.1 转发节点选择优化策略.....	51
4.3.2 节点权重评估与选择机制.....	52
4.3.3 协议工作流程.....	53
4.4 基于 Q-Learning 的路由协议自适应切换决策.....	55
4.4.1 算法整体架构设计.....	55
4.4.2 状态空间与动作空间设计.....	57
4.4.3 奖励函数与学习策略设计.....	58
4.5 仿真验证与分析.....	60
4.5.1 网络仿真设置.....	60
4.5.2 仿真结果分析.....	61
4.6 本章小结.....	68
结 论.....	69
致 谢.....	70
参考文献.....	71
在读期间发表的学术论文与研究成果.....	77
附 录.....	78

第 1 章 绪论

1.1 研究背景及意义

近年来，全球自主无人系统领域正迎来快速发展期，市场研究显示，无人系统市场规模从 2022 年的 1475 亿美元增长到 2023 年的 2080 亿美元，预计到 5 年后将达到 4283 亿美元^[1]。无人系统通过航空、地面和海洋等不同环境中的无人平台，提供了高效的信息获取、监测和执行能力，能够在高辐射区、极端天气环境和灾难现场等人类难以直接作业的场景中执行任务，实现了作业效率与人员安全的双重优化，同时显著提升了数据采集精度和任务执行的可靠性^[2]。

随着无人系统应用场景的多样化和任务复杂度的提升，单一的通信技术已无法满足当下全时、全域的通信需求。在此背景下，由不同类型、不同通信能力的无人设备组成的无人异构网络系统应运而生。这类网络能够灵活整合多种通信资源，实现信息传输渠道的动态优化^[3]。

与传统的异构网络不同，无人异构网络普遍具有节点移动速度快、网络拓扑变化频繁以及节点能量消耗高等显著特点，特别是在无人长途物流配送^[4]、无人节点协同搜索的灾害救援^[5]、以及偏远地区农业环境监测^[6]等特定应用场景中，传统的网络垂直切换算法难以有效应对频繁网络切换引起的乒乓效应^[7]，从而避免网络间断或中断问题。此外，传统的路由协议往往在处理高速运动和动态拓扑环境时存在明显不足，导致数据传输效率低下或出现路由空洞，无法保证数据的可靠传输。

作为无人异构网络中的关键技术，垂直切换算法直接决定了网络的稳定性与切换效率，故设计一个好的垂直切换算法的设计就显得至关重要。算法主要分为几种类型：第一类是基于单因素切换算法，如通过信噪比来判断网络切换的时机^[8]；第二类是多因素切换算法，如在文献[9]中提出的基于数据速率、功耗和费用三个要素来综合判断网络切换的策略；第三类是基于多属性决策的切换，如采用层次分析法^[10]（Analytic Hierarchy Process, AHP）对不同网络的属性进行加权评估，以决定切换；此外，还有基于机器学习类的切换算法，如使用人工神经网络^[11]进行个性化位置预测和网络选择。虽然以上提及的切换算法各自有其应用场景和优势，但也存在各自的局限性：基于单一因素的算法忽视了网络中多重指标的动态变化，导致切换决策的片面性；多因素算法虽然考虑了多个因素，但权重分配和决策过程往往依赖人工设定，缺乏自适应能力；基于多属性决策的算法虽然能综合评估多项因素，但计算复杂度较高，实时性差；而基于机器学习的切换算法则通常依赖大量的训练数据，且在实际应用中可能面临数据不足或算法过拟合

等问题。因此,设计兼顾多因素感知、自适应决策的垂直切换算法,对提升无人异构网络的连通可靠性与服务质量具有重要意义。

与此同时,路由协议作为网络中数据传输的核心技术,直接影响网络的性能表现。在无人异构网络中,由于其高度动态的特性,传统的基于拓扑结构的路由协议面临着更多挑战。传统的路由协议基于拓扑结构主要分为四种类型:主动式路由协议,如优化链路状态路由^[12](Optimized Link State Routing, OLSR)、反应式路由协议,如按需距离向量路由^[13](Ad-Hoc On-Demand Distance Vector, AODV)、混合式路由协议,如区域路由协议^[14](Zone Routing Protocol, ZRP)和分簇路由协议^[15](Cluster-Based Routing Protocol, CBRP)。然而,这些传统协议在无人异构网络中表现出明显的局限性:主动式路由协议虽然能够维持全网的路由表,但频繁的路由表更新会导致较大的网络开销;反应式路由协议在路径发现过程中引入较高的延迟,难以满足实时性要求;混合式路由协议虽然结合了主动式和反应式路由的优点,但在三维空间中网络区域的划分存在困难;而分簇路由协议在控制开销方面表现较好,但在高动态环境下簇头的选举与维护仍然需要进一步优化。这些局限性使得传统路由协议难以在无人异构网络中满足其复杂的通信需求,因此,研究适应性更强、能够应对动态变化的路由协议成为提升无人异构网络性能的关键。

在此背景下,本文针对无人异构网络中垂直切换面临的乒乓切换频繁、决策滞后等问题,提出了基于长短期记忆神经网络和注意力机制的自适应垂直切换算法(Long Short-Term Memory-Attention based Adaptive Vertical Handover Algorithm, LAAVHA),利用堆叠 LSTM 网络对网络状态参数进行时序预测以实现主动式切换决策,通过多头注意力机制动态生成各网络属性的权重以适应不同需求,并结合改进逼近理想解排序法(Technique for Order Preference by Similarity to an Ideal Solution, TOPSIS)方法与双重滞后机制进行最优网络选择,有效降低了切换次数与丢包率,提升了通信时延性能。同时,针对无人异构网络中传统路由协议的场景适配局限性,分别对 OLSR 和 AODV 协议进行了改进优化:设计了控制消息发送策略改进 OLSR 路由协议(OLSR Control, OLSR-C)协议和多因素权重 AODV 路由协议(AODV Multi-Factor Weighted, AODV-MFW),并在此基础上提出了基于 Q-Learning^[16]的自适应路由协议切换算法(Q-Learning based Adaptive Routing Protocol Switching Algorithm, QAS),通过强化学习方法实时感知网络状态,智能选择当前场景下的最优协议,实现 OLSR-C 与 AODV-MFW 的动态互补。两者的结合为无人异构网络中的垂直切换与路由协议切换提供了一种智能自适应解决方案,能够更好地适应动态变化的网络环境,提升通信效率和网络可靠性。本文所提相关算法能够切实改善无人异构网络的通信传输效率与切换性能,为无人异构网络的网络优化提供了具备实操性的技术方案与理论参考。

1.2 研究现状

本节梳理了无人异构网络的研究现状，阐明了无人异构网络与传统网络的区别，在总结现有无人异构网络垂直切换算法和路由协议的分类和进展基础上，进一步分析了各个算法场景的适用性。

1.2.1 无人异构网络研究现状

近年来，无人异构网络受到了学术界和工业界的广泛关注，研究成果广泛应用于军事、应急救援、智慧城市等领域。随着应用场景的不断拓展，相关研究也日益增多。在文献[17]中提出的无人异构网络架构集成了基于卫星的天基网络、空基网络 and 传统地面网络，整个网络的组成包括无人机、无人车等移动性节点、地面站、卫星以及它们之间的无线链路，如图 1-1 所示。




图 1-1 无人异构网络架构

天基网络层位于整个架构的最上层，主要由高轨卫星组成，这些卫星在太空轨道上运行，能够提供广域网络覆盖，满足大范围通信需求。天基网络的优势在于视野广阔、覆盖范围大，能够实现对地面和空中节点的全域连接，特别适合为偏远地区或海洋等传统网络难以覆盖的区域提供通信支持；空基网络层处于中间位置，包括飞艇、固定翼无人机、多旋翼无人机等空中节点，这些节点在空中形

成机动灵活的网络，能够快速部署并对特定区域实现网络增强。空基网络层的特点是灵活性强、部署迅速，可以根据实际需求进行动态调整，弥补天基网络在局部区域覆盖密度不足的问题，同时为地面网络提供更可靠的连接。地面网络层是整个架构的基础部分，主要包括无人车、无人船等移动节点和各类终端设备，以及智慧城市的相关服务。这些设备和节点通过地面网络相互连接，支撑多样化的应用场景。

文献[18]提出，无人异构网络相比于传统异构网络面临的最大的挑战就包括节点能耗和续航差异。由于无人异构网络中的节点通常具有高动态性，其能耗较大，从而造成续航不足的问题。此外，无人异构网络集成了多种不同的数据链路层和物理层，这使得网络结构更加复杂，需要处理来自各类设备和通信协议的多重挑战^[19]。相比于传统异构网络，基于无线通信的无人异构网络不仅要求网络在高度动态的环境中保持稳定，还必须确保在不同层级的节点之间高效通信。

表 1-1 异构网络之间的区别

对比维度	传统异构网络	无人异构网络
网络组成	主要包括宏基站、Wi-Fi 接入点和中继器等固定基础设施	包括无人机、地面站、卫星以及它们之间的无线链路 ^[17]
移动性特征	主要为二维平面内的有限移动，且移动速度较慢	在三维环境中，且移动速度较快 ^[20]
网络覆盖	主要提供水平覆盖，覆盖范围相对固定	提供三维立体覆盖 ^[20]
节点能耗特征	相对充足的电力供应，能耗管理主要关注效率优化	电池、有效载荷容量和续航力的差异会影响网络性能 ^[18]

从表 1-1 中不难看出，传统异构网络通常依赖于固定的基础设施，且在二维平面内进行通信，节点的移动性较低，能耗管理相对简单。而在无人异构网络中，节点以三维空间中的移动为特征，通信环境更为复杂，尤其在动态拓扑和移动速度较高的情况下，节点的能耗和续航能力成为影响网络性能的关键因素。无人异构网络的三维立体覆盖特性使其能够在更广泛的场景中提供服务，但也需要应对更复杂的网络管理等问题，从而导致了使用于传统异构网络的相关技术并不适用于无人异构网络。

1.2.2 无人异构网络垂直切换算法研究现状

垂直切换算法作为一种决定节点在不同接入网络之间切换的关键技术，直接影响网络的稳定性、切换效率以及通信质量。现有研究表明，垂直切换算法的主要类型可以分为基于单因素切换、基于多属性切换和基于机器学习类切换，如图

1-2 所示:




图 1-2 垂直切换算法分类

(1) 单因素切换

基于单因素切换算法，顾名思义就是以单一指标作为切换判据，这类算法实现简单、计算开销低，对参数测量要求少，因此在对实时性要求高且资源受限的场景中具有实用性。文献[21]仅采用信噪比单一指标作为网络切换的判断依据。文献[22-23]基于接收信号强度(Received signal strength, RSS)这一指标提出 RSS 滞后法和动态 RSS 阈值法。其中，当前连接的 RSS 低于阈值 T 且目标网络 RSS 需高出当前网络一个滞后量 H 时才进行切换。单因素算法最大的优点就在于简单直接、反应快速，测量和计算开销小，对终端和网络开销影响最小。

(2) 多属性切换

多属性决策(Multiple Attribute Decision Making, MADM)算法是一类源自决策科学的方法，专门用于在存在多个评价指标时进行选优排序。MADM 方法通常有一套明确的决策流程，如构建决策矩阵、归一化、计算各方案得分或距离等，然后对候选项进行排序^[24]，从而选择最符合综合需求的网络。常用的 MADM 方法包含 TOPSIS, AHP^[25]等。TOPSIS 通过计算各方案与理想最优点和理想最劣点的距离来排序^[26]。其步骤包括归一化决策矩阵、确定各指标的正理想值和负理想值，然后计算每个网络到这两个理想点的欧式距离，最后使用特定的评分公式作为评选依据。在垂直切换中，TOPSIS 常用于选择综合性能最接近理想网络的选项。一些改进的 TOPSIS 也被提出，如考虑网络历史体验值的增强 TOPSIS^[27]，即是根据各网络历史体验值的偏差距离进行优劣排序。该算法能够充分利用绝对数量差异，结果更加符合实际情况。层次分析法本身是一种权重确定方法，可通过两两比较从定性偏好中推导出各指标权重^[28]。研究将 AHP 用于网络选择时，不仅用其求权重，还通过层次结构对网络方案打分。文献[29]分别使用熵权法计算网络属性的客观权重和 AHP 计算网络属性的主观权重。将网络选择分解为带宽、丢包率等子评价。层次分析法优点在于结构清晰，考虑了人对各指标相对重要性的判断。

(3) 机器学习类

为了有效解决传统切换算法在复杂网络环境下的局限性,近年来机器学习技术被广泛应用于垂直切换决策中。根据学习方式和算法特点,可将基于机器学习垂直切换算法分为四大类:监督学习类、无监督学习类、强化学习类和多方法融合类。决策树作为监督学习的经典方法,因其良好的可解释性成为早期研究的重点。文献[30]针对无人船异构通信网络提出了基于 C4.5 决策树算法的切换策略。最终选择具有最大多属性判决值的网络作为目标网络完成切换。Goutam 等^[31]实现了基于 k-means 聚类的垂直切换决策算法,算法采用肘部方法,通过计算不同 k 值下的簇内平方和来决定切换。文献[32]深入分析了移动性对网络切换决策的影响,在 Q-learning 中设计了专门的移动感知奖励函数来动态平衡信号强度维持和切换频率控制之间的关系,使得在学习过程中既能够追求更好的信号质量,又能够有效控制因高速移动而引发的频繁切换。

尽管现有的垂直切换算法在不同场景下各有优势,但它们也存在明显的不足。因此,如何在动态、复杂的无人异构网络环境中实现更高效、更稳定的垂直切换,仍然是一个值得深入研究的问题。

1.2.3 无人异构网络路由协议研究现状

路由协议是保障无人异构网络稳定运行的核心技术,总的来说可以分为基于拓扑和位置的两大类路由协议^[33]如图 1-3 所示:




图 1-3 路由协议分类

基于拓扑结构的路由协议通过维护网络拓扑信息来进行路由决策,通常不需要节点的地理位置信息。根据网络中节点结构的组织方式,基于拓扑结构的路由协议可进一步分为分簇路由协议和平面路由协议。分簇路由协议采用层次化管理,网络中节点分为簇头与簇内成员;平面路由协议则采用平面网络结构,所有节点在网络中具有平等地位。再根据路由发现和维护机制的不同,平面路由协议可以

进一步分为三类：主动路由协议、按需路由协议和混合路由协议。基于地理位置的路由协议则获取节点位置信息来实现高效路由选择。

（1）主动路由协议

主动式路由协议通过周期性更新路由表维护全网路由信息，保证路由始终可用，其代表协议是 OLSR。针对高度动态的拓扑，研究者对 OLSR 进行了多项改进。例如，文献[34]在搜索救援场景中比较了标准 OLSR、Directional OLSR、Mobility-and-Load aware OLSR 及 Predictive OLSR 等四种协议，结果表明 ML-OLSR 能在链路动态情况下保持更高的包投递率、较低的时延和能耗，并在吞吐量方面显著优于其他 OLSR 变体。此外，为降低能源消耗，文献[35]提出了一种基于萤火虫算法的能量感知路由方案，将发送/接收 Hello 包的连接质量和剩余能量作为多点中继选择因素，仿真表明该方法相较于 OLSR 能在延迟、包投递率和吞吐量方面取得改善。可见，主动式协议的改进主要集中在针对节点移动性和能量限制引入方向性、中继选择和能量权衡等机制，以提升在高动态环境下的路由效率。

（2）按需路由协议

按需式协议在需要通信时才建立路由，典型代表为 AODV。但传统 AODV 在高动态环境中存在路由开销大、路径失效频繁等问题。近年来的研究通过多因素加权或智能算法提升其性能。文献[36]对 AODV 进行了参数调优并提出了改进协议 FAODVN-OE，调节路由缓存大小、超时和 Hello 周期后，该方案显著降低了抖动和平均时延。另一个方向是能量感知路由，通过在 RREQ 消息中加入能量、可靠距离和移动相似度等字段，过滤抑制广播风暴并综合跳数、能量和距离评分选择路径^[37]。

（3）混合路由协议

混合协议通过结合主动路由和按需路由的特点，利用预测机制或监控缓冲区，在确保路径质量的同时降低了网络开销。ZRP 是一个典型的例子。然而，在动态变化的网络环境中，区域的划分往往难以精确实施。为了优化网络性能并减少开销，Garg 等^[38]提出了一种基于按需多指标路由的策略，通过设定一个环绕选定路径的区域来实时监控链路质量，并在链路质量下降前主动切换至备用路径。而 Sirai 等^[39]则通过优化目标节点的区域划分，提出了结合长短期记忆循环神经网络的 ZRP 优化方案，能够动态调整区域半径，综合考虑路由开销、能耗、吞吐量等多个因素。

（4）分簇路由协议

在分簇路由协议通过将网络节点划分为多个簇，每个簇由一个簇头负责管理簇内通信及跨簇的数据转发，从而有效减小了路由信息的传播范围，降低了网络开销。簇间通信通过引入网关节点实现，形成虚拟骨干网络。这种结构结合了集

中式决策和分布式执行。然而，分簇过程本身面临着挑战，特别是在节点数量较多的情况下，分簇优化成为一个复杂的 NP-Hard 问题。为了减轻这一问题，元启发式算法被广泛应用于簇头选举与网络拓扑优化。例如，文献[40]提出结合加权分簇与自适应果蝇优化算法，成功优化了簇规模和网络稳定性。此外，尽管分簇协议在静态环境中表现良好，但在快速移动和拓扑频繁变化的无人异构网络中，簇头的选举与维护仍然是难题。为此，文献[41]提出了一种基于剩余能量和邻居密度的簇头选举机制，并引入信任管理，显著提升了协议的能源效率与安全性。

（5）地理位置路由协议

地理位置路由协议通过利用节点的位置信息来优化路由决策，无需维护全局路由表或进行复杂的路由发现过程。这类协议通常依靠周期性广播位置信息来确定数据包的转发路径，减少控制开销。例如传统的贪婪周边无状态路由协议（Ground Positioning Service Router, GPSR）协议利用距离目的地最近的邻居进行数据转发^[42]。此外还有类似于位置辅助路由^[43]（Location-Aided Routing, LAR）通过限制路由发现范围减少开销，但其性能依赖于位置信息的准确性。

尽管现有的路由协议在特定场景下已经有了显著的性能提升，但在无人异构网络的高动态、复杂环境中，依然面临不少挑战。尤其是在高速移动和网络拓扑频繁变化的场景下，如何高效地进行路由切换和优化，仍是有待解决的问题。

1.3 论文研究内容

无人异构网络因其节点高速移动、拓扑结构动态变化、链路稳定性差等特点，对传统网络协议与切换机制提出了严峻挑战。无人异构网络中的垂直切换机制面临乒乓切换频繁、决策滞后及固定权重难以适应动态环境等瓶颈，严重制约了网络通信系统的可靠性与整体性能；与此同时，现有路由协议在无人节点高动态场景中存在明显的适配局限，难以有效应对拓扑感知滞后、广播风暴与链路频繁失效等问题。为此，本文围绕无人异构网络垂直切换和路由协议切换两大核心问题展开深入研究，主要研究内容如下：

（1）针对无人异构网络中垂直切换面临的乒乓切换频繁、决策滞后及固定权重难以适应动态环境等问题，提出了基于 LSTM-Attention 的自适应垂直切换算法。利用堆叠 LSTM 网络对信干噪比、参考信号接收功率、时延、吞吐量和丢包率等网络状态参数进行时序预测，实现主动式切换决策；通过 Multi-Head Attention 机制根据网络状态与无人节点移动特征动态生成各属性权重，适应不同任务需求；结合改进 TOPSIS 方法构建融合当前状态与预测状态的决策矩阵进行最优网络选择，并引入双重滞后机制有效抑制乒乓切换，显著降低了切换次数与丢包率，提升了通信可靠性。

(2) 针对传统 OLSR 和 AODV 协议在无人异构网络中的场景适配局限性, 分别提出了 OLSR-C 和 AODV-MFW 两种改进协议及 QAS 算法。OLSR-C 通过融合节点移动特征与邻居密度动态调整 HELLO/TC 消息发送间隔, 解决了固定时隙导致的拓扑感知滞后与控制消息泛滥问题; AODV-MFW 结合传播区域约束、相对移动速度预判、剩余能量与网络密度等多因素优化转发节点选择, 有效抑制了盲目泛洪引发的广播风暴与链路频繁失效。在此基础上, 针对单一协议难以适应全场景需求的问题, 设计 QAS 算法以节点移动性、链路质量、网络密度和拥塞度为状态空间, 通过强化学习实时感知网络状态并智能选择最优协议, 实现 OLSR-C 与 AODV-MFW 的动态互补, 进一步提升网络整体性能。

1.4 论文章节安排

本文总体分为四章, 整体结构安排如下:

第一章为绪论。作为全文的开篇, 首先阐述了本课题的研究背景与意义, 梳理了国内外相关无人异构网络领域的研究现状, 在此基础上明确了论文的研究内容, 并概述了全文的组织架构, 为后续研究奠定了方向性基础。

第二章为相关理论基础, 系统介绍了本文所涉及的核心理论与技术工具。具体包括相关协议、强化学习的基本原理、LSTM 神经网络的结构与特性, 以及 NS-3 仿真工具与网络性能评价指标的相关内容。本章为后续两章的算法设计与实验验证提供了理论支撑。

第三章为基于 LSTM-Attention 的自适应垂直切换算法研究, 是本文的第一个核心研究内容。本章首先分析了传统垂直切换算法的局限性, 包括切换滞后、切换判决不够准确、无法预测未来状态以及固定权重导致适应性差等问题。为解决上述不足, 设计了基于堆叠 LSTM 的网络状态预测模块和 Multi-Head Attention 动态权重生成模块, 并在此基础上提出了基于改进 TOPSIS 的垂直切换决策方法。最后通过仿真实验和消融实验, 从平均切换次数、平均吞吐量、丢包率和平均端到端时延等指标对算法的有效性进行了全面验证与分析。

第四章为基于 Q-Learning 的自适应路由协议切换算法研究, 是本文的第二个核心研究内容。本章首先分析了 OLSR 和 AODV 路由协议在网络中的局限性, 指出泛洪消息造成资源浪费、控制消息包造成资源消耗、以及不同密度下协议效果差异较大等问题。针对这些问题, 分别提出了基于控制消息发送策略改进的 OLSR-C 协议研究和基于多因素改进的 AODV-MFW 协议研究。在此基础上, 设计了基于 Q-Learning 的自适应路由协议切换算法, 使网络能够根据实时状态智能选择最优路由协议。最后通过仿真实验, 从平均吞吐量、平均端到端时延和丢包率三个维度对算法性能进行了验证与分析。

最后对研究内容进行总结，并展望未来可能研究方向。
全文内容结构如图 1-4 所示。




图 1-4 全文内容结构

第 2 章 相关理论基础

本章概述垂直切换与路由协议基础理论，涵盖垂直切换决策模型、OLSR 和 AODV 路由协议工作原理、强化学习理论框架以及 LSTM 神经网络结构。为后续研究提供理论基础。

2.1 协议原理

2.1.1 垂直切换阶段介绍

垂直切换过程通常分为切换触发、切换判决和切换执行三个阶段^[44]，如图 2-1 所示。




图 2-1 垂直切换过程

切换触发阶段负责监测网络状态参数，判断是否满足启动切换判决的条件。常用的触发机制包括基于信号强度阈值的触发、基于服务质量劣化的触发以及基于用户请求的触发等。当监测参数超出预设阈值时，触发后续的切换判决过程。

切换判决阶段是垂直切换的核心环节，负责从多个候选网络中选择最优目标网络。判决算法需要综合考虑信号质量、网络负载、传输带宽、时延、费用、用户偏好等多种因素^[44]。常用的判决方法包括基于单一指标的简单比较法、基于多属性决策的综合评价法以及基于机器学习的智能决策法等。

切换执行阶段负责完成从当前服务网络到目标网络的实际切换操作，包括与目标网络建立连接、进行身份认证、更新路由信息、迁移数据会话等步骤^[45]。切换执行的效率直接影响切换时延和数据丢失率。

2.1.2 路由协议工作原理

不同的路由协议在设计理念、资源消耗和适用场景上存在显著差异，深入理解其工作原理对于后续章节的协议改进具有重要意义。

主动式路由协议又称表驱动路由协议，其核心思想是网络中的每个节点持续维护到达所有其他节点的路由信息。节点通过周期性地交换控制消息来更新路由表，确保在任意时刻都能获得全网的拓扑视图^[46]。

以 OLSR 协议为例，协议的核心工作机制包括邻居发现和拓扑信息扩散两个过程。在邻居发现阶段，节点周期性广播 HELLO 消息，通过接收邻居节点的 HELLO 消息建立一跳和二跳邻居表。基于邻居信息，节点从一跳邻居中选举多点中继（Multipoint Relay, MPR）节点，MPR 节点需满足能够覆盖所有二跳邻居的最小集合条件^[45]。在拓扑信息扩散阶段，MPR 节点周期性生成并转发拓扑控制（Topology Control, TC）消息，TC 消息中包含 MPR 选择器集合信息。通过 TC 消息在全网的扩散，每个节点都能构建完整的网络拓扑图，并基于最短路径算法计算到达任意目的节点的路由。OLSR 协议的工作流程如图 2-2 所示。




图 2-2 OLSR 协议工作示意图

反应式路由协议仅在有需要数据传输需求时才发起路由发现过程，不主动维护全网路由信息。

以 AODV 路由协议为例，协议的工作过程包括路由发现和路由维护两个阶段。当源节点需要向目的节点发送数据但本地路由表中无有效路由时，发起路由

发现过程：源节点广播路由请求（Route Request, RREQ）消息，中间节点收到 RREQ 后检查是否为目的节点或是否有到目的节点的有效路由，若无则继续广播 RREQ^[48]。当 RREQ 到达目的节点或具有有效路由的中间节点时，该节点沿反向路径单播路由回复（Route Reply, RREP）消息，RREP 消息经过的中间节点依次建立到目的节点的正向路由。在路由维护阶段，节点通过周期性交换 HELLO 消息检测邻居链路状态，当检测到链路断裂时，生成路由错误消息通知相关节点删除失效路由^[49]。AODV 协议的路由发现过程如图 2-3 所示。




图 2-3 AODV 协议路由发现流程图

2.2 强化学习

2.2.1 强化学习框架

强化学习作为机器学习领域的重要分支，在学习模式上与监督学习、无监督学习存在明显差异，其核心思路是在特定的交互环境中训练智能体 Agent，使其自主选择合理动作，最终实现累积奖励的最大化。Bellman^[50]等提出的离散型最优控制理论，即马尔可夫决策过程（Markov Decision Processes, MDP），为强化学习问题的形式化定义提供了基础理论框架。在强化学习体系中，普遍采用 MDP 模型描述智能体与环境的交互过程：智能体通过执行动作改变自身状态，并依据环境反馈的奖励与惩罚信号不断迭代学习，整体目标是获得最大化的长期收益^[51]。此后，Deepmind^[52]团队对传统 Q-Learning 算法进行了改进与升级，通过引入卷积神经网络实现特征提取与价值函数拟合，提出深度 Q 网络模型，进一步推动了强化学习技术的发展与应用。

图 2-4 呈现了强化学习的核心模型架构，该模型中智能体 Agent 与外部环境持续交互并执行相应动作。环境的状态会因智能体所采取的动作发生改变，随后

智能体从环境中接收两类关键信息：一是环境更新后的新状态，二是与环境交互目标相关联的奖励反馈。在此过程中，智能体以获取最大化累计奖励为核心目标，结合当前获得的奖励与环境状态来决策下一步要执行的动作。但在与未知环境交互时，智能体需要通过不断尝试不同动作，收集更多环境状态与对应动作的奖励数据，以此为依据优化后续策略，从而更好地适应环境。基于这一学习过程，强化学习具备三个核心特征：试错性（通过尝试探索环境规律）、收益延迟性（收益并非即时获取，而是体现在后续场景或整体收益中）以及适应性（智能体持续利用环境反馈提升自身性能）。




图 2-4 强化学习基本模型

强化学习可划分为有模型学习与无模型学习两类范式。其中，有模型学习适用于环境模型已知的场景，该方法借助动态规划算法预测后续状态与奖励值，以此实现奖励最大化的目标；而无模型学习则针对环境模型未知的情况，通过从真实环境中采集状态与奖励的样本数据开展学习。智能体在学习过程中会逐步预判环境对自身执行动作的反馈结果，进而推算出在未知环境中可执行的最优策略。考虑到无人自组网的环境会随时间推移和任务推进动态变化，因此在无人网络环境模型（涵盖状态集合、状态转移概率等网络性能参数）未知的场景下，采用无模型学习方法来探索最优策略更为适配。

无模型学习的核心算法主要包括蒙特卡洛强化学习和时序差分强化学习两类，二者的核心差异体现在策略更新机制上：蒙特卡洛方法需要完成一轮完整的采样流程后，才能对策略估计值进行更新；而时序差分方法允许智能体每执行一步动作就更新一次状态值，无需等待到达终止状态，因此时序差分方法的计算效率更高。此外，时序差分学习还可进一步细分为同策略的 SARSA 算法和异策略的 Q-Learning 算法。

2.2.2 马尔可夫决策模型

强化学习的核心目标是解决序贯决策相关问题^[51]，MDP 依托马尔可夫性构

建智能体与环境的交互模型，所谓马尔可夫性，是指系统下一时刻的状态仅由当前状态与所执行的动作决定，与此前的历史状态、动作序列均无关联。作为强化学习领域的基础数学建模工具，MDP 被用于定义强化学习中的值函数与状态值函数。它可以用五元组 $\langle S, A, P, R, \gamma \rangle$ 来描述。其中 S 表示状态空间，它包含了环境所有可能的状态。 A 是动作空间，它包含了 Agent 能够执行的所有动作。 P 表示状态转移概率，定义了从当前状态执行某个动作后转移到新状态的概率。 R 是奖励函数， γ 是折扣因子，表示未来奖励对当前奖励的重要性^[51]。

如图 2-5 所示，Agent 从初始状态 S_0 开始，执行动作 a_0 后转移到新状态 S_1 并获得奖励 r_0 ，然后继续执行动作 a_1 转移到状态 S_2 并获得奖励 r_1 ，如此进行下去，直到达到终止状态 S_n 。




图 2-5 MDP 表示强化学习

智能体 Agent 与环境保持持续交互，并在贪心选择与新动作探索之间进行权衡，最终目标是得到最优策略。策略的优劣，通过对比智能体在对应时刻采用不同策略所获得的累计奖励来评判。换言之，基于马尔可夫决策过程的强化学习，其核心目标是找到能让未来累计奖励最大化的策略。在实际应用里，受环境不确定性影响，未来累计奖励通常需要采用折扣方式进行计算。

因此，强化学习的求解过程本质上可看作对贝尔曼方程的优化。也就是说，最优策略的寻找问题，可以转化为求解状态值函数或动作值函数所对应贝尔曼方程的最大值问题，最优策略可通过最优状态值函数进行表示。在具体求解时，若 MDP 规模较小，可直接使用数学方法求解；而对于规模较大的 MDP，直接求解并不现实，此时可采用动态规划、蒙特卡洛、时序差分等迭代方法进行近似求解。

2.3 LSTM 神经网络

1997 年，Hochreite 与 Schmidhuber 针对循环神经网络存在的梯度消失难题展开研究，首次提出长短期记忆 LSTM 神经网络这一改进模型^[53]。作为循环神经网络的特殊变体，LSTM 尤其擅长处理时间序列、文本序列等各类序列型数据。相较于传统循环神经网络，LSTM 在结构上增加了单元状态在相邻时刻的变化信息作为输入维度，能够有效调控长时序数据中关键信息的传递过程，从而解决了循环神经网络因网络层数加深而出现的梯度异常问题。

在 LSTM 神经网络的运行过程中，隐藏层神经元之间的信号传递需要依托遗忘门、输入门和输出门这三类精心设计的门控结构协同运作，以此实现对信息

的精准保留与舍弃,让网络具备长期记忆的能力。其中,遗忘门是核心组件之一,其核心作用在于评估各类信息的价值:筛选并保留对当前场景仍有参考意义的关键数据,同时及时剔除失效或无关的冗余信息,以此提升数据处理的效率。这一机制不仅能保障系统的高效运行、聚焦核心信息以减少无效数据干扰,还能有效缓解梯度爆炸或梯度消失等训练过程中的常见问题,进而精准提取时间序列数据中的核心特征。输入门则会结合当前时刻的输入数据与上一时刻的隐藏层状态,控制新信息融入单元状态的过程,完成网络记忆的动态更新;输出门的作用是决定当前时间步下,单元状态中的哪些信息需要输出至隐藏状态,进而影响网络的最终输出结果。图 2-6 展示了 LSTM 的网络模型。当中 σ 是 $sigmoid$ 激活函数,同样 $\tanh$ 也是激活函数, W 是权重矩阵, $\cdot$ 是点对积。




图 2-6 LSTM 网络模型

遗忘门 f_t 的输入参数是上一时刻的隐藏状态 H_{t-1} 和长序列特征向量 L_t , 其表达式为公式 (2-1)。

$$f_t = \sigma(W_f \cdot [H_{t-1}, L_t] + b_f) \quad (2-1)$$

其中, W_f 是遗忘门权重, b_f 是遗忘门偏置。

输入门 i_t 和遗忘门 f_t 具有类似输入参数, 表达式见公式 (2-2)。

$$i_t = \sigma(W_i \cdot [H_{t-1}, L_t] + b_i) \quad (2-2)$$

其中, W_i 是相应的权重, b_i 是相应的偏差。

当前单元状态 C_t , 其输入参数包括遗忘门的输出 f_t 、输入门的输出 i_t 、前一时刻的单元状态值 C_{t-1} 和特征向量 L_t , 其表达式如公式 (2-3)。

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tanh(W_c \cdot [H_{t-1}, L_t] + b_c) \quad (2-3)$$

其中, W_c 是相应的权重, b_c 是相应的偏差。

输出门为 o_t , 输入参数为前一时刻隐藏状态 H_{t-1} 和特征向量 L_t , 其表达式如公式 (2-4)。

$$o_t = \sigma(W_o \cdot [H_{t-1}, L_t] + b_o) \quad (2-4)$$

其中, W_o 是输出门的权重, b_o 是输出门的偏置。

更新 H_t 后的当前隐藏状态, 其表达式如公式 (2-5)。

$$H_t = o_t \cdot \tanh(C_t) \quad (2-5)$$

LSTM 神经网络与传统神经网络的训练逻辑存在诸多共通点: 二者均采用反向传播算法, 依托链式法则处理网络内部的非线性关联, 以此精准定位核心梯度方向; 并通过计算损失函数对各权重参数的偏导数来迭代优化参数, 最终实现最优的训练效果。不过, LSTM 在反向传播的实现形式上有明显区别。其训练过程中产生的误差不仅会在网络的层级维度向前一层传递, 还会在时间维度上反向传播, 进而影响此前各时间步的权重调整。这种兼具层级和时间维度的双向传播机制, 使得 LSTM 能够有效应对包含长期依赖关系的序列数据, 更精准地挖掘数据的内在规律, 从而提升预测与分类任务的准确率。因此, 在训练 LSTM 网络时, 需重点关注其时间维度上的反向传播过程, 确保网络能够充分挖掘序列数据中的长期依赖信息, 最终提升模型的预测精度与泛化能力。

2.4 NS-3 网络仿真器与网络性能评价指标

本小节围绕 NS-3 网络仿真器展开, 详细阐述了其核心工作机制与基础应用场景, 同时明确了用于评估路由协议性能的核心指标。具体而言, 这些指标涵盖吞吐量、平均端到端时延以及丢包率。通过将 NS-3 仿真器与上述性能评估指标相结合, 能够为后续路由协议与算法的设计优化及效果评估, 提供精准且可靠的数据支撑。

2.4.1 NS-3 离散事件网络仿真器

NS-3 是一款面向科研与教学场景的网络仿真工具, 其核心代码基于 C++ 开发, 同时提供了 Python 语言的绑定接口, 因此仿真脚本既可以用 C++ 编写, 也能通过 Python 实现, 大幅降低了测试过程中的调试难度。Manzoor^[54]与 handerao^[55]等人在相关研究中对当前业界主流的各类网络仿真器, 并形成了全面的仿真工具对比综述; 多篇同类研究结论均表明, NS-3 是各类测试场景下表现最为出色的网络仿真器。此外, NS-3 还具备良好的跨软件扩展兼容性, 例如 NS3-AI^[56]框架便实现了 NS-3 与强化学习相关工具的集成适配。

NS-3 的仿真功能依托时序化事件列表的调度与处理来实现。其整体仿真流程如图 2-7 所示, 用户在仿真前需要完成网络模型的完整搭建, 涉及各类网络节点 (如无人机、交换机)、网络硬件设备 (如网卡)、传输信道 (如有线链路)、网络协议栈 (如 MAC 协议、路由协议) 以及业务数据包 (如 Hello 报文) 等核

心组件。除此之外，NS-3 还提供了配套的功能对象，可用于随机数生成与额外信息的存储。仿真启动后，模拟器会依次遍历待触发的事件，同步更新仿真时间并调用对应的处理程序；由处理程序触发的新事件会被动态加入事件列表，且 NS-3 的仿真时间与真实时间相互独立、互不关联。




图 2-7 NS-3 工作流程图

NS-3 仿真平台内置了专用的跟踪子系统，支持 PCAP 等通用数据格式完成数据采集与记录，方便用户借助 Wireshark 等工具开展后续分析。用户还可根据自身需求修改跟踪接收器，实现自定义数据输出格式的扩展。此外，NS-3 同样支持可视化调试，其 Animation Interface 模块可对仿真测试数据进行收集，并在仿真结束后通过图形界面，直观展示网络节点的移动状态与数据发送过程。凭借上述功能，NS-3 成为能够适配多种科研与教学需求的优质网络仿真模拟器。

2.4.2 性能评价指标

为了方便评估仿真涉及的性能，使用了以下三个性能指标：

（1）平均吞吐量

吞吐量^[57]表示网络中成功传输数据的总速率，一般用于衡量网络的传输能力。指标反映了网络在单位时间内能够传输的有效数据量，单位为比特每秒。

$$Throughput = \frac{\sum_{i=1}^{N_r} S_i * 8}{T} \quad (2-6)$$

其中， N_r 表示在时间 T 内成功传输的数据包总数， S_i 表示第 i 个数据包，单位为字节（Byte）， T 表示总时间，单位为秒。

（2）平均端到端时延

平均端到端时延^[57]代表数据包从源节点到目的节点的平均传输时间，其中包括传输时延、排队时延和传播时延等，单位为毫秒。

$$EED = \frac{\sum_{i=1}^{N_r} [T_r(i) - T_s(i)]}{N_r} \quad (2-7)$$

其中, $T_r(i)$ 和 $T_s(i)$ 表示第 i 个数据包的接收时间和发送时间。

(3) 丢包率

丢包率^[58]代表网络中未成功传输的数据包数量与源节点发送的数据包总数的比率, 可用于衡量网络的传输可靠性, 定义单位为百分比。

$$PDR = \frac{N_s - N_r}{N_s} * 100\% \quad (2-8)$$

其中, N_s 表示源节点一共发送的数据包总数。

2.5 本章小结

本章阐述了垂直切换三阶段决策模型及 OLSR 和 AODV 路由协议的基本原理, 并深入探讨了 LSTM 神经网络的结构特点与门控机制。对强化学习的基本理论进行了简要阐述, 引入并解析了马尔可夫决策过程, 旨在为后续章节中自适应垂直切换算法与路由协议切换算法的设计与实现提供一个全面而稳固的理论支撑与知识铺垫。

第3章 基于 LSTM-Attention 的自适应垂直切换算法研究

本章提出基于 LSTM-Attention 的自适应垂直切换算法 LAAVHA。该算法采用监督学习与多属性决策相结合的技术路线：利用长短期记忆网络对网络状态参数进行时序预测；通过多头注意力机制动态计算各网络属性的权重，适应不同场景需求；最后使用 TOPSIS 方法进行最优网络选择，同时引入切换滞后机制避免乒乓切换。LAAVHA 具有训练简单、实时性好、可解释性强等优点。其主要包含三个核心模块：LSTM 网络状态预测模块、Attention 动态权重生成模块和改进 TOPSIS 网络选择模块。仿真实验和消融实验结果表明，所提出的 LAAVHA 算法展现出优异的性能。在平均切换次数、平均吞吐量、平均端到端时延及丢包率等核心指标上显著优于相关协议，充分验证了方案的有效性与实用性。本章内容结构如图 3-1 所示。




图 3-1 本章内容结构

3.1 传统垂直切换算法局限性分析

垂直切换是无人异构网络中实现无缝移动性管理的关键技术。根据决策方法的不同,现有垂直切换算法可分为基于 RSS 的切换算法、基于多属性决策的切换算法和基于机器学习的切换算法。

基于 RSS 的切换算法是最早也是最简单的垂直切换方法,当目标网络的 RSS 超过当前网络一定阈值时触发切换。然而,该方法仅考虑单一指标,难以适应复杂的网络环境,容易导致频繁的乒乓切换^[59]。

多属性决策方法能够综合考虑多个网络属性进行切换决策。其中 TOPSIS 是一种经典的无人网络垂直切换算法,近年来众多学者基于 TOPSIS 演变出了许多改进算法。Abdullah^[60]等提出了增强型 TOPSIS 垂直切换算法,考虑了 RSS、网络使用率等参数,相比传统 RSS 方法减少了 60% 的切换次数。Ndegwa^[61]等提出了基于用户偏好的 MADM 切换算法,利用模糊 AHP 方法计算属性权重,实现了较低切换率。Chen^[62]等将 TOPSIS 方法应用于高速铁路切换场景,有效提高了切换成功率。然而,传统 MADM 方法的属性权重通常是预先设定的,难以适应动态变化的网络环境。

随着机器学习的技术在近年来广泛兴起,相关现有研究应用于垂直切换决策。Kaur^[63]等提出了 LSTM-SVM 混合切换算法,利用 LSTM 预测移动设备参数, SVM 进行网络选择,预测精度达到较高水平。Kim^[64]等利用深度强化学习实现了无人机的主动切换决策,减少了较多的不必要切换。然而,强化学习方法需要大量的环境交互进行训练,实时性较差。

针对上述局限性,本章提出一种基于 LSTM-Attention 的无人异构网络自适应垂直切换算法。该算法采用监督学习与多属性决策相结合的方法,首先利用 LSTM 网络对网络状态参数进行时序预测;然后通过注意力机制动态计算各网络属性的权重,适应不同需求;最后结合改进的 TOPSIS 方法进行最优网络选择。与强化学习方法相比, LAAVHA 具有训练简单、实时性好、可解释性强等优点。

3.2 基于堆叠 LSTM 的网络状态预测

为实现精准的切换决策,需要对未来时刻的网络状态进行准确预测。传统的被动式切换方法仅根据当前时刻的网络状态进行决策,往往导致切换延迟、服务中断等问题。本节详细介绍基于堆叠 LSTM 的网络状态预测模块,通过利用历史网络状态数据的时序特性,预测未来短期内的网络参数变化,为切换决策提供前瞻性信息。该模块包括网络状态参数建模、数据预处理方法和 LSTM 网络结构设计三个关键部分。

3.2.1 网络系统模型

本章考虑传统网络场景，无人机和无人车在多种网络覆盖范围内自由移动。如图 3-2 所示。




图 3-2 无人网络场景

图中包含 3 种无线接入网络，分别记为 5G、长期演进（Long Term Evolution, LTE）和无线局域网（WiFi）。各类网络具有不同的覆盖范围、传输能力和服务特性：5G 提供高带宽、低时延的广域覆盖；LTE 作为成熟技术提供可靠的中等带宽服务；WiFi 在热点区域提供高速率的局部覆盖。无人节点在运动过程中可以接入任意一个可用网络，并根据网络状态和实时位置进行垂直切换。

现假设无人节点在 t 时刻的三维位置为 $p(t) = \{x(t), y(t), z(t)\}$ 。节点与第 i 个网络的基站或接入点之间的距离为：

$$d_i(t) = \sqrt{(x(t) - (x_i^{BS}))^2 + (y(t) - (y_i^{BS}))^2 + (z(t) - (z_i^{BS}))^2} \quad (3-1)$$

其中， $p_i^{BS} = \{x_i^{BS}, y_i^{BS}, z_i^{BS}\}$ 为第 i 个网络基站的位置坐标。此外考虑信道模型，无人节点与地面基站之间的路径损耗由视距（Line-of-Sight, LoS）和非视距（Non-Line-of-Sight, NLoS）两部分组成^[65]。

$$PL_i(t) = P_{LoS}(t) * PL_i^{LoS}(t) + P_{NLoS}(t) * PL_i^{NLoS}(t) \quad (3-2)$$

其中， $P_{LoS}(t)$ 和 $P_{NLoS}(t)$ 分别为 LoS 和 NLoS 的概率，与无人节点高度、仰角及环境参数相关。根据 3GPP TR 36.777 标准规定^[66]。

LOS 和 NLoS 路径损耗可以近似表示为：

$$PL_i^{LoS}(t) = 20 \log_{10} \left(\frac{4\pi f_c d_i(t)}{c} \right) + \eta_{LoS} \quad (3-3)$$

$$PL_i^{NLoS}(t) = 20 \log_{10} \left(\frac{4\pi f_c d_i(t)}{c} \right) + \eta_{NLoS} \quad (3-4)$$

其中, f_c 为载波频率, c 为光速, η_{LoS} 为 LoS 附加损耗, η_{NLoS} 为 NLoS 附加损耗。

3.2.2 网络状态参数建模

为平衡状态表征的完整性与仿真实现的可行性, 本章选取 5 个核心参数构建网络状态向量。这些参数从不同维度反映了无线网络的服务质量, 涵盖了信号质量、传输性能和可靠性三个方面。参数的选取遵循以下原则: 首先, 参数应能够直接反映用户体验和应用需求; 其次, 参数应具有可测量性, 能够通过标准的网络监测机制获取; 第三, 参数之间应具有一定的独立性, 避免信息冗余。对于第 i 个候选网络, 在 t 时刻的状态向量定义为:

$$S_i(t) = [SINR_i(t), RSRP_i(t), D_i(t), T_i(t), PLR_i(t)] \quad (3-5)$$

各参数含义如下:

(1) 信号与干扰加噪声比 ($SINR$)

$SINR$ 是衡量信道质量的关键指标, 定义为有用信号功率与干扰信号功率及噪声功率之和的比值, 单位为 dB。 $SINR$ 直接决定了无线链路能够支持的调制编码方案, 进而影响可达传输速率。

(2) 参考信号接收功率 ($RSRP$)

$RSRP$ 反映无人节点接收到的信号强度, 单位为 dBm。在 LTE 和 5G 系统中, $RSRP$ 定义为承载小区专用参考信号的资源元素功率的线性平均值。 $RSRP$ 的大小主要取决于基站发射功率和路径损耗, 是判断网络覆盖状况的重要依据。在垂直切换决策中, $RSRP$ 是判断目标网络是否具有足够覆盖的首要条件。

(3) 传输时延 (D)

传输时延表示数据包从发送端到接收端的平均端到端时延, 单位为秒。时延由多个组成部分构成: 传播时延取决于传输距离; 传输时延取决于数据包大小和链路带宽; 排队时延取决于网络负载和缓冲区状态; 时延是最关键的服务质量指标。在切换决策中, 目标网络的时延特性需要满足应用的时延约束。

(4) 吞吐量 (T)

吞吐量表示单位时间内成功传输的数据量, 单位为 Mbps。吞吐量是衡量网络传输能力的综合指标, 受信道质量、网络负载、协议开销等多种因素影响。

(5) 丢包率 (PLR)

丢包率表示数据传输过程中丢失的数据包比例, 取值范围为 [0,1]。丢包可能由多种原因导致: 网络拥塞导致缓冲区溢出; 切换过程中的服务中断等。丢包率直接影响传输可靠性和用户体验。在垂直切换决策中, 丢包率是评估网络稳定性

的重要依据。

3.2.3 数据预处理与预输入构建

原始网络状态参数具有不同的量纲和数值范围，直接用于模型训练会导致某些参数因数值较大而主导模型学习过程，影响预测准确性。为保证模型训练的稳定性和收敛性，需要对原始数据进行归一化处理。本章采用 Min-Max 归一化方法，该方法通过线性变换将各属性值映射到[0,1]区间，保持了数据的相对分布特性，同时消除了量纲差异。具体公式如下：

$$\hat{s}_i^j(t) = \frac{s_i^j(t) - s_{min}^j}{s_{max}^j - s_{min}^j} \quad \hat{s}_i^j(t) = 1 - \frac{s_i^j(t) - s_{min}^j}{s_{max}^j - s_{min}^j} \quad (3-6)$$

其中， $s_i^j(t)$ 为原始值， s_{min}^j 和 s_{max}^j 为第 j 个属性的最小值和最大值。因为网络状态参数中存在效益型属性（*SINR*、*RSRP*、吞吐量，越大越好）和成本型属性（时延、丢包率，越小越好）。对成本型属性进行方向转换，使所有属性统一为值越大表示网络质量越好。

LSTM 网络的输入需要组织为时序序列形式。将过去 T 个时间步的归一化状态数据组织为输入序列，其中 T 为时间窗口长度，5 为状态参数维度。时间窗口 T 的选择需要在信息量和计算复杂度之间取得平衡：窗口过短会丢失重要的历史信息，导致预测准确性下降；窗口过长会增加计算开销，同时可能引入与当前状态相关性较弱的过时信息。设置正确的参数能够有效捕获网络状态的短期变化趋势，同时保持较低的计算复杂度。

$$X_i = [\hat{S}_i(t - T + 1), \hat{S}_i(t - T + 2), \dots, \hat{S}_i(t),] \in R^{T \times 5} \quad (3-7)$$

其中，通过交叉验证确定时间窗口 T 的最优值，在信息量和计算复杂度之间取得平衡。

3.2.4 堆叠 LSTM 网络结构设计

长短期记忆网络是一种特殊的循环神经网络，通过引入门控机制有效解决了传统循环神经网络的梯度消失和梯度爆炸问题，特别适合处理长序列的时序预测任务^[67]。本文采用两层堆叠 LSTM 网络进行网络状态预测，其网络结构如图 3-3 所示。




图 3-3 两层堆叠 LSTM 网络

LSTM 单元包含三个门控结构：遗忘门决定从细胞状态中丢弃哪些信息；输入门决定哪些新信息将被存储；输出门决定输出哪些信息。三个门通过激活函数输出 0 到 1 之间的值，控制信息的通过比例。细胞状态的更新采用加法操作，使重要信息能够长期保持。具体在第二章已经做了详细讲述。

本文提出的 LSTM 网络的具体配置为：第一层 128 个隐藏单元，负责提取低层次时序特征；第二层 64 个隐藏单元，提取高层次抽象特征。两层之间添加 Dropout 层防止过拟合。第二层的最后时刻输出经全连接层映射为预测状态：

$$\hat{S}_i(t + \Delta t) = W_{out} * h_T^2 + b_{out} \quad (3-8)$$

其中， Δt 为预测时间间隔。数据集来源于真实仿真过程记录。原始数据被划分为训练集、验证集和测试集，比例分别为 80%、10% 和 10%。模型采用均方误差作为损失函数，并使用 Adam 优化器进行训练，该优化器结合了动量法和自适应学习率的优点，能够确保收敛过程既快又稳。此外，训练过程引入了早停策略，若验证集损失连续 10 个 epoch 不再下降则停止训练。

3.3 基于 Multi-Head Attention 的动态权重生成

传统的 MADM 采用固定权重进行网络属性评价，这种方法存在明显的局限性。固定权重无法适应动态变化的网络环境和多样化的任务需求：当无人节点高速运动时，信道条件快速变化，信号质量指标的重要性应当提高；当执行大数据量传输任务时，吞吐量指标的重要性应当突出；当执行实时控制任务时，时延指标应当被优先考虑。因此，需要一种能够根据上下文动态调整权重的方法。本节引入 Multi-Head Attention 机制，实现属性权重的自适应生成，使切换决策能够

灵活适应不同的场景和需求。

3.3.1 注意力机制原理

注意力机制的核心思想是为输入的不同部分分配不同的权重，使模型聚焦于最相关的信息^[68]。注意力机制允许序列中的每个元素与其他元素交互，捕获全局依赖关系。

给定输入，注意力机制通过查询（ Q ）、键（ K ）和值（ V ）三个矩阵计算注意力输出：

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (3-9)$$

其中，缩放因子 $\sqrt{d_k}$ 防止点积结果过大导致梯度消失。此外公式中的 $softmax$ 函数将任意实数值映射为 0 到 1 之间的概率分布，计算公式为：

$$softmax(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}} \quad (3-10)$$

其中， $softmax$ 确保输出的注意力权重和为 1，且原始分数越高的位置获得越大的权重。多头注意力机制通过并行计算多组注意力，从不同表示子空间提取信息：

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h)W^O \quad (3-11)$$

其中， $head_i$ 为第 i 个注意力头的输出，每个头独立执行公式(3-9)的计算； h 为注意力头的数量，本章设置 $h = 4$ ； $Concat$ 表示拼接操作，将各头的输出横向连接； W^O 为输出投影矩阵，用于将拼接后的结果变换到目标维度，该矩阵在训练过程中学习得到。多头机制的优势在于不同的注意力头可以学习到不同的关注模式。例如，某个头可能学会关注信号质量相关的参数，另一个头可能更关注传输性能参数，最终融合得到更全面的特征表示。

3.3.2 动态权重生成网络

动态权重生成网络结构如图 3-4 所示。




图 3-4 动态权重生成网络结构

输入包括当前网络状态矩阵 $S_{cur} \in R^{K \times 5}$ ，包含 K 个候选网络的 5 维状态参数和移动状态向量 $f_{mob} = v(t), z(t)$ ，包括当前飞行速度和高度。移动状态反映了无人节点的动态特性，高速移动时信道变化剧烈，低速移动时信道相对稳定，不同移动状态下切换决策的关注重点有所不同。

网络首先对状态矩阵添加位置编码，增强位置信息。然后通过 Multi-Head Attention 层计算各属性间的相关性。将注意力输出进行平均池化后与移动状态特征拼接，经全连接层和 softmax 函数生成动态权重：

$$w = \text{softmax}(W_w [h_{pool}; f_{mob}] + b_w) \quad (3-12)$$

其中， $w = [w_1, w_2, w_3, w_4, w_5]$ 为输出的动态权重向量，分别对应 SINR、RSRP、时延、吞吐量、丢包率五个参数的权重； h_{pool} 为 Attention 输出经过平均池化后的特征向量； f_{mob} 为移动状态向量； $[h_{pool}; f_{mob}]$ 表示将两个向量纵向拼接； W_w 为全连接层的权重矩阵； b_w 为全连接层的偏置向量。 W_w 和 b_w 均为可学习参数，在训练过程中通过反向传播算法自动优化。最后输出权重向量 $w = [w_{SINR}, w_{RSRP}, w_D, w_T, w_{PLR}]$ ，满足 $w_{SINR} + w_{RSRP} + w_D + w_T + w_{PLR} = 1$ 。

LSTM 模块与 Attention 模块共同构成一个端到端的深度神经网络，在训练阶段一起优化。LSTM 模块的参数学习时序预测规律，Attention 模块的参数学习权重分配规律，两者协同工作使整体性能达到最优。通过这种动态权重机制，网络能够根据当前移动状态和网络条件自适应调整各参数的重要性权重。例如，当无人节点高速运动时信道变化剧烈，SINR 和 RSRP 等信号质量参数的权重会自动提高，以确保切换到信号稳定的网络；当无人节点低速运动且信号稳定时，吞吐量的权重会相应提高，以获得更好的传输性能。这种自适应机制相比传统固定权重方法具有更好的灵活性和环境适应性。

3.4 基于改进 TOPSIS 的垂直切换决策方法

本节在之前两个小节的基础上，设计垂直切换的最终决策模块，从给定 LSTM 预测的未来网络状态和 Attention 生成的动态权重上，选出多个候选网络中选出最优目标网络，并判断是否执行切换。本文选取 TOPSIS 垂直切换算法作为基础算法，其原因主要是 TOPSIS 的计算过程为确定性矩阵运算，不涉及迭代优化，计算复杂度低，满足无人节点实时切换决策对时效性的严格要求；且 TOPSIS 天然支持外部权重输入，能够与 Attention 模块生成的动态权重无缝对接，无需额外的权重融合机制。

3.4.1 融合决策矩阵构建

传统 TOPSIS 方法仅基于当前时刻的网络状态构建决策矩阵，这种被动式决策机制忽略了网络状态的变化趋势。在无人节点高速移动场景下，网络状态变化迅速，当前时刻的最优网络可能在切换完成后很快变为次优，导致频繁的二次切换。

本章提出的改进 TOPSIS 方法融合了当前状态和 LSTM 预测的未来状态，构建融合决策矩阵。对于 K 个候选网络和 M 个属性，融合决策矩阵 D 的元素定义为：

$$d_{ij} = \alpha * \hat{s}_i^j(t) + (1 - \alpha) * \hat{s}_i^j(t + \Delta t) \quad (3-13)$$

其中， $\hat{s}_i^j(t)$ 为当前时刻归一化值， $\hat{s}_i^j(t + \Delta t)$ 为 LSTM 预测的未来时刻值， $\alpha \in [0,1]$ 为融合系数。本章通过实验确定最优融合系数为 α ，在大多数场景下能够取得良好的平衡。

3.4.2 TOPSIS 网络选择流程

基于融合决策矩阵和动态权重，改进 TOPSIS 的计算流程包括以下五个步骤。

(1) 向量归一化

由于不同属性具有不同的量纲和数值范围，需要对融合决策矩阵进行归一化处理。本章采用向量归一化方法，该方法保持了各方案之间的相对比例关系。归一化公式为：

$$r_{ij} = \frac{d_{ij}}{\sqrt{\sum_{k=1}^K d_{kj}^2}} \quad (3-14)$$

其中， r_{ij} 为归一化后的值； d_{ij} 为融合决策矩阵的元素； K 为候选网络数量。分母

为第 j 个属性所有网络值的平方和开根号，确保归一化后各属性的向量模长为1。

(2) 加权归一化

利用 Attention 模块生成的动态权重向量计算加权归一化矩阵：

$$v_{ij} = w_j * r_{ij} \quad (3-15)$$

其中， v_{ij} 为加权归一化后的值； w_j 为第 j 个属性的动态权重，由 Attention 模块根据当前网络状态和移动状态自适应生成。通过加权操作，不同属性根据其在当前场景下的重要性对最终决策产生不同程度的影响。

(3) 确定理想解

正理想解由各属性的最优值组成，代表理论上最好的网络状态： $v_j^+ = \max(v_{ij})$ ；负理想解由各属性的最差值组成，代表理论上最差的网络状态： $v_j^- = \min(v_{ij})$ 。

(4) 计算距离

计算各候选网络到正负理想解的欧氏距离：

$$D_i^+ = \sqrt{\sum_{j=1}^M (v_{ij} - v_j^+)^2} \quad D_i^- = \sqrt{\sum_{j=1}^M (v_{ij} - v_j^-)^2} \quad (3-16)$$

其中， D_i^+ 为第 i 个网络到正理想解的距离； D_i^- 为第 i 个网络到负理想解的距离； M 为属性数量。距离越小表示与对应理想解越接近。

(5) 计算相对贴近度

综合距离计算各网络的相对贴近度：

$$C_i = \frac{D_i^-}{D_i^+ + D_i^-} \quad (3-17)$$

其中，相对贴近度 $C_i \in [0,1]$ ，值越大表示网络质量越好。选择相对贴近度最大的网络作为目标网络。

3.4.3 切换决策与滞后机制

在实际无线环境中，网络状态参数会受到信道衰落、干扰等因素的影响而产生波动。如果每次检测到更优网络就立即触发切换，会导致频繁的乒乓切换，增加信令开销和切换失败风险。为解决这一问题，设计了双重滞后机制：

(1) 贴近度阈值滞后

仅当目标网络的相对贴近度超过当前服务网络一定阈值时，才满足切换的必

要条件:

$$N_{NET} = \begin{cases} \text{切换到} N^*, & \text{if } C_{N^*} - C_{N_{cur}} > \Delta_{th} \\ \text{保持} N_{cur}, & \text{其他} \end{cases} \quad (3-18)$$

其中, N_{NET} 代表节点连接的网络, N_{cur} 为当前服务网络, N^* 代表当前最优网络; C_{N^*} 和 $C_{N_{cur}}$ 分别为最优网络和当前网络的相对贴近度; Δ_{th} 为切换阈值。

(2) 时间窗口滞后

为进一步提高切换决策的稳定性, 引入时间窗口机制。只有当连续多个决策周期都满足贴近度阈值条件时, 才最终执行切换。这一机制能够有效过滤由瞬时信道波动引起的虚假切换触发, 减少不必要的切换操作。

3.4.4 LAAVHA 算法流程

TOPSIS 模块本身不包含可学习参数, 仅执行确定性的数学计算。算法的学习能力完全来自 LSTM 和 Attention 两个神经网络模块, 它们在训练阶段通过端到端的方式联合优化, 学习预测网络状态变化趋势和根据场景动态调整权重的能力。在推理阶段, 训练好的模型参数固定, 三个模块协同工作完成切换决策。在综合三大模块后提出的 LAAVHA 算法伪代码如下:

表 3-1 LAAVHA 垂直切换算法

LAAVHA 垂直切换算法
输入: 历史网络状态序列 $\{\hat{S}_i(t-T+1), \dots, \hat{S}_i(t)\}_{i=1}^K$, 移动状态 f_{mob} , 当前服务网络 N_{cur} 输出: 切换决策和目标网络 N^*
1: for 每个候选网络 $N_i, i = 1, \dots, K$ do 2: 对历史状态数据进行归一化预处理 3: 通过堆叠 LSTM 网络预测未来状态 $\hat{S}_i(t + \Delta t)$ 4: end for 5: 构建当前网络状态矩阵, 添加位置编码 6: 通过 Multi-Head Attention 计算属性相关性 7: 融合上下文特征, 生成动态权重 w 8: for 每个候选网络和属性 do

```

9:      计算融合决策值  $d_{ij} = \alpha * \hat{s}_i^j(t) + (1 - \alpha) * \hat{s}_i^j(t + \Delta t)$ 
10: end for
11: 执行 TOPSIS 计算: 向量归一化→加权归一化→确定理想解→计算距离→计算贴近
    度
12: 选择最优网络  $N^*$ 
13: if  $C_{N^*} - C_{N_{cur}} > \Delta_{th}$  then
14:   return (切换,  $N^*$ )
15: else
16:   return (保持,  $N_{cur}$ )
17: end if

```

3.5 仿真验证与分析

为了验证 LAHVHA 算法的性能, 以仿真期间统计的平均切换次数, 全面对比了基于多因素垂直切换算法^[69] (Multi-factor vertical switching algorithm, Muti-VSA)、基于深度强化学习的接收信号强度决策算法^[70] (Deep Reinforcement Learning-based Received Signal Strength, DRL-based RSS) 和基于 Q-learning 的 TOPSIS 算法即 TOPSIS-Q^[71]。此外进行除开 LSTM 网络状态预测模块和 Attention 动态权重生成模块的消融实验, 算法名称定义为 LAHVHA-L 和 LAHVHA-A。

3.5.1 仿真平台与环境配置

基于 NS-3 离散事件网络仿真器搭建仿真环境。采用高斯马尔可夫移动模型的无人节点在未知场景中随机移动, 三维空间场景大小为 2000m*2000m*200m。

表 3-2 仿真参数设置

仿真参数	参数值	仿真参数	参数值
仿真软件	NS3.31	节点速度	5-30m/s
数据包大小	1024Byte	节点数量	50-350
仿真时长	100S	仿真区域	2000m*2000m* 200m
数据包发送方式	固定比特率	切换周期	0.1S
传输层协议	UDP	传输范围	200m

物理层协议	802.11g	传输功率	20dBm
候选网络	5G,LTE,WIFI	Attention 数	4
时间窗口	10	融合系数	0.6

3.5.2 仿真结果分析

仿真过程中,节点采用随机移动方式,如图 3-5 所示: t_1 时刻无人机处于 5G 与 LTE 网络的重叠覆盖区域内,经仿真时采用的算法决策后选择接入 LTE 网络,无人车在 5G、WIFI 和 LTE 网络信号范围内经算法计算选择连接 WIFI 网络。节点持续运动一段时间后,受位置变迁及各网络服务质量动态差异的影响, t_2 时刻无人机和无人车均切换为 5G 网络以提升整体通信质量。




图 3-5 网络连接示意图

(1) 速度恒定

首先在设置了节点速度恒定为 20m/s 移动情况下,先以节点数量由低到高从 50 到 350 的网络场景来验证四种垂直切换算法的性能表现。

由图 3-6 可知,四种算法的平均切换次数均随节点数量的增加呈上升趋势,但各算法的增长幅度存在显著差异。在低节点密度场景下,LAHVHA 仅产生 8 次切换,分别比 Muti-VSA 的 15 次、DRL-based RSS 的 18 次和 TOPSIS-Q 的 20 次分别低 46.7%、55.6%和 60.0%。随着节点数量增至 350 时,各算法切换次数均大幅上升,DRL-based RSS 达到 65 次,Muti-VSA 为 61 次,TOPSIS-Q 为 54 次,而 LAHVHA 仅为 27 次,分别低了 58.5%、55.7%和 50.0%。值得注意的是,

LAHVHA 算法在全部场景下均保持最低切换次数且增长最为平缓，其优势主要源于堆叠 LSTM 预测模块实现主动式切换决策避免被动响应，Multi-Head Attention 机制根据实时状态自适应调整属性权重避免固定权重的局限性，以及双重滞后机制有效过滤信道瞬时波动引起的虚假切换触发，三者协同显著抑制了乒乓切换现象。




图 3-6 不同节点规模下平均切换次数对比

由图3-7可知，四种算法的平均端到端时延均随节点数量的增加呈上升趋势。在低节点密度场景下，LAHVHA 时延为 0.28s，相对于 Muti-VSA 的 0.43s、DRL-based RSS 的 0.42s 和 TOPSIS-Q 的 0.48s 分别低了 34.9%、33.3%和 41.7%。随着节点数量增至 350 时，网络拓扑复杂度提升、信道竞争加剧，各算法时延均大幅上升，DRL-based RSS 达到 1.28s，Muti-VSA 为 1.13s，TOPSIS-Q 为 1.08s，而 LAHVHA 仅为 0.71s。可以看出，随着节点规模增大，LAHVHA 的时延优势愈发明显，其增长幅度最为平缓。这主要得益于 LSTM 预测模块能够提前感知网络状态变化，避免了被动响应导致的服务中断和路由重建耗时；同时融合决策矩阵综合考虑当前与预测状态，优先选择未来时延特性更优的目标网络，从而在全场景下始终保持最低时延表现。




图 3-7 不同节点规模下平均端到端时延对比

由图 3-8 可知，四种算法的丢包率均随节点数量的增加呈上升趋势，但 LAAVHA 在全部场景下均保持最低丢包率。在低节点密度场景下，LAAVHA 丢包率仅为 2.15%，分别比 Muti-VSA(3.65%)、DRL-based RSS(4.25%)和 TOPSIS-Q (4.82%)低 41.1%、49.4%和 55.4%。当节点数量增至 350 时，DRL-based RSS 丢包率飙升至 31.52%，Muti-VSA 为 28.62%，TOPSIS-Q 为 25.88%，而 LAAVHA 仅为 15.28%，分别低了 51.5%、46.6%和 41.0%。可以看出，随着节点规模增大，LAAVHA 的丢包率优势进一步扩大，其增长幅度远低于其他三种算法。这主要得益于 LSTM 预测模块能够在丢包率恶化前主动切换至更稳定的网络，同时双重滞后机制减少了因频繁切换导致的数据包丢失，从而显著提升了传输可靠性。




图 3-8 不同节点规模下丢包率对比

由图 3-9 可知，四种算法的平均吞吐量均随节点数量的增加呈下降趋势，但各算法的衰减幅度差异显著。在低节点密度场景下，四种算法表现较为接近，LAAVHA 与 Muti-VSA 均为 0.46Mbps，略高于 DRL-based RSS 和 TOPSIS-Q 的 0.44Mbps。然而随着节点数量增大，差距逐渐拉开。当节点数量达到 350 时，DRL-based RSS 吞吐量降至 0.25Mbps，Muti-VSA 为 0.26Mbps，TOPSIS-Q 为 0.28Mbps，而 LAAVHA 仍维持在 0.38Mbps，分别比上述三种算法高了 52.0%、46.2%和 35.7%。LAAVHA 的吞吐量衰减幅度最小，而其他三种算法降幅均超过 30%以上。这主要得益于 LSTM 预测机制在信道质量劣化前提前完成切换准备，最大程度减少了切换过程中的传输中断时间，同时动态权重机制在高密度场景下合理平衡切换稳定性与传输效率，使吞吐量始终保持在较高水平。




图 3-9 不同节点规模下平均吞吐量对比

(2) 节点规模恒定

在节点规模恒定为 200 的情况下，设置了节点速度从 5m/s 到 30m/s 来验证四种垂直切换算法的性能表现。

由图 3-10 可知，四种算法的平均切换次数均随节点移动速度的增加呈上升趋势，这是由于高速移动导致信道状态快速变化、链路中断频率增大，各算法触发切换的频率相应增加。在低速场景下，LAAVHA 仅产生 7 次切换，随着速度增至 30m/s 时，各算法切换次数均大幅攀升，DRL-based RSS 高达 68 次，Muti-VSA 为 54 次，TOPSIS-Q 为 50 次，而 LAAVHA 仅为 27 次，相对低了 60.3%、50.0% 和 46.0%。值得注意的是，LAAVHA 在全部速度场景下均保持最低切换次数且增长最为平缓，其优势主要源于 LSTM 预测模块能够捕捉高速移动下的网络状态变化趋势实现提前预判，Multi-Head Attention 机制在高速场景下自动提升信号质量属性权重保障切换稳定性，以及双重滞后机制有效抑制因信号瞬时波动引发的乒乓切换。




图 3-10 不同节点速度下平均切换次数对比

由图 3-11 可知，四种算法的平均端到端时延均随节点移动速度的增加呈上升趋势。在低速场景下，LAAVHA 时延为 0.25s，分别比 Muti-VSA 的 0.31s、DRL-based RSS 的 0.35s 和 TOPSIS-Q 的 0.42s 低了 19.4%、28.6%和 40.5%。当速度增至 30m/s 时，DRL-based RSS 时延高达 1.28s，Muti-VSA 为 1.15s，TOPSIS-Q 为 1.10s，而 LAAVHA 仅为 0.68s。可以看出，随着速度增大，LAAVHA 的时延优势愈发显著，这主要得益于预测模块在链路质量恶化前主动完成切换，避免了被动响应导致的服务中断和路由重建耗时，同时融合决策矩阵优先选择未来时延特性更优的目标网络。




图 3-11 不同节点速度下平均端到端时延对比

由图 3-12 可知, 四种算法的丢包率均随节点移动速度的增加呈上升趋势。在低速场景下, LAAVHA 丢包率为 2.84%, 分别比 Muti-VSA (3.28%)、DRL-based RSS (3.85%) 和 TOPSIS-Q (4.56%) 低了 13.4%、26.2% 和 37.7%。当速度增至 30m/s 时, DRL-based RSS 丢包率飙升至 29.32%, Muti-VSA 为 25.15%, TOPSIS-Q 为 23.24%, 而 LAAVHA 仅为 14.86%。LAAVHA 在全场景下丢包率最低且增长最为平缓从而避免了被动响应导致的服务中断。其中双重滞后机制也有效减少了因频繁切换导致的数据丢失。




图 3-12 不同节点速度下丢包率对比

由图 3-13 可知, 四种算法的平均吞吐量均随节点移动速度的增加呈下降趋势。在低速场景下, 四种算法表现较为接近, LAAVHA 与 Muti-VSA 均为 0.46Mbps, DRL-based RSS 为 0.45Mbps, TOPSIS-Q 为 0.44Mbps。然而随着速度增大, 差距逐渐拉开。当速度达到 30m/s 时, DRL-based RSS 降至 0.27Mbps, Muti-VSA 和 TOPSIS-Q 为 0.27 Mbps 和 0.29Mbps, 而 LAAVHA 仍维持在 0.36Mbps。LAAVHA 的优势在于, 在丢包率恶化前主动切换至更稳定网络; Multi-Head Attention 机制根据移动速度动态调整各属性权重, 高速时自动提升信号质量和丢包率属性的决策权重, 减少不必要的切换操作及其伴随的数据丢失。




图 3-13 不同节点速度下平均吞吐量对比

3.5.3 消融实验分析

消融实验用固定节点速度的形式进行仿真，节点数量仍然从 50 至 350 个。




图 3-14 平均切换次数对比

由图 3-14 可知，三种方案的平均切换次数均随节点数量的增加而呈现上升趋势。LAAVHA 在所有场景下均保持最低的切换次数，当节点规模从 50 增加到 350 时，切换次数仅从 8 次增长至 27 次，增长趋势最为平缓。剔除 LSTM 预测模块后的 LAAVHA-L 方案性能下降最为显著，在 350 个节点时切换次数高达 63

次。而剔除 Attention 模块的 LAAVHA-A 方案由于无法根据无人节点的移动特征和信道状态自适应调整权重，导致其在 350 节点下的切换次数升至约 40 次，性能表现介于两者之间。实验结果充分证明了 LSTM 预测模块与 Attention 权重生成模块在优化切换决策中具有不可替代的协同作用。




图 3-15 平均端到端时延对比

由图 3-15 可知，三种方案的平均端到端时延均随网络节点数量的增加而呈现上升趋势。LAAVHA 在全场景下始终保持最低的时延水平，其时延在 50 个节点时仅为 0.28s，即便在 350 个节点的高密度环境下也仅上升至 0.71s。剔除 LSTM 预测模块后的 LAAVHA-L 方案时延增加最为显著，在 350 个节点时达到 1.15s，相比 LAAVHA 增加了约 62%。而剔除 Attention 模块的 LAAVHA-A 方案时延表现居中，在 350 个节点时约为 0.95s，说明多头注意力机制通过动态权重分配优先选择时延特性更优的目标网络，对降低端到端时延同样具有重要支撑作用。




图 3-16 丢包率对比

由图 3-16 可知，三种方案的丢包率均随节点规模的扩大而呈现上升趋势。LAAVHA 在全场景下均保持最低的丢包率，即便在 350 节点环境下也仅上升至 15.28%。相比之下，剔除 LSTM 预测模块后的 LAAVHA-L 方案性能受损最为严重，在 350 节点时丢包率飙升至 27.66%，证明了预测模块在减少由于切换滞后导致的数据丢失方面的核心价值。而剔除 Attention 模块的 LAAVHA-A 方案在 350 个节点时的丢包率约为 23%，介于两者之间，说明多头注意力机制通过动态权重优化目标网络选择，对保障系统在高动态环境下的通信稳定性同样不可或缺。




图 3-17 平均吞吐量对比

由图 3-17 可知，三种方案的平均吞吐量均随网络节点数量的增加而呈现下降趋势。LAAVHA 在全场景下均维持了最高的吞吐量水平，其在 50 个节点时吞吐量约为 0.46 Mbps，即便在 350 个节点的高密度场景下仍能保持在 0.38 Mbps，表现出极强的吞吐量稳定性。剔除 LSTM 预测模块后的 LAAVHA-L 方案性能衰减最为严重，在 350 个节点时吞吐量降至约 0.25 Mbps，相比 LAAVHA 大幅下降了约 34%。而剔除 Attention 模块的 LAAVHA-A 方案在 350 个节点时的吞吐量约为 0.31Mbps，性能表现介于两者之间，说明多头注意力机制通过根据当前网络需求动态调整属性权重，对保障高动态环境下的数据传输效率具有显著的增益效果。

3.6 本章小结

本章针对无人异构网络中垂直切换面临的乒乓切换频繁、决策滞后及固定权重难以适应动态环境等问题，提出了基于 LSTM-Attention 的自适应垂直切换算法 LAAVHA。首先，设计了基于堆叠 LSTM 的网络状态预测模块，实现主动式切换决策，避免了传统被动式方法的切换滞后问题；其次，引入 Multi-Head Attention 动态权重生成机制，克服了传统固定权重方法在不同场景下适应性不足的局限；最后，结合改进 TOPSIS 方法构建融合当前状态与预测状态的决策矩阵进行最优网络选择，并引入双重滞后机制有效抑制乒乓切换。NS-3 仿真结果表明，在不同节点规模和不同移动速度的网络场景下，LAAVHA 在平均切换次数、平均端到端时延、丢包率和平均吞吐量等核心指标上均显著优于 Muti-VSA、DRL-based RSS 和 TOPSIS-Q 三种对比算法。消融实验进一步验证了 LSTM 预测模块和 Attention 动态权重生成模块的关键作用，移除对应模块后各项性能指标均出现下降，充分证明了两个模块对提升垂直切换决策质量的重要性。

第 4 章 基于 Q-Learning 的自适应路由协议切换算法研究

本章针对传统 OLSR 协议固定 HELLO/TC 消息发送间隔导致的控制消息泛滥、拓扑动态跟踪不及时等问题，设计了 OLSR-C 协议；针对传统 AODV 协议路由发现阶段盲目泛洪引发的广播风暴、链路稳定性差、路由重建频繁等弊端，提出了 AODV-MFW 协议。考虑到无人异构网络在运行过程中存在节点移动、密度波动、链路质量动态变化等特性，单一路由协议难以在全场景下维持最优性能，进一步提出基于 Q-Learning 的自适应路由协议切换算法 QAS。NS-3 仿真实验结果表明，所提 OLSR-C、AODV-MFW 改进协议及 QAS 自适应切换算法均展现出优异的性能，在平均吞吐量、平均端到端时延及丢包率等核心指标上显著优于传统协议与单一改进协议，充分验证了方案的有效性与实用性。本章内容结构如图 4-1 所示。




图 4-1 本章内容结构

4.1 OLSR、AODV 路由协议局限性分析

OLSR 作为主动式链路状态路由协议，但面对网络中节点高速移动、网络密度骤增的情况，容易出现控制消息泛滥问题，但提升 HELLO/TC 消息发送频率以跟踪拓扑变化，却会导致 MPR 节点转发负担剧增，大量控制包挤占数据带宽，同时频繁更新的拓扑视图易引发路由震荡，使数据传输丢包率显著上升，反而降低网络通信稳定性。

AODV 作为按需驱动的距离向量路由协议，既不主动维护全网拓扑，也不长期保存无效路由条目，仅在有数据传输需求时才通过泛洪 RREQ 消息发现目标节点路径。但在面对网络拓扑极速变化、链路频繁断裂的情况，容易遭遇路由失效问题，改用重复发送 RREQ 消息重新发现路由，且为扩大覆盖范围会增加泛洪跳数，这个过程中会产生大量冗余请求包从而引发广播风暴。

由此可见，OLSR 的固定消息频率与 AODV 的固定 RREQ 重发及泛洪策略，本质上均是针对特定网络场景设计的静态应对机制，缺乏面向网络中高动态特性的通用性与灵活性。这类固定策略无法根据节点移动速度、网络密度等实时状态进行自适应调整，更缺乏与动态网络环境的交互感知及策略探索机制，导致其在拓扑剧变、链路波动的复杂场景中，难以平衡资源消耗与通信性能，无法稳定收敛至最优传输路径。

为克服以上局限性，近年来，在高动态拓扑、链路不稳定、节点密度不均等场景下的传输局限性，近年来研究人员针对协议核心缺陷提出了多种优化方案。Jain 等^[72]提出了一种将节点的意愿和链接质量信息引入 OLSR 协议，通过考虑链路质量来进行路由决策，从而找到更高效的路径。孙一凡等^[73]提出了一种基于分簇的拓扑自适应的无人机蜂群 OLSR 路由协议，将无人机群体划分为多个簇，分簇结构网络规模不受限制，且不需要全网广播链路状态更新消息。文献[74]中提出 AODV-C，按邻居节点数分场景选转发节点，适配高节点密度，提投递率降开销。此外，Nenad 等^[75]人为 AODV 集成 ETX 度量，借 LPP 算链路质量选最优路径，在实验仿真中降低了整个网络的时延与丢包率。

上述改进型路由协议在提升网络中路由传输效率、缓解路由空洞问题、均衡网络能耗等方面展现出优异性能，但仍存在若干共性局限性：首先，部分方案依赖精准的节点位置、链路质量等感知数据，一旦感知模块出现误差，易导致路由决策失效，且额外的感知与计算流程会增加节点的资源开销；其次，分簇类协议存在簇头节点瓶颈问题，簇头的通信负载与能量消耗远高于普通节点，易引发簇内通信延迟与簇结构频繁重构；最后，多数改进方案为针对性场景设计，缺乏跨场景的自适应能力，在节点移动特性、网络密度剧烈变化的复杂网络环境中，难以维持稳定的传输性能。

4.2 基于控制消息发送策略改进的 OLSR 协议研究

传统 OLSR 协议采用固定时隙周期性发送 HELLO 消息和 TC 消息，这种静态机制在面对高动态拓扑时存在明显不足：当网络拓扑变化剧烈时，固定间隔难以及时感知邻居变化，导致路由信息滞后；当网络相对稳定时，频繁的控制消息发送又会造成不必要的带宽开销。针对上述问题，本节提出 OLSR-C 协议，通过融合节点移动特征与网络密度等多维度信息，实现控制消息发送间隔的自适应调整，在路由开销与拓扑适配性之间取得平衡。

4.2.1 OLSR 协议控制消息机制分析

在深入设计自适应机制之前，有必要对传统 OLSR 协议的控制消息机制进行系统分析。OLSR 协议的控制消息主要包括 HELLO 消息和 TC 消息两类，二者在路由维护中承担不同职责。

HELLO 消息用于发现和维护邻居关系。节点通过周期性广播 HELLO 消息，宣告自身存在并收集一跳邻居信息。接收到 HELLO 消息的节点据此建立邻居表，并进一步选举 MPR 节点。MPR 机制是 OLSR 协议的核心优化策略，其基本思想是：每个节点从一跳邻居中选择一个能覆盖所有二跳邻居的最小子集作为 MPR 节点，仅由 MPR 节点负责转发广播消息，从而有效减少网络中的泛洪开销。

TC 消息用于构建全网拓扑视图。被选为 MPR 的节点周期性生成并转发 TC 消息，消息中包含其 MPR 选择器集合。通过 TC 消息的扩散，网络中的每个节点都能获取全网的链路状态信息，进而建立完整的路由表。如图 4-2 所示，节点 A、B、C、E、F 作为 A 的一跳节点被选为 MPR 节点负责 TC 消息转发，而节点 D 和 G 作为普通节点不参与转发，有效降低了控制消息的冗余传播。




图 4-2 MPR 节点选择示意图

从上述分析可知，OLSR 协议的路由开销主要来源于 HELLO 消息和 TC 消

息的发送。传统协议采用固定发送间隔这种静态策略存在较大局限例如拓扑感知滞后问题，当节点高速移动时，邻居关系可能在一个 HELLO 周期内发生显著变化，固定间隔无法及时捕捉这种变化，导致邻居表和 MPR 集合与实际拓扑产生偏差，进而影响路由有效性；带宽资源浪费问题：当网络拓扑相对稳定时，频繁发送控制消息不仅消耗节点能量，还占用有限的信道带宽，挤压数据传输资源，降低网络整体吞吐量。网络密度适配问题：在高密度场景下，大量节点同时发送控制消息易引发信道冲突和广播风暴；而在稀疏场景下，较长的控制消息间隔又可能导致链路发现不及时。

4.2.2 自适应 HELLO 消息发送机制

HELLO 消息的核心功能是邻居发现与链路感知，其发送频率应与节点的邻居关系变化速度相匹配。本节设计的自适应 HELLO 消息发送机制以综合链路感知需求度为核心决策因子，综合考虑节点移动性和邻居密度两个维度。

移动剧烈度 M_v 表征节点的运动状态强度，其设计依据是：节点移动速度越快，其邻居拓扑变化的概率越高，需要更频繁地发送 HELLO 消息以及时发现新邻居、检测失效链路。 M_v 定义为：

$$M_v = \frac{v_{current}}{v_{max}} \quad (4-1)$$

其中， $v_{current}$ 是为节点当前瞬时速度， v_{max} 是网络预设的节点最大速度阈值。 M_v 取值范围为 0 到 1 之间。数值越大表示节点移动越剧烈，链路感知需求越高。

邻居密度冗余度 N_r 表征当前节点周围的邻居拥挤程度，其设计依据是：当邻居节点数量过多时，大量节点同时发送 HELLO 消息会导致信道冲突概率显著增加，此时应适当延长发送间隔以缓解信道压力。 N_r 定义为：

$$N_r = 1 - \frac{N_{current}}{N_{max}} \quad (4-2)$$

其中， $N_{current}$ 是代表节点的当前一跳邻居数， N_{max} 是设置的最大节点最大可承载邻居数。 N_r 同样归一化至 0 到 1 之间，数值越大表示邻居越稀疏，信道竞争压力越小，可以支持更频繁的消息发送。

在通过加权得到综合链路感知需求度 D_{hello} 。

$$D_{hello} = w_1 * M_v + w_2 * N_r \quad (4-3)$$

其中， w_1 和 w_2 为权重系数，满足 $w_1 + w_2 = 1$ 。权重的设置可根据具体应用场景调整：在对移动性敏感的场景中可增大 w_1 在对信道冲突敏感的场景中可增大 w_2 。

在基于 D_{hello} 映射 HELLO 消息包的发送间隔 T_{hello} ，本文采用非线性反比映射函数，其设计原则是：需求度越高，发送间隔越短，同时通过指数函数避免间隔过短导致的开销激增。映射公式为：

$$T_{hello} = T_{hello-min} + (T_{hello-max} - T_{hello-min}) * e^{-k*D_{hello}} \quad (4-4)$$

其中, $T_{hello-min}$ 代表 HELLO 包发送最小间隔, $T_{hello-max}$ 代表 HELLO 包发送最大间隔, k 为映射灵敏度调节系数。当 D_{hello} 较大时, $e^{-k*D_{hello}}$ 趋近于 0, T_{hello} 趋近于 $T_{hello-min}$; 当 D_{hello} 较小时, T_{hello} 趋近于 $T_{hello-max}$ 。

图 4-3 展示了 D_{hello} 和 T_{hello} 的非线性映射关系:




图 4-3 非线性映射关系

4.2.3 自适应 TC 消息发送机制

TC 消息用于全网拓扑信息同步, 其发送频率应与全网拓扑变化幅度和网络拥塞状态相匹配。相比 HELLO 消息的局部感知特性, TC 消息需要从全局视角评估拓扑同步的紧迫性。MPR 集变化频率反映网络中关键转发节点的更迭速度, 其设计依据是: MPR 集合的变化直接影响 TC 消息的转发路径和拓扑信息的有效性, 频繁变化意味着需要更及时地同步拓扑信息。 F_m 定义为:

$$F_m = \frac{N_{mpr-change}}{T_{windows}} \quad (4-5)$$

其中, $T_{windows}$ 代表统计时间窗口长度, $N_{mpr-change}$ 为该时间窗口内 MPR 集合的变化次数。 F_m 数值越大, 表示 MPR 集合变化越频繁, 拓扑同步需求越紧迫。

全网拓扑变化幅度从链路层面量化网络拓扑的动态程度, 其设计依据是: 链路状态变化越剧烈, 节点维护的拓扑视图与实际网络偏差越大, 需要更频繁地发送 TC 消息进行校正。 T_a 定义为:

$$T_a = \frac{\sum_{i \in mpr} \Delta_{link-i}}{N_{mpr}} \quad (4-6)$$

其中, Δ_{link-i} 为 MPR 节点 i 的链路状态变化次数包括链路建立和断开, N_{mpr} 代表为本地 MPR 节点数。 T_a 通过对所有 MPR 节点的链路变化求平均, 反映全网拓扑的平均动态程度。

将上述两个指标通过加权求和得到拓扑同步优先级 P_{tc} :

$$P_{tc} = \alpha * F_m + \beta * T_a \quad (4-7)$$

其中, 权重 $\alpha + \beta = 1$ 。基于 P_{tc} 映射 TC 消息的发送间隔 T_c , 采用分段线性映射策略, 相比 HELLO 消息的连续映射, 该策略能够更精确地划分网络状态并采取差异化响应:

$$T_c = \begin{cases} T_{tc-min} + \frac{(T_{tc-max} - T_{tc-min}) * (0.8 - P_{tc})}{0.6} & 0.8 > P_{tc} > 0.2 \\ T_{tc-min} & P_{tc} \geq 0.8 \\ T_{tc-max} & P_{tc} \leq 0.2 \end{cases} \quad (4-8)$$

其中, T_{tc-max} 代表 TC 最大发送间隔一般取传统的发送间隔时间的两倍, T_{tc-min} 代表 TC 最小发送间隔, 一般取传统发送间隔的 0.5 倍。

图 4-4 展示了 P_{tc} 和 T_c 的取值策略:




图 4-4 分段线性映射关系

4.3 基于多因素改进的 AODV-MFW 协议研究

传统 AODV 协议在路由发现阶段采用盲目泛洪策略广播 RREQ 消息，虽然简单有效，但在高动态环境下存在明显不足：一方面，泛洪过程中大量节点参与转发导致信道资源浪费和广播风暴；另一方面，协议未考虑链路的时变特性，建立的路由可能在数据传输过程中快速失效。针对上述问题，本节提出 AODV-MFW 协议，通过综合考虑节点传播区域、相对移动速度、剩余能量和网络密度等多维度因素，优化路由发现与转发节点选择策略。

4.3.1 转发节点选择优化策略

传统 AODV 协议的路由发现过程中，源节点广播 RREQ 消息后，通信范围内的所有节点均会接收并继续转发，这种无差别泛洪在高节点密度场景下会产生大量冗余消息。本节从传播区域约束和链路稳定性预判两个角度优化转发节点的选择策略。

在数据从源节点向目的节点传输的过程中，并非所有邻居节点都具有转发价值。如图 4-5 所示，圆圈代表 A 的通信范围，源节点 A 向目的节点 D 发送数据，节点 B 和节点 C 均位于 A 的通信范围内，但 B 位于 A→D 传输方向的反向区域，若将 RREQ 转发给 B 不仅不能推进数据向目的节点的传递，反而会增加无效的网络负载。因此，应当仅选择位于有效传播区域内的节点作为转发候选。




图 4-5 数据转发过程

有效传播区域的判定通过向量夹角计算实现。设源节点/当前转发节点为 A，候选中间节点为 C，目的节点为 D，首先根据 A、C 节点的坐标计算他们之间的单位向量，A、D 之间同理：

$$\widehat{AC} = \frac{\vec{AC}}{\|AC\|} \quad (4-9)$$

之后计算两个单位向量之间的夹角。

$$\theta = \arccos(\widehat{AC}, \widehat{AD}) \quad (4-10)$$

规定如果算出的角度值小于等于 90 度，则该点可以作为转发候选节点。此外节点均位于无效区域，不参与本次路由发现的转发过程。

此外用传统的 AODV 协议容易导致链路的频繁切断^[76]，如图 4-6 所示 t_1 时刻源节点 A 通过中间节点 B 向目的节点 C 发送 RREQ 数据包。但是当在发送的过程中， t_2 时刻节点 C 移动到了节点 B 的通信范围之外如图 4-6 所示，导致 C 无法返回路由回复 RREP 数据包。故需要及时计算节点相对速度从而估算链路在 t_2 时刻后是否还有效，若已经离开通信范围，则需快速寻另一条链路传输。

为避免上述链路快速失效问题，引入基于相对移动速度的链路稳定性预判机制。设当前时刻两节点间距为 d ，通信半径为 R ，两个节点相对移动速度为 v_{rel} ，则可估算链路剩余有效时间 T_{link} ：

$$T_{link} = \frac{R - d}{v_{rel}} \quad (4-11)$$




图 4-6 t_1 和 t_2 时刻节点位置示意图

4.3.2 节点权重评估与选择机制

在通过传播区域约束和链路稳定性预判筛选出候选转发节点后，当存在多个候选节点时，需要进一步评估各节点的转发优先级。本小节设计基于剩余能量和网络密度的节点权重评估机制。

在无人异构网络中，节点能量是宝贵的系统资源。若频繁选择同一节点承担转发任务，将导致该节点能量快速耗尽，进而引发网络分割。为实现能量均衡，本文将节点剩余能量纳入转发决策。设定每个无人节点都有初始能量为 E_0 ，每次发送或接收一个数据包消耗能量为 E_j ，那么在任意时刻，节点的剩余能量 E_s 可以表示为：

$$E_s = E_0 - NE_j \quad (4-12)$$

$$E_{norm} = \frac{E_s}{E_0} \quad (4-13)$$

其中, N 为接收或发送数据次数。在两个或多个节点处于上述同一传播区域, 并且在 t 时刻后仍然互相处于有效通信范围内的时候, 优先选择剩余能量多的节点进行数据转发。

此外在大规模的集群当中, 节点之间的距离往往很近, 如果采用泛洪的方法, 可能导致有效覆盖节点重复。所以界定一个节点中介值 $D_{threshold}$ 就显得尤为重要, 在节点数目小于中介值的时候直接采用泛洪转发, 当节点数目大于中介值的时候再采用传播区域计算。假设此时网络的密度是 D , N 是区域内的节点数目, A 是区域的面积, 则有

$$D = \frac{N}{A} \quad (4-14)$$

其中, 当 $D < D_{threshold}$ 的时候网络较为稀疏, 采用传统泛洪方式以确保路由发现成功率, 当 $D \geq D_{threshold}$ 的时候网络较为密集, 启用传播区域约束和节点权重评估机制, 选择最优转发节点。

对于满足基本约束条件的候选节点, 计算其综合转发权重 W :

$$W = \omega_1 * E_{norm} + \omega_2 * \left(1 - \frac{v_{rel}}{v_{max}}\right) + \omega_3 * \cos\theta \quad (4-15)$$

其中, 第一项反映能量优势, 第二项反映链路稳定性, 第三项反映传播方向优势。 ω_1 、 ω_2 、 ω_3 为权重系数, 满足 $\omega_1 + \omega_2 + \omega_3 = 1$ 。选择权重 W 最大的节点作为下一跳转发节点。如表 4-1 所示:

表 4-1 多因素权重参数说明表

因素	符号	含义	取值范围
剩余能量	E_{norm}	节点能量充足程度	[0,1]
链路稳定性	$1 - \frac{v_{rel}}{v_{max}}$	相对速度越小越稳定	[0,1]
传播方向	$\cos\theta$	夹角越小越接近目的	[0,1]

4.3.3 协议工作流程

综合上述优化策略, AODV-MFW 协议的完整工作流程如图 4-7 所示:




图 4-7 协议工作流程图

协议的主要工作步骤描述如下：

步骤 1：路由请求发起当源节点有数据发送需求且本地路由表中无到目的节点的有效路由时，发起路由发现过程，广播 RREQ 消息。RREQ 消息中携带源节点位置、目的节点位置、序列号等信息。

步骤 2：网络密度判断中间节点收到 RREQ 后，首先计算本地网络密度 D 。若 $D < D_{threshold}$ ，采用传统泛洪方式转发 RREQ，跳转至步骤 6；若 $D \geq D_{threshold}$ ，进入步骤 3 执行多因素筛选。

步骤 3：传播区域筛选计算本节点与目的节点方向的夹角 θ 。若 $\theta > 90^\circ$ ，丢弃该 RREQ，不参与转发；若 $\theta \leq 90^\circ$ ，进入步骤 4。

步骤 4：链路稳定性评估计算与上游节点的相对移动速度 v_{rel} ，估算链路剩余有效时间 T_{link} 。若 $T_{link} < T_{threshold}$ ，标记该链路为不稳定链路，在权重计算中给予惩罚。

步骤 5：综合权重计算与转发决策计算本节点的综合转发权重 W ，并在 RREQ 中记录。若存在多条候选路径，选择权重最高的路径进行转发。

步骤 6：路由回复目的节点收到 RREQ 后，沿反向路径发送 RREP 消息，建立正向路由。中间节点收到 RREP 后更新本地路由表，并继续向源节点方向转发。

4.4 基于 Q-Learning 的路由协议自适应切换决策

前述章节分别针对 OLSR 和 AODV 协议的核心缺陷进行了改进, 提出了 OLSR-C 和 AODV-MFW 两种优化协议。然而, 单一路由协议即使经过优化, 也难以在所有网络场景下都保持最优性能: OLSR-C 作为主动式协议, 在网络拓扑稳定时能够提供低时延的路由服务, 但在拓扑剧变时控制开销仍可能显著增加; AODV-MFW 作为反应式协议, 在拓扑动态变化时能够灵活应对, 但路由发现时延可能影响实时性要求较高的业务。

针对上述问题, 本节提出基于 Q-Learning 的自适应路由协议切换 QAS, 通过强化学习方法实时感知网络状态, 智能选择当前场景下的最优协议, 实现 OLSR-C 与 AODV-MFW 的动态互补, 进一步提升通信可靠性与资源利用效率。

4.4.1 算法整体架构设计

作为机器学习领域的关键分支, 强化学习 (Reinforcement Learning, RL) 以试错-反馈-优化为核心逻辑, 其核心任务在于构建科学的奖惩反馈体系, 引导智能体在与环境的动态交互中持续迭代行为模式, 通过渐进式的探索与认知, 最终实现经验积累与决策策略的优化升级。在强化学习的基本框架内, 智能体在每个时间节点都会从预设的动作空间中选取具体行为, 随后接收环境的双重反馈: 一是环境状态的实时更新, 二是与该动作对应的奖励或惩罚信号。这一交互过程的反复迭代, 使得智能体的环境认知能力不断深化, 决策策略也随之逐步优化。

强化学习的基础理论主要依托马尔可夫决策过程构建, 该模型的核心构成包含四大要素: 智能体、状态、动作以及奖励函数^[77]。强化学习的终极目标, 是通过持续优化智能体的行为策略, 使其在与环境的长期交互过程中实现累积奖励的最大化。这里的策略本质上是一套状态-动作映射规则, 用于明确智能体在不同环境状态下应采取的最优动作组合。如前文所述, 环境会针对智能体的动作输出两类关键反馈: 更新后的环境状态与量化的奖惩数值。而智能体对长期累积奖励最大化这一目标的追求, 需通过价值函数进行量化评估。奖励机制在整个强化学习体系中占据核心地位, 它作为策略有效性的评估标尺, 当智能体在某一状态下的动作未能获得预期奖励时, 会触发其在后续相似场景中调整动作选择逻辑, 进而逐步逼近最优策略。

在强化学习的算法体系中, Q-Learning 是一种经典的无模型强化学习算法^[78], 其核心设计思想是通过学习状态-动作对的 Q 值为智能体提供任意状态下的最优动作选择依据, 最终实现全局最优策略的挖掘。Q-Learning 算法的核心执行路径, 是通过维护一张 Q 表存储所有可能状态-动作对对应的 Q 值, 并基于环境反馈持

续更新 Q 值，逐步缩小与最优策略的偏差。Q 表的核心功能在于记录状态-动作组合的长期价值。

Q-Learning 的 Q 值更新规则以贝尔曼方程为理论基础^[79]，其核心计算公式如下：

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_{t+1} + \gamma \max_a Q(s_{t+1}, a_t) - Q(s_t, a_t)] \quad (4-16)$$

其中， α 为学习率，控制新经验对 Q 值更新的影响程度，其核心作用是调控新经验信息对 Q 值更新的影响权重，取值范围介于[0,1]之间； γ 为折扣因子，权衡即时奖励与未来奖励的重要性； r_{t+1} 为即时奖励； $\max_a Q(s_{t+1}, a_t)$ 为下一状态所有动作 Q 值的最大值。通过这一迭代更新机制，Q-Learning 能够使 Q 值逐步逼近最优价值，最终引导智能体在任意状态下都能选择出最大化未来累积奖励的动作。

因此本文设计了 QAS 算法。通过感知网络实时状态、学习两种协议的性能反馈，实现 OLSR-C 与 AODV-MFW 的智能切换，解决单一协议的场景适配局限，进一步提升通信可靠性与资源利用效率。

算法整体分为状态感知模块、Q-learning 决策模块、协议执行模块和性能反馈模块四个部分形成协作机制。如图 4-8 所示。




图 4-8 QAS 算法架构

各模块功能职责如下：状态感知模块负责周期性采集网络状态特征，将多维度指标量化处理后组合为状态向量，以为 Q-Learning 决策提供输入，该模块需

在信息全面性与计算开销之间取得平衡，重点选取对协议性能影响最显著的关键指标。Q-Learning 决策模块作为算法的核心，通过维护 Q 表存储各状态下不同协议选择的价值评估，依据输入的状态向量与当前 Q 表采用贪婪策略选择最优动作，并在收到奖励反馈后完成 Q 表更新。协议执行模块接收决策模块输出的协议选择指令，执行协议切换或维持当前协议运行，为保证切换过程的平滑性，该模块支持协议间的快速无缝切换。性能反馈模块则在每个决策周期结束后采集当前协议的实际传输性能指标，通过奖励函数将多维指标转化为标量奖励值并反馈至决策模块，用于驱动 Q 表的持续迭代更新。

4.4.2 状态空间与动作空间设计

状态空间的设计需要准确刻画影响协议性能的关键网络特征。结合 OLSR-C 与 AODV-MFW 的核心改进维度，算法选取节点移动性、链路质量、网络密度和网络拥塞度四个维度构建状态向量，各维度均进行量化分级处理。

节点移动性表征节点运动的剧烈程度，直接影响链路稳定性和拓扑变化速度。该指标与 AODV-MFW 的相对移动速度优化策略以及 OLSR-C 的 HELLO 消息间隔调整逻辑高度相关。量化方法综合节点瞬时速度与相对移动速度方差，归一化后划分为低、中、高三个等级。

链路质量表征节点与邻居间的通信可靠性，影响数据传输成功率。该指标与 OLSR-C 的链路感知需求度以及 AODV-MFW 的链路有效性判断密切相关。量化方法统计最近 5 次 HELLO/RREQ 交互的平均信噪比，划分为差、中、优三个等级。

网络密度表征区域内节点的拥挤程度，影响信道竞争强度和泛洪开销。该指标与 OLSR-C 的邻居密度冗余度计算以及 AODV-MFW 的网络密度阈值策略直接对应。量化方法为计算单位面积内的节点数量，划分为稀疏、适中、密集三个等级。

网络拥塞度表征当前信道的负载状态，影响控制消息和数据消息的传输时延。该指标与 OLSR-C 的消息拥塞避让以及 AODV-MFW 的泛洪风暴抑制策略相关。量化方法为检测 MAC 层待发送队列占用率，划分为低、中、高三个等级。

表 4-2 明确表明了状态空间维度定义与量化规则。

表 4-2 状态空间维度定义与量化规则表

维度	符号	物理含义	量化指标
节点移动性	S1	运动剧烈程度	瞬时速度+速度方差
链路质量	S2	通信可靠性	平均信噪比
网络密度	S3	节点拥挤程度	单位面积节点数
网络拥塞度	S4	信道负载状态	MAC 队列占用率

动作空间定义智能体可执行的协议选择行为。本算法的动作空间包含两个离散动作：

a_0 ：选择 OLSR-C 协议

a_1 ：选择 AODV-MFW 协议

当决策结果与当前运行协议一致时，维持现状；当决策结果与当前协议不同时，执行协议切换。此外算法 Q 表为 81×2 的二维矩阵，行索引对应 81 种状态，列索引对应 2 种动作。Q 表初始值设为 0，随着学习过程逐步更新收敛。表 4-3 为算法 Q 表结构示意图：

表 4-3 Q 表示意图

状态空间 S	动作空间 A	
	a_0 : OLSR-C	a_1 : AODV-MFW
$S_1 = (\text{低, 差, 稀疏, 低})$	$Q(s_1, a_0)$	$Q(s_1, a_1)$
$S_2 = (\text{低, 差, 稀疏, 中})$	$Q(s_2, a_0)$	$Q(s_2, a_1)$
$S_3 = (\text{低, 差, 稀疏, 高})$	$Q(s_3, a_0)$	$Q(s_3, a_1)$
.....		
$S_{80} = (\text{高, 优, 密集, 中})$	$Q(s_{80}, a_0)$	$Q(s_{80}, a_1)$
$S_{81} = (\text{高, 优, 密集, 高})$	$Q(s_{81}, a_0)$	$Q(s_{81}, a_1)$

4.4.3 奖励函数与学习策略设计

奖励函数的设计需要综合评估协议选择的优劣。算法选取端到端时延、丢包率和路由开销三项核心性能指标，由于各指标量纲不同，首先进行归一化处理，映射至[0,1]区间。

路由开销归一化：

$$O_{norm} = \frac{O_{max} - O_{current}}{O_{max} - O_{min}} \quad (4-17)$$

其中， O_{max} 代表两种协议在全场景下的最大控制流量， O_{min} 为最小控制消息流量。通过预仿真确定。OLSR-C 的开销为 HELLO/TC 消息总流量，AODV-MFW 的开销为 RREQ/RREP 消息总流量。

端到端时延归一化：

$$D_{norm} = \frac{D_{max} - D_{current}}{D_{max} - D_{min}} \quad (4-18)$$

丢包率归一化：

$$L_{norm} = 1 - \frac{L_{current} - L_{min}}{L_{max} - L_{min}} \quad (4-19)$$

其中, L_{norm} 越大表示丢包率越小。归一化参数通过预仿真确定。

奖励函数需要精准反映协议选择的优劣,同时抑制频繁切换导致的路由震荡。故设计加权多指标奖励函数,包含性能奖励与切换惩罚两部分:奖励函数 R 的表达式如下:

$$R = w_1 * O_{norm} + w_2 * D_{norm} + w_3 * L_{norm} - w_4 * \Delta A \quad (4-20)$$

其中, w_1, w_2, w_3 为性能指标权重,三者满足 $w_1 + w_2 + w_3 = 1$ 。 ΔA 为切换标志位, $\Delta A=0$ 表示不发生切换, $\Delta A=1$ 表示发生切换, w_4 为切换惩罚系数用于抑制不必要的频繁切换。本文在后续仿真中选取了一组能够使 Q-Learning 算法稳定收敛且性能均衡的权重值: $w_1=0.2, w_2=0.4, w_3=0.4$ 。同时,为抑制协议频繁切换造成的震荡,将切换惩罚系数 w_4 设为 0.1。

探索与利用的协同调控机制是 Q-Learning 算法挖掘潜在最优传输路径的核心策略。其中,探索过程体现为当前节点随机选取邻居节点,进而发掘未被探索的传输路径;利用过程则是依托历史交互反馈信息,优先选择 Q 值最优的邻居节点,以充分发挥已知最优路径的传输效能。如何构建探索与利用的动态平衡机制,是 Q-Learning 算法设计中的关键问题:若探索强度过高,会导致算法收敛速度缓慢甚至难以收敛;若过度依赖利用,则易陷入局部最优解,无法挖掘全局最优路径。因此,设计科学合理的探索,利用权衡策略对算法性能至关重要,本文采用 ϵ -greedy^[80] 策略实现二者的动态调控。公式如 4-21 所示:

$$\epsilon(t) = \max\left(\epsilon_{min}, \frac{\epsilon_{init} - \epsilon_{min}}{T_{decay}} * t\right) \quad (4-21)$$

其中, ϵ_{init} 代表初始探索概率, ϵ_{min} 代表最小探索概率, T_{decay} 代表决策周期,以适配拓扑动态变化的学习需求。随着学习的进行, ϵ 逐渐减小,算法从以探索为主过渡到以利用为主。

表 4-4 展示了 QAS 算法伪代码:

表 4-4 QAS 自适应路由协议切换算法

QAS 自适应路由协议切换算法
输入: 学习率 α , 折扣因子 γ , 初始探索率 ϵ_{init} , 最小探索率 ϵ_{min} , 衰减周期 T_{decay}
输出: 最优协议选择策略
1: 初始化 Q 表 $Q[S][A] \leftarrow 0, \forall S \in \text{状态空间}, A \in \{\text{OLSR-C}, \text{AODV-MFW}\}$

```

2: 初始化当前协议←OLSR-C
3: for 每个决策周期 T do
4:     采集网络状态指标（移动性、链路质量、密度、拥塞度）
5:     量化处理得到状态向量 $S=(S1, S2, S3, S4)$ 
6:      $\varepsilon(t) = \max\left(\varepsilon_{min}, \frac{\varepsilon_{init}-\varepsilon_{min}}{T_{decay}} * t\right)$ 
7:     if  $Random() < \varepsilon(t)$  then
8:          $A \leftarrow$  随机选择{OLSR-C, AODV-MFW}
9:     else
10:         $A \leftarrow Argmax_a Q[S][A]$ 
11:    end if
12:    if  $A \neq$  当前协议 then
13:        执行协议切换,  $\Delta A \leftarrow 1$ 
14:    else
15:        维持当前协议,  $\Delta A \leftarrow 0$ 
16:    end if
17:    采集性能指标（开销 $O$ 、时延 $D$ 、丢包率 $L$ ）
18:    归一化处理得 $O_{norm}, D_{norm}, L_{norm}$ 
19:    计算奖励  $R = w_1 * O_{norm} + w_2 * D_{norm} + w_3 * L_{norm} - w_4 * \Delta A$ 
20:    采集下一状态向量 $S'$ 
21:    更新 Q 表公式:  $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_{t+1} + \gamma \max_a Q(s_{t+1}, a_t) - Q(s_t, a_t)]$ 
22:    更新状态向量 $S \leftarrow S'$ 
23: end for

```

4.5 仿真验证与分析

为了验证改进协议的性能，本小节设计了对应的仿真环境。全面对比了相关协议和自适应切换算法性能表现。

4.5.1 网络仿真设置

为了描述网络负载的变化，用源节点发生数据包频率来表示网络负载的大小。

另外，采用高斯马尔可夫移动模型的无人节点在未知场景中随机移动的过程，三维空间场景大小为 2000m*2000m*200m，相关参数如表 4-5 所示：

表 4-5 仿真参数设置

仿真参数	参数值	仿真参数	参数值
仿真软件	NS3.31	节点速度	20m/s
数据包大小	1024Byte	节点数量	50-350
数据包发送方式	固定比特率	路由协议	AODV、 AODV-ETX ^[81] 、 AODV-MFW、OLSR、 P-OLSR ^[82] 、OLSR-C
Q-Learning 参数	$\alpha = 0.25$ $\gamma = 0.85$ $\varepsilon_{init} = 0.9$ $\varepsilon_{min} = 0.1$	网络	0.1s
传输层协议	UDP	传输范围	200m
物理层协议	802.11g	传输功率	20dBm

4.5.2 仿真结果分析

(1) AODV-MFW 及其相关协议仿真结果

在设置了节点速度平均为 20 m/s 移动情况下，以节点数量由低到高从 50 到 350 的网络场景来验证优化协议的性能表现。采用传统 AODV 和 AODV-ETX 两种路由协议作为对比协议进行实验。

由图 4-9 可知，三种协议随着节点数量的增大平均吞吐量都呈下降趋势。在节点数量相对较小的场景下，AODV-ETX 的平均吞吐量表现最优，均略高于 AODV-MFW，而原始 AODV 协议表现最差。这一阶段 AODV-ETX 凭借 ETX 度量对低损耗链路的精准选择，减少了传输重传开销，而 AODV-MFW 的多因素筛选逻辑尚未体现明显优势，仅在性能上略优于缺乏链路质量感知的原始 AODV。随着节点数量增至中高规模，AODV-MFW 的吞吐量优势逐渐凸显，且节点数量越多优势越显著。200 个节点时，AODV-MFW 数据分别比 AODV 和 AODV-ETX 提升 14.7%和 8.3%；当节点再次逐步增大时 AODV-MFW 的性能领先幅度扩大至 52.4%和 28.0%。这一变化的核心原因是，中高节点密度下，原始 AODV 的盲目泛洪导致信道冲突加剧，AODV-ETX 的 LPP 探针数据包额外占用有限带宽，而 AODV-MFW 通过网络密度阈值动态调整转发策略高密度时避免泛洪、选择传播区域内节点转发，结合剩余能量筛选避免节点过载失效，有效抑制了冗余开销和传输冲突，使得吞吐量衰减幅度显著低于另外两种协议，展现出

更强的节点规模适配能力。




图 4-9 不同节点规模下 AODV 相关协议平均吞吐量对比

由图 4-10 可知，随着节点数量的增加，网络拓扑复杂度提升、信道竞争加剧，且数据包转发跳数增多，导致传输等待时间和路由维护耗时同步增加。在低节点数量场景，AODV-ETX 的平均端到端时延表现最优，这是因为低节点密度下信道冲突较少，AODV-ETX 通过 ETX 度量筛选出的低损耗链路减少了数据包重传和传输误差，进而降低了时延，而 AODV-MFW 的多因素路由决策带来轻微额外计算开销，导致时延略高于 AODV-ETX，但显著低于缺乏链路质量感知的原始 AODV。随着节点数量增至中高规模，AODV-MFW 的时延控制优势逐渐扩大，且节点数量越多，优势越明显。当节点数增至 350 的时候，AODV-MFW 时延已经趋近平稳，而 AODV 和 AODV-ETX 已大幅度增加，领先幅度 14.4% 和 9.2%。核心原因在于，中高节点密度下，原始 AODV 的盲目泛洪导致信道拥堵加剧，AODV-ETX 探针数据包额外占用有限带宽，且二者均未考虑节点移动性和网络密度对路由稳定性的影响，易因链路频繁失效引发路由重建，进而增加时延；而 AODV-MFW 通过相对移动速度预判链路有效性，减少了路由失效后的重建耗时，同时基于网络密度动态调整转发策略，避免了高密度下的泛洪冲突，使得时延衰减幅度显著低于另外两种协议，展现出更强的高节点规模适配能力。




图 4-10 不同节点规模下 AODV 相关协议平均端到端时延对比

由图 4-11 可知，三种协议的丢包率均随节点数量增加而逐步上升，节点越多，信道竞争、链路冲突越剧烈，丢包概率越高。低节点数量场景下，AODV-ETX 表现稍优，丢包率略低于 AODV 和 AODV-MFW，这是因为 AODV-ETX 的低损耗链路选择减少了传输失败。当节点数量继续增大时，AODV-MFW 的丢包率优势明显凸显，且节点越多优势越突出。350 个节点时，AODV-MFW 丢包率仅 21.4%，远低于 AODV 和 AODV-ETX。这是因为 AODV-MFW 能通过多因素筛选避免无效转发和节点过载，而 AODV 盲目泛洪、AODV-ETX 忽视节点密度和能量，导致高节点规模下丢包率飙升更快，AODV-MFW 的稳定性更优。




图 4-11 不同节点规模下 AODV 相关协议丢包率对比

(2) OLSR-C 及其相关协议仿真结果

由图 4-12 可知三种协议的平均吞吐量均随节点数量增加依然呈下降趋势，低节点数量场景下，P-OLSR 表现稍优。P-OLSR 的核心优化是在 MPR 节点选举中引入优先级权重，优先选择剩余能量较高的节点充当 MPR，减少了低能量节点失效导致的链路中断，因此在低密度网络中比未考虑节点状态的原始 OLSR 更高效。当节点数量增至 200 个时，OLSR-C 的吞吐量优势逐渐凸显并稳定领先。分别高于 P-OLSR 和 OLSR；350 个节点时，OLSR-C 吞吐量仍维持在相对较高水平。这是由于 OLSR-C 的自适应 HELLO/TC 消息发送机制，能根据节点密度和移动状态动态调整控制消息间隔，有效抑制了高节点规模下的控制消息泛滥，减少了带宽占用；而 P-OLSR 未优化控制消息策略，高节点密度下 MPR 转发负担剧增，控制开销挤占数据带宽，导致吞吐量下降速度快于 OLSR-C，原始 OLSR 因固定消息发送间隔，性能恶化也较为明显。




图 4-12 不同节点规模下 OLSR 相关协议平均吞吐量对比

由图 4-13 可知，三种协议的平均端到端时延均随节点数量增加逐步上升。低节点数量场景下，P-OLSR 与 OLSR-C 表现接近且均显著优于原始 OLSR：这一阶段，P-OLSR 通过优先选择高能量 MPR 节点，减少了链路中断后的路由重建耗时；OLSR-C 则借助自适应 HELLO 消息间隔，及时感知邻居节点状态变化，避免了固定间隔带来的链路感知滞后，二者在时延控制上各有优势。当中高节点数量到来时，OLSR-C 的时延控制优势愈发明显，350 个节点时，OLSR-C 时延仅 0.85S。关键差异在于，OLSR-C 的自适应 TC 消息发送机制能根据拓扑变化动态调整同步频率，减少了高节点密度下的冗余拓扑更新，缓解了信道拥堵。




图 4-13 不同节点规模下 OLSR 相关协议平均端到端时延对比

由图 4-14 可知，三种协议的丢包率均随节点数量增加呈上升趋势，节点越多，链路竞争、带宽占用冲突越剧烈，数据包丢失概率越高。低节点数量场景下，OLSR-C 表现最优，略优于 P-OLSR 和原始 OLSR。这一阶段，OLSR-C 通过自适应 HELLO 消息间隔及时规避了不稳定链路，减少了传输失败；P-OLSR 则依靠高能量 MPR 节点的稳定性，降低了因节点失效导致的丢包，而原始 OLSR 因缺乏针对性优化，丢包率明显偏高。节点数量增加时，OLSR-C 的丢包率上升幅度最小，优势愈发显著。核心原因是 OLSR-C 的动态消息发送策略有效控制了高节点规模下的控制消息开销，避免了带宽被过度挤占，减少了数据传输冲突导致的丢包；而 P-OLSR 和原始 OLSR 均未解决高节点密度下的控制消息冗余问题，MPR 节点转发压力剧增，数据传输资源被挤压，最终导致丢包率快速飙升，OLSR-C 的动态适配能力使其展现出更优的传输稳定性。




图 4-14 不同节点规模下 OLSR 相关协议丢包率对比

(3) 基于 QL 的切换算法

设置在节点固定为 200 个节点的情况下，实时统计在仿真时长 200s 内平均吞吐量，平均端到端时延，丢包率的数据表现验证切换算法对整体性能的影响。

由图 4-15 可知，从数据演化来看，AODV-MFW 的吞吐量始终处于波动状态，OLSR-C 则表现为平稳但低效，吞吐量长期维持在窄幅区间。而 QAS 的吞吐量呈现清晰的稳步上升趋势。QAS 的优势在仿真初期，网络拓扑相对稳定，QAS 通过 Q-Learning 可以快速感知到较优路由，使得自身吞吐量快速追平并超越；随着仿真推进，节点移动引发拓扑动态变化，QAS 能快速捕捉到网络变化选择合适的路由协议，实现高效数据传输；仿真后期，网络进入动态稳定阶段，QAS 已通过持续学习掌握两种协议的适配规律，实现取长补短，最终将吞吐量稳定在高位区间。




图 4-15 平均吞吐量对比图

与此同时，由图 4-16 可知，仿真周期内 QAS 在端到端时延控制上展现出碾压性优势，全程保持更低时延和更高稳定性的双重特性，显著超越 AODV-MFW 和 OLSR-C 两种单一路由协议，充分验证了智能自适应决策对时延优化的核心价值。QAS 能充分利用低时延路由模式的特性，减少数据传输的等待与转发耗时；当网络拓扑发生动态变化时，它又能快速适配高稳定性路由模式的优势，规避路由中断或重建带来的时延激增；即便在网络状态频繁波动的阶段，也能通过已学习的适配规律，灵活平衡传输效率与链路稳定性，始终将时延控制在低位。




图 4-16 平均端到端时延对比图

由图 4-17 可知，在丢包率的指标上 QAS 同样展现出更低丢包和更强稳定的双重核心优势，显著优于 AODV-MFW 和 OLSR-C 两种单一路由协议，充分印证了智能自适应决策对传输可靠性的提升价值。量化对比来看，QAS 的平均丢包率比 AODV-MFW 和 OLSR-C 降低大约 2 个百分点；且在整个仿真周期内，QAS 的丢包率波动幅度仅为两种单一协议的三分之一左右，展现出极强的传输可靠性。这一结果再次充分证明，QAS 通过智能自适应机制，成功规避了单一路由协议在丢包率控制上的固有短板。




图 4-17 丢包率对比图

4.6 本章小结

针对无人异构网络场景中传统 OLSR 和 AODV 路由协议面临的场景适配局限性问題，分别对两种协议进行了改进优化，并在此基础上提出了基于 Q-Learning 的自适应路由协议切换算法 QAS。首先，针对传统 OLSR 协议固定消息发送间隔导致的拓扑感知滞后与带宽浪费问题，设计了 OLSR-C 协议；其次，针对传统 AODV 协议盲目泛洪引发的广播风暴与链路频繁失效问题，设计了 AODV-MFW 协议；最后，考虑到单一协议难以适应全场景需求，提出了 QAS 自适应切换算法。NS-3 仿真结果表明，在不同节点规模的网络场景下，相比传统 OLSR、AODV 及其对应已有改进协议，OLSR-C 和 AODV-MFW 在平均吞吐量、平均端到端时延及丢包率方面均有显著提升；QAS 切换算法通过智能协议选择，进一步优化了网络长期的整体性能，充分验证了所提方案的有效性与实用性。

结 论

本文针对无人异构网络中路由协议场景适配局限性和垂直切换决策效率不足两大核心问题，分别从路由协议自适应切换和垂直切换优化两个方面展开研究，提出了相应的改进方案并通过 NS-3 仿真进行了验证。主要研究工作与结论如下：

(1) 针对无人异构网络中垂直切换面临的乒乓切换频繁、决策滞后及固定权重难以适应动态环境等问题，提出了基于 LSTM-Attention 的自适应垂直切换算法 LAHVHA。该算法利用堆叠 LSTM 网络对网络状态参数进行时序预测实现主动式切换决策，通过 Multi-Head Attention 机制根据网络状态与无人节点移动特征动态生成各属性权重，结合改进 TOPSIS 方法构建融合当前状态与预测状态的决策矩阵进行最优网络选择，并引入双重滞后机制有效抑制乒乓切换。仿真结果表明，LAHVHA 算法在平均切换次数、平均端到端时延、丢包率和平均吞吐量等指标上均显著优于对比算法，消融实验进一步验证了 LSTM 预测模块和 Attention 动态权重生成模块对提升切换决策质量的关键作用。

(2) 针对传统 OLSR 协议固定消息发送间隔导致的拓扑感知滞后与控制消息泛滥问题，设计了 OLSR-C 协议，通过融合节点移动特征与邻居密度动态调整 HELLO/TC 消息发送间隔，在路由开销与拓扑适配性之间取得平衡；针对传统 AODV 协议盲目泛洪引发的广播风暴与链路频繁失效问题，提出了 AODV-MFW 协议，结合传播区域约束、相对移动速度预判、剩余能量与网络密度等多因素优化转发节点选择策略。在此基础上，考虑到单一协议难以适应全场景需求，提出了基于 Q-Learning 的自适应路由协议切换算法 QAS，以节点移动性、链路质量、网络密度和拥塞度为状态空间，通过强化学习实时感知网络状态并智能选择最优协议，实现 OLSR-C 与 AODV-MFW 的动态互补。仿真结果表明，改进协议在不同节点规模下的平均吞吐量、平均端到端时延及丢包率方面均显著优于传统协议及已有改进方案，QAS 算法通过智能协议选择进一步提升了网络整体性能。

尽管本文提出的改进协议和算法在仿真环境中取得了良好的性能表现，但仍有一些研究方向值得进一步探索：

(1) 分别独立研究了路由协议自适应切换和垂直切换问题，未来可考虑将两者进行联合设计，在垂直切换决策中同步考虑路由协议的适配性，在路由协议选择中融入网络切换状态信息，实现跨层协同优化，进一步提升无人异构网络的整体通信性能。

(2) 当前研究基于 NS-3 仿真平台进行性能验证，未来将重点推进算法在实际无人异构网络环境中的部署与测试，针对硬件资源受限的特性优化模型计算复杂度和内存占用，并验证算法在真实信道条件和多样化任务场景下的实际效果，为无人异构网络的工程应用提供技术支撑。

致 谢

时光荏苒，数载求学之路即将画上句点，一时间不知道写些什么。回首这段充实而珍贵的研究生生涯，从初入校园的懵懂探索，到论文写作中的反复打磨，每一步成长都离不开师长、亲友与同窗的陪伴与支持。在此，我谨以最诚挚之心，向所有给予我帮助与关怀的人们致以深深的谢意。

首先，我由衷地感谢我的导师罗俊松，多滨老师。从论文选题、框架搭建，到理论研究、实验设计与反复修改，导师都给予了我悉心指导与耐心点拨。导师严谨的治学态度、深厚的学术素养与求真务实的科研精神，让我受益终身，也为我今后的学习与工作树立了榜样。在此，致以最崇高的敬意与最真挚的感谢。

感谢和我一起共度研究生三年时光的同门宁元凯，兰国豪，李宇佳，王俊，丁俊文。在我遇到困难时给予无私帮助与鼓励，营造了积极向上、互帮互助的良好氛围，让我研究生阶段的学习生活充满温暖与力量。

感谢我的父母。你们是最坚实的后盾，始终默默支持、理解与包容我的选择，在我迷茫与疲惫时给予温暖与力量，让我能够心无旁骛地完成学业，勇敢面对挑战。

最后，谨向在三年研究生时光里，于求学途中曾相伴一程的人，致以诚挚的谢意。如今虽已各自奔赴前路，或许再难朝夕相伴，但每一次相遇皆有馈赠，每一段同行都藏着温暖。纵此后山高水远，天各一方，也惟愿岁月温柔以待，你我各自安好，喜乐常伴，岁岁无忧。

愿所有师长、亲友顺遂安康，愿所有奔赴理想的人皆有所成。

谨以此文，献给我平凡却热烈的勇敢的青春。

再见，二仙桥东三路 1 号。

参考文献

- [1] Banks D B, Liu Y C. Statistics, AI, and Autonomous Vehicles[J]. Amstat News, 2023, 555: 10-15.
- [2] Chen J, Sun J, Wang G. From Unmanned Systems to Autonomous Intelligent Systems[J]. Engineering, 2022, 12: 16-19.
- [3] Ahmed F, Mohanta J C, Keshari A, et al. Recent Advances in Unmanned Aerial Vehicles: A Review[J]. Arabian Journal for Science and Engineering, 2022, 47(7): 7963-7984.
- [4] Rejeb A, Rejeb K, Simske S J, et al. Drones for supply chain management and logistics: a review and research agenda[J]. International Journal of Logistics Research and Applications, 2023, 26(6): 708-31.
- [5] Masroor R, Naeem M, Ejaz W. Efficient deployment of UAVs for disaster management: A multi-criterion optimization approach[J]. Computer Communications, 2021, 177: 185-94.
- [6] Maddikunta P K R, Hakak S, Alazab M, et al. Unmanned aerial vehicles in smart agriculture: Applications, requirements, and challenges[J]. IEEE sensors journal, 2021, 21(16): 17608-19.
- [7] 赵雪圻,崔玉波.乒乓切换问题的区域用户预测研究[J].山东通信技术,2022,42(04):40-42.
- [8] Yu H, Ma Y, Yu J. Network selection algorithm for multiservice multimode terminals in heterogeneous wireless networks[J]. IEEE Access, 2019, 7: 46240-46260.
- [9] Han C, Sun L, Wang C, et al. A handoff algorithm based on network calculus for heterogeneous wireless networks[C]//2022 China Automation Congress (CAC). IEEE, 2022: 4113-4118.
- [10] Wang X, Su X, Liu B. A Novel Network Selection Approach in 5G Heterogeneous Networks Using Q-Learning[C]//2019 26th International Conference on Telecommunications (ICT). IEEE, 2019: 309-313.
- [11] Tan X, Chen G, Sun H. Vertical handover algorithm based on multi-attribute and neural network in heterogeneous integrated network[J]. EURASIP Journal on Wireless Communications and Networking, 2020, 2020(1): 202.
- [12] Wheeb A H, Al-Jamali N A S. Performance analysis of OLSR protocol in mobile ad hoc networks[J]. iJIM, 2022, 16(01): 107.
- [13] Maurya P K, Sharma G, Sahu V, et al. An overview of AODV routing protocol[J]. International Journal of Modern Engineering Research (IJMER), 2012, 2(3): 728-32.
- [14] Raju S R, Runkana K, Mungara J. ZRP versus AODV and DSR: A comprehensive study on ZRP performance[J]. International Journal of Computer Applications, 2010, 1(12): 36-41.

- [15] Kumar M, Rishi R, Madan D. Comparative analysis of CBRP, DSR, AODV routing protocol in MANET[J]. International Journal on Computer Science and Engineering (IJCSE), 2010, 2(09): 2853-8.
- [16] Tan K, Bremner D, Le Kernec J, et al. Intelligent handover algorithm for vehicle-to-network communications with double-deep Q-learning[J]. IEEE transactions on vehicular technology, 2022, 71(7): 7848-7862.
- [17] Yang K, Wang Y, Gao X, et al. Communications in Space–Air–Ground Integrated Networks: An Overview[J]. Space: Science & Technology, 2025, 5: 0199.
- [18] Chandran I, Vipin K. Multi-UAV Networks for Disaster Monitoring: Challenges and Opportunities from a Network Perspective[J]. Drone Systems and Applications, 2024, 12: 1-28.
- [19] Ribeiro L M B, Müller I, Buss Becker L. Communication Interface Manager for Improving Performance of Heterogeneous UAV Networks[J]. Sensors, 2021, 21(13): 4255.
- [20] Ayass T, Coqueiro T, Carvalho T, et al. Unmanned Aerial Vehicle with Handover Management Fuzzy System for 5G Networks: Challenges and Perspectives[J]. Intelligence & Robotics, 2022, 2(1): 20-36.
- [21] Wang Z, Lv Z, Xu X, et al. Vertical Switching Algorithm for Unmanned Aerial Vehicle in Power Grid Heterogeneous Communication Networks[J]. Electronics, 2024, 13(13): 2612.
- [22] Alam S, Sulisty S, Mustika I W, et al. Handover Decision for V2V Communication in VANET Based on Moving Average Slope of RSS[J]. J. Commun., 2021, 16(7): 284-293.
- [23] Satapathy P, Mahapatro J. An efficient multicriteria-based vertical handover decision-making algorithm for heterogeneous networks[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(4): e4409.
- [24] Goutam S, Unnikrishnan S, Karandikar A. Algorithm for handover decision based on TOPSIS[C]//2020 International Conference on UK-China Emerging Technologies (UCET). IEEE, 2020: 1-4.
- [25] Zolfani S, Yazdani M, Pamucar D, et al. A VIKOR and TOPSIS focused reanalysis of the MADM methods based on logarithmic normalization[J]. arXiv preprint arXiv:2006.08150, 2020.
- [26] Xiao K Y, Li C G. Vertical handoff decision algorithm for heterogeneous wireless networks based on entropy and improved TOPSIS[C]. 2018 IEEE 18th International Conference on Communication Technology (ICCT), 2018: 706-710.
- [27] Ahmed I I O, Ipaye A A, Mitropoulos D N G, et al. Vertical handover E-TOPSIS algorithm mathematical model using AHP and standard deviation weighing method[C]//2019 International Conference on Computer, Control, Electrical, and Electronics Engineering (ICCCEEE). IEEE, 2019: 01-05.

- [28] Silva F S D, Lima M P S, Corujo D, et al. A Comprehensive Step-Wise Survey of Multiple Attribute Decision-Making Mobility Approaches[J]. IEEE Access, 2024.
- [29] 李远彤, 石振刚. 基于组合权重和多属性决策的异构网络接入算法[J]. 科技资讯, 2023, 21(08): 25-28.
- [30] 华振兴. 决策树算法在无人船异构通信网络切换中的应用[J]. 舰船科学技术, 2022, 44(24): 67-70+131.
- [31] Goutam S, Unnikrishnan S, Kudu N. Decision for Vertical Handover Using K-means Clustering Algorithm[C]. 2020 IEEE Bombay Section Signature Conference (IBSSC), 2020: 31-35.
- [32] Tanveer J, Haider A, Ali R. Reinforcement Learning-Based Optimization for Drone Mobility in 5G and Beyond Ultra-Dense Networks[J]. Computers, Materials & Continua, 2021, 68(3).
- [33] 祝经, 周新力, 宋斌斌, 等. 无人机自组网GPSR路由协议研究[J]. 兵器装备工程学报, 2021, 42(12): 81-6.
- [34] Wheeb A H, Nordin R, Samah A A, et al. Performance evaluation of standard and modified OLSR protocols for uncoordinated UAV ad-hoc networks in search and rescue environments[J]. Electronics, 2023, 12(6): 1334.
- [35] Lansky J, Rahmani A M, Malik M H, et al. An energy-aware routing method using firefly algorithm for flying ad hoc networks[J]. Scientific Reports, 2023, 13(1): 1323.
- [36] El-Basioni B M M. Intensive study, tuning and modification of reactive routing approach to improve flat FANET performance in data collection scenario[J]. Scientific Reports, 2024, 14(1): 23467.
- [37] Hosseinzadeh M, Husari F M, Yousefpour M S, et al. A local filtering-based energy-aware routing scheme in flying ad hoc networks[J]. Scientific Reports, 2024, 14(1): 17733.
- [38] Garg S, Ihler A, Bentley E S, et al. A hybrid reactive routing protocol for decentralized UAV networks[J]. IEEE Transactions on Aerospace and Electronic Systems, 2025.
- [39] Sirait F, Mulyono, Dani A W, et al. An Energy-Aware Zone Routing Protocol Scheme Utilizing LSTM-RNN for 5G Wireless Backhaul Network[C]. 2023 International Conference of Computer Science and Information Technology (ICOSNIKOM), 2023: 1-6.
- [40] 王翔宇, 张艳语, 李龙, 等. 基于自适应果蝇优化算法的加权分簇算法[J]. 系统工程与电子技术, 2023, 45(7): 2259-2268.
- [41] Fang W, Zhang W, Yang W, et al. Trust management-based and energy efficient hierarchical routing protocol in wireless sensor networks[J]. Digital Communications and Networks, 2021, 7(4): 470-8.
- [42] Yang X, Li M, Qian Z, et al. Improvement of GPSR protocol in vehicular ad hoc network[J]. IEEE Access, 2018, 6: 39515-39524.

- [43] Husain A, Kumar B, Doegar A. A study of Location Aided Routing (LAR) protocol for vehicular ad hoc networks in highway scenario[J]. International Journal of Engineering and Information Technology, 2010, 2(2): 118-24.
- [44] Zhong Y, Wang H, Lv H, et al. A vertical handoff decision scheme using subjective-objective weighting and grey relational analysis in cognitive heterogeneous networks[J]. Ad hoc networks, 2022, 134: 102924.
- [45] Tanveer J, Haider A, Ali R, et al. An overview of reinforcement learning algorithms for handover management in 5G ultra-dense small cell networks[J]. Applied Sciences, 2022, 12(1): 426..
- [46] Yang H, Pu C, Wu J, et al. Enhancing OLSR protocol in VANETs with multi-objective particle swarm optimization[J]. Physica A: Statistical Mechanics and its Applications, 2023, 614: 128570.
- [47] Jin R, Zhang X, Liu J, et al. A comprehensive evaluation algorithm of multi-point relay based on link-state awareness for UANETs[J]. Sensors, 2024, 24(5): 1702.
- [48] Nabati M, Maadani M, Pourmina M A. AGEN-AODV: an intelligent energy-aware routing protocol for heterogeneous mobile ad-hoc networks[J]. Mobile Networks and Applications, 2022, 27(2): 576-587.
- [49] Li Y, Li Q, Yu H, et al. TAAODV: TOPSIS-aided AODV routing protocol to diffuse mass information in the unstable and high-density UAV ad hoc networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2024.
- [50] Bellman R. A markovian decision process[J]. Indiana University Mathematics Journal, 1957, 6(5): 679-684.
- [51] Sutton R, Barto A. Reinforcement learning: An introduction[M]. MIT press, 2018.
- [52] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.
- [53] Watkins C, Dayan P. Q-learning[J]. Machine learning, 1992, 8(3): 279-292.
- [54] Manzoor S, Manzoor M, Manzoor H, et al. Which simulator to choose for next generation wireless network simulations? ns-3 or omnet++[J]. Engineering Proceedings, 2023, 46(1): 36.
- [55] Khanderao K S, Khedekar L S. Study and systematic review of computer network simulation with NS-3[J]. International Journal of Interdisciplinary Innovative Research &Development (IJIIRD), 2021, 6(1): 28-33.
- [56] Yin H, Liu P, Liu K, et al. ns3-ai: Fostering artificial intelligence algorithms for networking research[C]. Proceedings of the 2020 Workshop on ns-3, 2020: 57-64.

- [57] Benelhourri A, Idrissi-Saba H, Antari J. An improved gateway-based energy-aware multi-hop routing protocol for enhancing lifetime and throughput in heterogeneous WSNs[J]. *Simulation Modelling Practice and Theory*, 2022, 116: 102471.
- [58] Ayub M S, Adasme P, Melgarejo D C, et al. Intelligent Hello Dissemination Model for FANET Routing Protocols[J]. *IEEE Access*, 2022, 10: 46513-25.
- [59] Goudarzi S, Anisi M H, Ciuonzo D, et al. Employing unmanned aerial vehicles for improving handoff using cooperative game theory[J]. *IEEE Transactions on Aerospace and Electronic Systems*, 2022, 57(2): 776-794.
- [60] Abdullah N F, Zukarnain Z A. Enhanced TOPSIS based vertical handover algorithm for heterogeneous networks[J]. *ETRI Journal*, 2023, 45(3): 456-468.
- [61] Ndegwa K M, Orero J O. User preference-based heterogeneous network management system for vertical handover[J]. *Journal of Electrical and Computer Engineering*, 2023, 2023: 5551773.
- [62] Chen Y, Zhang H, Liu J, et al. Research on adaptive handover decision algorithm in next-generation high-speed railway scenario[J]. *Mobile Information Systems*, 2022, 2022: 7557917.
- [63] Kaur G, Goyal R K, Mehta R. An efficient handover mechanism for 5G networks using hybridization of LSTM and SVM[J]. *Multimedia Tools and Applications*, 2022, 81(26): 37057-37085.
- [64] Kim S, Lim H. Reinforcement learning based handover management for 5G networks[J]. *IEEE Wireless Communications Letters*, 2022, 11(5): 1045-1049.
- [65] Al-Hourani A, Kandeepan S, Lardner S. Optimal LAP altitude for maximum coverage[J]. *IEEE Wireless Communications Letters*, 2014, 3(6): 569-572.
- [66] Panaitopol D, Jin Y, Tang R, et al. Requirements on satellite access node and user equipment for non-terrestrial networks in 5G new radio of 3GPP Release-17[J]. *International journal of satellite communications and networking*, 2023, 41(3): 289-301.
- [67] Malashin I, Tynchenko V, Gantimurov A, et al. Applications of long short-term memory (LSTM) networks in polymeric sciences: A review[J]. *Polymers*, 2024, 16(18): 2607.
- [68] Soydaner D. Attention mechanism in neural networks: where it comes and where it goes[J]. *Neural Computing and Applications*, 2022, 34(16): 13371-13385.
- [69] Song X, Liu J, Lei J, et al. Vertical switching algorithm considering multiple factors for new energy distribution network business[C]//2024 6th International Conference on Energy, Power and Grid (ICEPG). IEEE, 2024: 274-277.
- [70] Jang Y, Raza S M, Kim M, et al. Proactive handover decision for UAVs with deep reinforcement learning[J]. *Sensors*, 2022, 22(3): 1200.

- [71] Zaid M, Kadir M K A, Shayea I, et al. Machine learning-based approaches for handover decision of cellular-connected drones in future networks: A comprehensive review[J]. Engineering Science and Technology, an International Journal, 2024, 55: 101732.
- [72] Jain R, Kashyap I. An QoS aware link defined OLSR (LD-OLSR) routing protocol for MANETs[J]. Wireless Personal Communications, 2019, 108(3): 1745-1758.
- [73] 孙一凡, 米志超, 王海, 等. 基于分簇的拓扑自适应的无人机蜂群OLSR路由协议[J]. 计算机科学, 2021, 48(6): 268-275.
- [74] 吴鹏飞, 杨正保. 基于邻节点数目和位置信息改进的AODV路由协议[J]. 传感器与微系统, 2024, 43(08): 126-128.
- [75] Jevtic N J, Malnar M Z. The NS-3 simulator implementation of ETX metric within AODV protocol[C]//2017 25th Telecommunication Forum (TELFOR). IEEE, 2017: 1-4.
- [76] 陈付亮, 杨清香, 赵长春, 等. 结合链路稳定因子的AODV路由协议优化[J]. 飞控与探测, 2024, 7(04): 96-103.
- [77] Lansky J, Ali S, Rahmani A M, et al. Reinforcement Learning-Based Routing Protocols in Flying Ad Hoc Networks (FANET): A Review[J]. Mathematics, 2022, 10(16): 3017.
- [78] Aktas F, Shayea I, Ergen M, et al. AI-enabled routing in next generation networks: A survey[J]. Alexandria Engineering Journal, 2025, 120: 449-74.
- [79] Alam M M, Moh S. Survey on Q-Learning-Based Position-Aware Routing Protocols in Flying Ad Hoc Networks[J]. Electronics, 2022, 11(7): 1099.
- [80] 冯宇旭, 李裕梅. 深度学习优化器方法及学习率衰减方式综述[J]. 数据挖掘, 2018, 8(4): 15.
- [81] Ardianto B, Nurcahyo H S D, Muftić H, et al. Performance Comparison of AODV, AODV ETX and Modified AODV-ETX in VANET Using NS3[C]. 2022 IEEE International Conference on Cybernetics and Computational Intelligence (CyberneticsCom), 2022: 156-161.
- [82] Gangopadhyay S, Jain V K. A position-based modified OLSR routing protocol for flying ad hoc networks[J]. IEEE Transactions on Vehicular Technology, 2023, 72(9): 12087-12098.

在读期间发表的学术论文与研究成果

已发表论文:

第一作者. Performance Analysis for GPSR-Based Protocols Under Large-Scale UAV Ad Hoc Networks[C]. Trends in Advanced Unmanned Aerial Systems, 2025: 331-7.

第一作者. 无人异构网络切换方法研究[J/OL].无线电通信技术,1-16.

在校期间获奖情况:

2023 年 10 月, 获得成都理工大学研究生学业奖学金三等奖。

2025 年 10 月, 获得成都理工大学研究生学业奖学金三等奖。

附录

附录 A 英文缩略词对照表

缩略词	英文解释	中文解释
OLSR	Optimized Link State Routing	优化链路状态路由
AODV	Ad hoc On-Demand Distance Vector	按需距离矢量路由
OLSR-C	Optimized Link State Routing Control	控制消息发送策略改进 OLSR 路由协议
AODV-MFW	Ad hoc On-Demand Distance Vector Multi-Factor Weighted	多因素权重 AODV 路由协议
QAS	Q-Learning based Adaptive Routing Protocol Switching Algorithm	基于 Q-Learning 的自适应路由协议切换算法
LAHVHA	Long Short-Term Memory-Attention based Adaptive Vertical Handover Algorithm	长短期记忆神经网络和注意力机制的自适应垂直切换算法
TOPSIS	Technique for Order Preference by Similarity to an Ideal Solution	逼近理想解排序法
AHP	Analytic Hierarchy Process	层次分析法
ZRP	Zone Routing Protocol	区域路由协议
CBRP	Cluster-Based Routing Protocol	分簇路由协议
RSS	Received signal strength	信号强度
MADM	Multiple Attribute Decision Making	多属性决策
GPSR	Greedy Perimeter Stateless Routing	贪婪周边无状态路由协议
LAR	Location-Aided Routing	位置辅助路由
MPR	Multipoint Relay	多点中继
TC	Topology Control	拓扑控制
RREQ	Route Request	广播路由请求
RREP	Route Reply	单播路由回复
MDP	Markov Decision Process	马尔可夫决策过程
RL	Reinforcement Learning	强化学习
LTE	Long Term Evolution	长期演进
LoS	Line-of-Sight	视距
NLoS	Non-Line-of-Sight	非视距
DRL-based RSS	Deep Reinforcement Learning-based Received Signal Strength	深度强化学习的接收信号强度决策算法
Muti-VSA	Multi-factor vertical switching algorithm	多因素垂直切换算法